

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ
ФЕДЕРАЦИИ

НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ ЯДЕРНЫЙ УНИВЕРСИТЕТ «МИФИ»

ИНСТИТУТ ИНТЕЛЛЕКТУАЛЬНЫХ КИБЕРНЕТИЧЕСКИХ СИСТЕМ

КАФЕДРА № 42 «КРИПТОЛОГИЯ И КИБЕРБЕЗОПАСНОСТЬ»

На правах рукописи

УДК 004.056.5:004.42

Ушаков Андрей Вячеславович

«Методика автоматической трансляции программного кода между языками с
сохранением семантики безопасности»

Выпускная квалификационная работа магистра

Направление подготовки 10.04.01
«Информационная безопасность»

Выпускная квалификационная
работа защищена

«__»_____2026 г.

Оценка

Секретарь ГЭК _____

г. Москва

2026

РЕФЕРАТ

Отчет: 237 с., 0 рис., 12 табл., 44 источн., 1 прил.

СВОЙСТВО БЕЗОПАСНОСТИ, ОТПЕЧАТОК БЕЗОПАСНОСТИ,
КЛАССЫ БЕЗОПАСНОСТИ, СЕМАНТИКА БЕЗОПАСНОСТИ,
СОХРАНЕНИЕ СЕМАНТИКИ БЕЗОПАСНОСТИ, ТРАНСЛЯЦИЯ КОДА,
СИМПЛИФИКАЦИЯ КОДА

Объектом исследования в данной работе является процесс автоматической трансляции программного кода между различными языками программирования.

Целью данной работы является разработка и экспериментальная проверка методики автоматической трансляции кода между языками программирования, обеспечивающей контролируемое сохранение семантики безопасности и тем самым повышающей управляемость и предсказуемость изменений защитных свойств при трансляции.

В процессе работы были проанализированы существующие подходы для обеспечения безопасности при компиляции; разработан подход с формированием отпечатка безопасности, классификацией свойств безопасности в сформированном отпечатке, сформулированы условия, при выполнении которых можно считать, что семантика безопасности сохраняется при трансляции. Была предложена идея симплификации исходного кода для упрощения кода транслятора, реализованы симплификатор для исходного кода на C# и транслятор с языка C# на язык Python; был проведен эксперимент, использующий разные подходы к трансляции кода.

В результате работы была создана методика по анализу и сохранению семантики безопасности при автоматической трансляции; был проведен эксперимент, демонстрирующий работу этой методики.

Результаты данной работы могут быть использованы для предсказания поведения отпечатка безопасности при трансляции кода и действий для минимизации потери свойств безопасности при трансляции.

СОДЕРЖАНИЕ

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ.....	7
ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ	9
ВВЕДЕНИЕ	10
1 Постановка задачи и рамки исследования.....	13
1.1 Актуальность. Почему проблема важна.....	13
1.2 Объект исследования	13
1.3 Предмет исследования	14
1.4 Задача исследования	14
1.5 Цель.....	15
1.6 Гипотеза	16
1.7 Новизна	16
1.8 Теоретическая и практическая значимость.....	16
1.9 Положения на защиту	18
1.10 Что такое трансляция кода	18
1.11 Трансляция кода с точки зрения функциональных и нефункциональных требований.....	19
1.12 Ограничения в рамках работы	23
2 Обзор подходов к безопасной компиляции и валидации трансляции	24
2.1 Secure compilation (безопасная компиляция)	24
2.2 Translation validation (валидация трансляции)	27
2.3 Verified compilation (верифицируемая компиляция).....	29
2.4 Сравнение с используемым подходом.....	31
3 Модель безопасности.....	38
3.1 Свойства безопасности кода	38
3.2 Понятие отпечатка безопасности.....	40
3.3 Сравнение отпечатков безопасности	43
3.4 Что такое семантика безопасности кода	46

3.5 Классы безопасности. Эволюция отпечатка безопасности во время трансляции.....	46
3.5.1 Попытка сохранения правильного доступа к членам при трансляции кода с языка C# на язык Python.....	54
3.6 Проблемы с внешними зависимостями.....	61
3.7 Сохранение семантики безопасности при трансляции	63
3.8 Влияние окружения (контекста использования).....	65
3.9 Цели трансляции и влияние на требования к сохранению семантики безопасности.....	68
3.10 Математическая формализация семантики безопасности кода	71
3.10.1 Формальная модель программы и трансляции.....	71
3.10.2 Модель свойств безопасности	72
3.10.3 Классификация уровней сохранения.....	72
3.10.4 Отпечаток безопасности.....	73
3.10.5 Метрика допустимого ослабления.....	74
3.10.6 Гипотеза симплификации.....	75
3.11 Нормативные и методические основания формирования отпечатка безопасности.....	75
3.12 Угрозы безопасности при трансляции	78
3.13 Построение методики трансляции	84
4 Методика автоматической трансляции.....	86
4.1 Теоретическая часть: что такое компиляция. Как она работает - лексический, синтаксический анализ, AST, семантика, генерация кода	86
4.2 Что такое автоматическая трансляция. Технические сложности, возникающие при трансляции	88
4.3 Неформальная классификация языков и платформ	90
4.3.1 Подход к управлению памятью.....	90
4.3.2 Статически и динамически типизированные языки.....	91

4.3.3 Языки с сильной и слабой типизацией.....	92
4.3.4 Парадигмы (стили), поддерживаемые языками.....	93
4.4 Проблемы при трансляции кода и возможные пути их решения.....	95
4.4.1 Трансляция кода с managed языков на unmanaged языки.....	95
4.4.2 Трансляция кода с unmanaged языков на managed языки.....	98
4.4.3 Трансляция кода с динамически типизированных языков на языки со статической типизацией	98
4.4.4 Трансляция кода с языков со статической типизацией на динамически типизированные языки.....	101
4.4.5 Трансляция кода с ООП языка на языки с частичной поддержкой ООП.....	101
4.4.6 Другие проблемы при трансляции между языками.....	103
4.4.7 Вывод	104
4.5 Проблема согласования АПИ между языками.....	105
4.6 Проблема сложности трансляции. Симплификация исходного кода как путь упрощения кода транслятора.....	107
4.7 Возможность ручного управления трансляцией.....	118
4.8 Применимость методики трансляции	119
4.9 Общая последовательность шагов при трансляции	120
4.10 Корректность и полнота реализации транслятора	123
5 Реализация.....	126
5.1 Общие положения, принятые для реализации	126
5.2 Минимальная последовательность шагов для запуска трансляции....	127
5.3 Максимальная (полная) последовательность шагов для запуска трансляции.....	127
5.4 Симплификатор. Детали реализации	129
5.5 Транслятор. Детали реализации.....	133
5.5.1 Проблема с перегруженными методами.....	133

5.5.2 Проблема согласования АПИ между языками	138
5.5.3 Правила именования объектов	139
6 Эксперимент	141
6.1 Исходный код.....	141
6.2 Результат трансляции кода с использованием симплификатора и транслятора.....	151
6.3 Результат ручной трансляции кода	162
6.4 Результат трансляции кода с помощью LLM.....	170
6.5 Выводы из результатов экспериментов	216
7 Ограничения	224
ЗАКЛЮЧЕНИЕ	230
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ.....	233
ПРИЛОЖЕНИЕ А Исходный код транслятора и симплификатора	237

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

В настоящем отчете применяют следующие термины с соответствующими определениями:

Common Vulnerabilities and Exposures	—	Международный стандарт и открытый каталог общеизвестных уязвимостей в программном обеспечении
Common Weakness Enumeration	—	Международный классификатор типичных ошибок и дефектов в программном или аппаратном коде, архитектуре и логике
Name mangling	—	Процесс преобразования имён функций, переменных или классов в уникальные идентификаторы на этапе компиляции или трансляции кода
readonly-семантика	—	Семантика неизменяемости полей, помеченных как только для чтения (readonly-полей)
Отпечаток безопасности	—	Набор всех (или интересующих нас) свойств безопасности для данной кодовой базы или для конкретной сущности
Симплификация	—	Упрощение исходного кода программы с помощью анализа и преобразования AST
Типобезопасность	—	Свойство языка программирования, гарантирующее, что код работает только с теми типами данных, которые ему разрешены
Транслятор	—	Программа, реализующая фазу трансляции компилятора, в которой на шаге кодогенерации вместо генерирования последовательности инструкций, которые

могут выполняться на целевой машине, генерируются сущности кода (типы, функции, операторы, выражения и т.п.) на некотором языке

Трансляция кода

— Преобразование исходного кода, написанного на одном языке программирования, в исходный код на другом языке программирования с максимально возможным сохранением структуры, функционального поведения и релевантных нефункциональных свойств

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ

В настоящем отчете применяют следующие сокращения и обозначения:

API	—	Application Programming Interface	—	программный интерфейс приложения
AST	—	Abstract Syntax Tree	—	абстрактное синтаксическое дерево
CVE	—	Common Vulnerabilities and Exposures		
CWE	—	Common Weakness Enumeration		
DAST	—	Dynamic Application Security Testing	—	метод динамического тестирования безопасности
GCC	—	GNU Compiler Collection		
LLM	—	Large Language Model	—	большая языковая модель
LLVM	—	Проект программной инфраструктуры для создания компиляторов и сопутствующих им утилит		
SAST	—	Static Application Security Testing	—	метод статического тестирования безопасности
SCA	—	Software Composition Analysis	—	анализ состава программного обеспечения
UB	—	Undefined Behavior	—	неопределенное поведение
ООП	—	Объектно-ориентированное программирование		

ВВЕДЕНИЕ

Одной из основных проблем, связанных с программным кодом, является его безопасность [1]. Один из подходов работы с безопасностью кода — это обработка свойств безопасности кода. Мы можем собрать свойства безопасности кода некоторой программы, отследить как они изменяются во время выполнения этой программы и выделить множество свойств, которые сохраняются — это будет отпечаток безопасности этой программы. Но мы можем не только отслеживать свойство безопасности кода во время выполнения некоторой программы, мы можем отслеживать эволюцию свойств безопасности во время трансформации исходного кода и предсказывать, как они изменятся (и соответственно, как изменится безопасность трансформированного кода). Одной из таких важных и сложных трансформаций является преобразование (трансляция) исходного кода на другой язык программирования.

При разработке программного обеспечения достаточно часто возникает задача о переносе программного кода между языками (который мы называем трансляцией кода, см. раздел 1.10). При этом, если о соответствии функциональным требованиям у перенесенного (полученного в результате трансляции) кода помнят почти всегда (обычно проблемы возникают с соответствием поведения, связанного с тонкостями того или иного языка/платформы), то вот о безопасности кода при трансляции обычно часто даже и не думают. Особенно эта проблема актуальна, если трансляция кода — это не однократное явление, а периодический или массовый процесс.

Процесс периодического/массового трансляции кода бывает нужен в следующих случаях:

- 1) Некоторая компания разрабатывает и выпускает свой продукт (библиотеку) на некотором определенном языке под некоторую платформу (например, на C# под платформу .NET). Но при этом есть желание выйти с данным продуктом (библиотекой) на другие языки и платформы: например, на

Java, на Python, на C++ и т.д. Примером такой компании может быть компания Aspose, которая разрабатывает библиотеку компонентов для работы с документами разнообразных форматов (word, excel, pdf и т.д.).

2) Есть некоторая функциональность (библиотека), реализованная на некотором языке под некоторую платформу (например, некоторая open source функциональность), у которой периодически выходят новые версии. Мы разрабатываем некоторое ПО на другом языке и под другую платформу, и мы нуждаемся в версии этой функциональности под язык и платформу, для которой разрабатывается ПО.

3) У нас есть большое количество ПО, созданного на одном языке и под одну платформу, а нам (например, по причине импортозамещения) необходимо перевести весь этот объем существующего ПО под другой язык и другую платформу.

Сделать трансляцию кода можно двумя способами:

- Вручную, но для этого нужно достаточно много разработчиков, которые бы хорошо знали как исходные язык программирования, так и язык программирования, на который будет транслироваться исходный код; при этом это будет не самый быстрый процесс, т.к. при ручной трансляции кода, транслируемый код фактически создается заново, особенно с учетом разницы между языками (см. раздел 4.3).
- С помощью средств автоматизации: это либо специально созданные утилиты, либо LLM-агенты. Но и в этом случае все достаточно не просто. Специально созданные утилиты обычно нужно конфигурировать под каждую транслируемую программу; к тому же далеко не весь код может быть вообще транслирован в автоматическом режиме (как, например, транслировать определение шаблонов с языка C++ на любой другой язык, где подобной концепции вообще нет) с одного языка на другой (см. раздел 4.4). А LLM-агенты периодически

могут генерировать некорректный или непредсказуемый результат (особенно это проявляется на большом объеме кода).

Очевидно, мы хотим, чтобы трансляция кода с одного языка на другой осуществлялась автоматически, т.к. несмотря на все проблемы, которые возникают при автоматической трансляции кода (см. раздел 4.4), обычно все-таки это более быстрый процесс, чем трансляция кода вручную.

И вот здесь, на стыке требований к безопасности кода и нашим желанием уметь автоматически осуществлять трансляцию кода с одного языка на другой возникают следующие вопросы. Если исходный код обладает всеми необходимыми для нас свойствами безопасности, то что можно сказать в этом случае о коде после трансляции? Будет ли он обладать всеми теми же свойствами безопасности, что и исходный код, или же какими-то из свойств придется “пожертвовать”? Будет ли осуществляться сохранение свойств безопасности автоматически или же для сохранения некоторых из них придется делать дополнительные действия?

1 Постановка задачи и рамки исследования

1.1 Актуальность. Почему проблема важна

Как уже было сказано выше, периодически возникают задачи о трансляции кода с одного языка на другой, как вручную, так и с помощью средств автоматизации. При этом важную роль играет не только безопасность полученного кода, а также то, как она связана с безопасностью исходного кода.

1.2 Объект исследования

Объектом исследования в данной работе является процесс автоматической трансляции программного кода между различными языками программирования. Под данным процессом понимается преобразование кода, написанного на одном (исходном) языке программирования, в эквивалентный код на другом (целевом) языке программирования с сохранением их функционального поведения. Такая трансляция может осуществляться как между языками высокого уровня, например, между C# и Python, так и в направлении понижения уровня абстракции, например, при генерации низкоуровневого кода с использованием инфраструктур вроде LLVM (но в данной работе рассматривается трансляция только между языками высокого уровня).

Особое внимание в рамках исследования уделяется вопросам корректности и надежности трансляции, поскольку даже при формальном сохранении синтаксической структуры программы могут возникать изменения в ее семантике, влияющие на поведение при выполнении. Это связано с различиями в моделях памяти, системах типов, механизмах управления ресурсами и особенностях выполнения программ в разных языках. В связи с этим процесс трансляции рассматривается не только как техническая задача преобразования кода, но и как сложная формальная проблема,

требующая учёта семантической эквивалентности, а также обеспечения свойств безопасности и устойчивости программ в целевой среде выполнения.

1.3 Предмет исследования

Предметом исследования являются методы выявления, классификации и сохранения свойств безопасности при автоматической трансляции программного кода между языками программирования. В рамках данной работы под свойствами безопасности понимаются характеристики кода, которые мы можем получить исходя из анализа этого кода на основе списка Common Weakness Enumeration (CWE) [2], а также на основе спецификации языка. Примером таких свойств безопасности могут служить следующие: “проверка входных аргументов в функции/методе”, “типобезопасность”, “сохранение инкапсуляции” и другие. Существенное внимание уделяется разработке подходов, позволяющих формально выявлять эти свойства на уровне исходного кода, а также определять, какие из них должны быть сохранены в процессе трансляции и что для этого необходимо сделать.

1.4 Задача исследования

Задачей исследования является следующее:

- формализация понятия семантики безопасности программного кода при автоматической трансляции исходного кода одного языка программирования в исходный код другого языка программирования;
- разработка модели отпечатка безопасности (Security Fingerprint) как совокупности относящихся к безопасности инвариантов программного кода, определяемых кодом, языком, средой выполнения и контекстом использования;
- разработка классификации изменений защитных инвариантов при трансляции, включая автоматически сохраняемые свойства, свойства,

требующие компенсирующих механизмов, свойства, допускающие ослабление, и свойства, возникающие в целевом языке;

- разработка методики автоматической трансляции программного кода, обеспечивающую контролируемое сохранение отпечатка безопасности и фиксацию допустимых ослаблений семантики безопасности;
- разработка механизма предварительной симплификации исходного кода как способ уменьшения сложности транслятора и снижения риска искажения инвариантов безопасности кода при трансляции;
- реализация прототипа методики для пары языков C# - Python, включая симплификатор, транслятор и элементы компенсации свойств безопасности, не поддерживаемых штатными средствами целевого языка;
- проведение экспериментальной проверки методики на примере трансляции с языка C# на язык Python, включая сравнение с ручной трансляцией и трансляцией с помощью большой языковой модели (LLM) по критериям сохранения защитных свойств, функциональной эквивалентности и допустимого ослабления отпечатка безопасности;
- проведение анализа ограничения применимости методики, включая зависимость от пары языков, типа программного кода, качества исходного кода, внешних зависимостей и возможностей целевого языка.

1.5 Цель

Разработка и экспериментальная проверка методики автоматической трансляции кода между языками программирования, обеспечивающей контролируемое сохранение семантики безопасности и тем самым повышающей управляемость и предсказуемость изменений защитных свойств при трансляции.

1.6 Гипотеза

При фиксированной паре языков (в нашем случае, это C# - Python) и при использовании анализа отпечатка безопасности, классификации L1–L4 (с применением компенсирующих мер для свойств L2) и симплификации риск потери значимых свойств безопасности (инвариантов безопасности) снижается по сравнению с трансляцией без такой методики.

1.7 Новизна

В данной работе предложена модель контролируемого сохранения семантики безопасности при трансляции программного кода между языками, включающая отпечаток безопасности, классификацию защитных инвариантов L1–L4, критерий допустимого ослабления, компенсирующие механизмы для L2 и использование предварительного упрощения исходного кода для снижения риска искажения инвариантов безопасности. Также был предложен и использован при приведении эксперимента подход с симплификацией исходного кода для упрощения кода транслятора.

1.8 Теоретическая и практическая значимость

В данной работе предлагается подход (методика) для централизованного управления безопасностью кода в тех случаях, когда один и тот же продукт (например, библиотека) выпускается на разных языках программирования. Для этого при трансляции мы обеспечиваем сохранение семантики безопасности: строим отпечаток безопасности исходного кода и отслеживаем его эволюцию во время трансляции. Также, для упрощения создания транслятора, мы используем подход с симплификацией исходного кода: мы изменяем код так, чтобы AST исходного кода по максимуму походила на AST кода, полученного в результате – при таком подходе процесс трансляции кода сильно упрощается. Такая централизация управления безопасностью кода уменьшает шансы того, что версии одного и того же продукта на разных

языках будут иметь разную семантику безопасности (разные потенциальные уязвимости).

Теоретическая значимость работы заключается в формализации понятия семантики безопасности при автоматической трансляции программного кода и разработке модели “отпечатка безопасности” как набора инвариантов, подлежащих сохранению при трансляции между языками.

В рамках работы вводятся критерии сохранения защитных свойств, классификация инвариантов по уровням сохранности, а также рассматривается понятие допустимого ослабления семантики безопасности в случаях, когда особенности целевого языка не позволяют полностью воспроизвести гарантии исходного языка.

Полученные результаты расширяют представления о трансформации программ с сохранением нефункциональных требований и могут быть использованы при разработке формальных подходов к оценке безопасности при миграции программных систем. Практическая значимость работы заключается в разработке и реализации прототипа инструмента автоматической трансляции программного кода (из языка C# в язык Python), демонстрирующего возможность сохранения защитных свойств при трансляции между языками.

Предложенная методика позволяет: снизить вероятность появления новых уязвимостей при миграции кода; обеспечить контролируемость процесса трансляции за счет фиксации и сравнения «отпечатков безопасности»; уменьшить трудоемкость поддержки мультиплатформенных решений; централизовать управление безопасностью исходного кода.

Результаты работы могут быть применены в организациях, осуществляющих миграцию программных систем, разработку библиотек для нескольких языков программирования или переход на новые технологические платформы.

1.9 Положения на защиту

Во время трансляции кода между какой-либо парой языков, мы можем сформировать отпечаток безопасности для исходного кода, провести классификацию свойств безопасности из сформированного отпечатка безопасности, применить компенсирующие меры для свойств безопасности класса L2 — это снизит потерю значимых свойств безопасности и позволит предсказать отпечаток безопасности кода после трансляции.

Симплификатор — это программа, которые эти преобразования кода на исходном языке реализует. В результате ее работы получается код также на исходном языке, но более простой для процедуры трансляции. В результате применения симплификатора уменьшается количество случаев, которые нужно обрабатывать в трансляторе, т.е. уменьшается цикломатическая сложность кода транслятора. Как итог, уменьшается вероятность ошибки/дефекта в трансляторе.

Связка симплификации исходного кода и автоматической/полуавтоматической трансляции позволяет (во многих случаях) достаточно быстро транслировать код между двумя языками с предсказуемыми свойствами безопасности кода, полученного в результате трансляции.

1.10 Что такое трансляция кода

Трансляция кода — это перевод кода с исходного языка на некоторый другой (например, с C# на Python) один к одному (ну или почти один к одному) - с сохранением структуры исходного кода. При этом должны быть сохранены все функциональные требования и максимально возможное количество нефункциональных требований (см. раздел 1.11). Может осуществляться как вручную, так и с использованием средств автоматизации. Полностью сохранить структуру исходного кода не всегда возможно — это зависит как от сущностей, которые использовались в исходном коде, так и от возможностей

языка, на который происходит трансляция кода. Например, если мы будем транслировать код с ООП языка на язык, в котором нет поддержки ООП, то очевидно, что структура после трансляции несколько изменится; однако, в коде, полученном в результате трансляции, все-равно так или иначе будет видна структура исходного кода. Если же перевод кода осуществляется таким образом, что его структура не сохраняется, то это уже не трансляция — это создание нового кода (новой кодовой базы) на основе существующего кода.

Автоматическая трансляция кода — это трансляция кода с использованием средств автоматизации: либо утилиты для автоматической трансляции кода, либо с помощью LLM (более подробно см. раздел 4.2 и раздел 6.4).

1.11 Трансляция кода с точки зрения функциональных и нефункциональных требований

С точки зрения функциональных требований все просто: трансляция кода должна возвращать такой код, который с точки зрения функциональных требований полностью эквивалентен исходному коду. Так как в противном случае код, полученный в результате трансляции, ведет себя иначе и/или результат его выполнения отличается от результата выполнения исходного кода - очевидно, что такой код, полученный в результате трансляции, никому не будет нужен.

Точно также, поведение транслируемого кода должно быть эквивалентно поведению исходного кода. Однако с этим есть ряд тонкостей/сложностей: в разных языках поведение похожих конструкций может быть разным. Это означает, что мы должны проверять на эквивалентность исходный код и код, полученный в результате трансляции, не только с точки зрения функциональных требований, но и с точки зрения спецификаций языков (на котором написан исходный код и на который он транслируется). Это же касается и случаев, когда мы хотим создать аналог

некоторой конструкции, которая есть в исходном языке, но нет в языке, на который происходит трансляция.

Рассмотрим несколько примеров, демонстрирующих, что учет поведения при трансляции должен выполняться максимально аккуратно.

Пример 1:

Пусть у нас есть следующее определение функции на C# (здесь приведен фрагмент кода):

```
void fun1(T1 arg1, T2 arg2, T3 arg3, T4 arg4) {...}
```

Порядок вычисления аргументов *arg1*, *arg2*, *arg3* и *arg4* перед вызовом функции *fun1* четко определен спецификацией языка C#: они вычисляются слева направо.

Предположим, что мы эту функцию транслировали на язык C++. В нем порядок вычисления аргументов *arg1*, *arg2*, *arg3* и *arg4* перед вызовом функции *fun1* не определен - каждый компилятор может вычислять их в своем порядке. Это является потенциальной проблемой, если вычисление значений одних аргументов прямо или косвенно могут влиять на вычисление значений других аргументов. В этом случае (если не предпринять специальных шагов) мы можем получить разное поведение в исходном коде на языке C# и в коде, полученном в результате трансляции на язык C++.

Пример 2:

В C-подобных языках есть тернарный оператор, который выглядит следующим образом (здесь приведен фрагмент кода):

```
cond ? expr1 : expr2
```

В языке Golang аналога тернарному оператору нет. Однако, некоторые разработчики реализуют его аналог следующим образом (здесь приведен фрагмент кода):

```
func TernOp[T any](cond bool, expr1 T, expr2 T) T {
```

```
if cond { return expr1 }  
return expr2  
}
```

После чего его использование выглядит так (здесь приведен фрагмент кода):

```
value := TernOp(a == 1, 13, 666)
```

На первый взгляд может показаться, что поведение аналога совпадает с поведением тернарного оператора, однако это не так. Например, значение следующего выражения с тернарным оператором (здесь приведен фрагмент кода):

```
int x = 0;  
int value = x != 0 ? 13 / x : 1;
```

когда значение переменной *x* равно 0 будет определено (вычислено).

А при вычислении значения аналогичного выражения в языке Golang (здесь приведен фрагмент кода):

```
x := 0  
value := TernOp(x != 0, 13 / x, 1)
```

когда значение переменной *x* равно 0 мы получим панику из-за деления на 0.

Основное различие между тернарным оператором и его попыткой реализацией на языке Golang в том, что при вычислении значения тернарного оператора выражения *expr1* и *expr2* вычисляются лениво, в зависимости от значения выражения *cond*; тогда как в приведенной реализации на языке Golang, выражения *expr1* и *expr2* вычисляются всегда, вне зависимости от значения выражения *cond*.

С нефункциональными требованиями все сильно сложнее - давайте рассмотрим некоторые из них:

1) Одно из самых важных нефункциональных требований — это безопасность. К ней относятся как требования по защите данных, шифрованию, контролю доступа и требования, так и требования к безопасности кода. Требования по защите данных, шифрованию, контролю доступа реализуются с помощью библиотечного кода (с помощью АПИ платформы); поэтому можно считать, что с этим обычно проблем не бывает.

А вот безопасностью исходного кода обычно не занимаются: многие разработчики считают, что если трансляция кода происходит один к одному (ну или почти один к одному), то безопасность кода, полученного в результате трансляции, не ухудшается. Основана эта уверенность на том, что наиболее очевидные механизмы безопасности кода являются составляющими частями самого кода: проверки входных аргументов и пользовательского ввода, очистка неиспользуемых ресурсов и т.д. Но многие механизмы не такие очевидные и связаны больше с возможностями языков программирования и платформ (сред выполнения); и вот они часто при трансляции кода не сохраняются, если не предпринимать для этого специальных действий. Так, например, в языке Python отсутствуют модификаторы доступа и, как следствие, инкапсуляция; таким образом, при трансляции кода с языка C# на Python теряются такие свойства безопасности, как инкапсуляция и контроль доступа к членам (см. раздел 3.5).

2) Другое, не менее важное нефункциональное требование — это производительность. И вот с производительностью при трансляции кода все достаточно неоднозначно: в одних случаях результат трансляции кода будет удовлетворять требованиям по производительности, в других нет и потребуются ручная кастомизация кода (см. раздел 4.7), а в некоторых случаях результат трансляции кода вообще не сможет удовлетворить требованиям по производительности к исходному коду из-за ограничений языка/платформы. В данной работе мы подробно останавливаться на этом не будем.

3) Реализация требований к масштабируемости, надежности и доступности — это отдельная большая тема, которая не рассматривается в данной работе; часто они реализуются с помощью распределенной (микросервисной) архитектуры, а также с помощью оркестраторов контейнеров, таких как Kubernetes (K8s). Поэтому подробно останавливаться на этом мы не будем.

1.12 Ограничения в рамках работы

В рамках данной работы мы часто будем обсуждать разнообразные языки и проблемы, которые возникают при трансляции между произвольными парами таких языков. Однако, это будут больше теория, т.к. главная пара языков, на которой сконцентрировано внимание в данной работе — это C# и Python. В рамках данной работы мы главным образом будем изучать трансляцию кода, написанного на языке C#, в код на языке Python, и сохранение свойств безопасности при такой трансляции.

Следует также сказать, что данная работа не доказывает универсальность для всех пар языков: в ней демонстрируется работоспособность методики для трансляции исходного кода с языка C# на язык Python. Можно сказать, что универсальность здесь не в том, что один транслятор работает для всех языков, а в том, что общий каркас методики может быть использован для трансляции между разными парами языков: отпечаток безопасности, классификация L1–L4, сравнение до/после, фиксация ослаблений, компенсирующие меры. Для каждой новой пары языков нужен свой профиль трансляции: какие инварианты сохраняются автоматически, какие требуют компенсации, какие теряются, какие появляются; а также свой транслятор.

2 Обзор подходов к безопасной компиляции и валидации трансляции

Давайте сделаем краткий обзор подходов, которые используются для обеспечения безопасности при компиляции (трансляции).

2.1 Secure compilation (безопасная компиляция)

Подход *secure compilation* (безопасной компиляции) представляет собой направление исследований в области теории компиляторов, компьютерной безопасности и формальных методов, направленное на обеспечение сохранения свойств безопасности программы при ее трансляции из исходного языка в целевой язык (машинный код, байт-код или некоторый низкоуровневый язык, такой как IR) [3], [4]. В отличие от традиционных компиляторов, таких как GCC, LLVM и другие, которые ориентированы преимущественно на сохранение семантики и оптимизацию производительности, безопасная компиляция требует более сильных гарантий, связанных с поведением программы в условиях потенциально враждебного окружения.

Классическое понятие корректности компиляции предполагает, что поведение скомпилированной программы эквивалентно поведению исходной программы. Однако в контексте безопасности этого недостаточно, поскольку после компиляции программа может взаимодействовать с низкоуровневой средой исполнения, в которой отсутствуют гарантии, предоставляемые высокоуровневым языком, такие как контроль доступа, типовая безопасность или автоматическое управление памятью. В результате возможны атаки, использующие особенности целевого уровня, например, нарушения границ памяти или вмешательство в поток управления.

В рамках *secure compilation* формулируются более строгие критерии корректности. Одним из фундаментальных является критерий полной абстракции (*fully abstract compilation*), согласно которому две программы,

неразличимые в исходном языке, должны оставаться неразличимыми после компиляции. Это означает, что компилятор не должен вводить дополнительные наблюдаемые различия, которые могли бы быть использованы атакующим для получения информации о внутреннем устройстве программы. Данный критерий обеспечивает сохранение поведенческой эквивалентности программ в присутствии произвольного контекста.

Более практическим подходом является сохранение свойств безопасности при взаимодействии с произвольным окружением (robust property preservation). В этом случае требуется, чтобы свойства, доказанные для программы на уровне исходного языка, сохранялись даже при выполнении в присутствии вредоносного или неконтролируемого кода. К таким свойствам относятся конфиденциальность, целостность данных и безопасность управления потоком выполнения. Данный подход учитывает реалистичные сценарии эксплуатации программ, в которых они редко выполняются в полностью доверенной среде.

Реализация безопасной компиляции может осуществляться различными способами. Один из подходов связан с использованием аппаратной поддержки безопасности: архитектура CHERI [5], реализующей модель capability-based доступа, технология защищенных анклавов, таких как Intel SGX [6] и т.д. Эти решения позволяют изолировать память и ограничивать доступ к ресурсам на уровне аппаратного обеспечения, тем самым усиливая гарантии безопасности скомпилированного кода.

Другой подход основан на программных методах изоляции, включая Software Fault Isolation и “выполнение в песочнице” (sandbox). В качестве примера безопасной целевой платформы часто рассматривается WebAssembly, обеспечивающий строгую модель исполнения с контролем памяти и ограничением взаимодействия между модулями. Такие механизмы позволяют

ограничить последствия возможных ошибок или атак внутри отдельных компонентов системы.

Существенную роль играют также методы, основанные на формальной верификации и криптографии. В частности, подход proof-carrying code (PCC) [7] предполагает, что программа сопровождается формальным доказательством своей корректности и безопасности, которое проверяется перед выполнением. Это позволяет перенести часть ответственности за безопасность на этап компиляции и статического анализа.

Отдельным направлением является типобезопасная компиляция, в рамках которой компилятор гарантирует сохранение типовых свойств исходной программы на уровне целевого кода. Это особенно важно для языков с развитой системой типов, таких как C#, Java, Rust, где многие гарантии безопасности основаны именно на типовой системе.

Формальное обоснование корректности и безопасности компиляции требует использования строгих математических методов. Среди них выделяются логические отношения, операционная и денотационная семантика, а также различные виды симуляций и бисимуляций. Эти методы позволяют доказать, что поведение программы сохраняется при трансляции, а также что никакие дополнительные возможности для атакующего не возникают на уровне целевого кода.

На практике идеи secure compilation реализуются в ряде систем, таких как CompCert - формально верифицированный компилятор языка C [8], seL4 - микроядро операционной системы с доказанной корректностью [9], а также WebAssembly как безопасная платформа выполнения [10].

Несмотря на достигнутые результаты, secure compilation остаётся сложной и активно развивающейся областью. Основные проблемы включают высокую сложность формальной верификации компиляторов, дополнительные накладные расходы на обеспечение безопасности, а также трудности интеграции с существующими промышленными системами. Кроме

того, остаётся открытым вопрос о полноте моделей угроз, особенно в контексте атак по побочным каналам.

Как результат, безопасная компиляция представляет собой важный шаг в направлении построения надежных программных систем, обеспечивая не только функциональную корректность, но и устойчивость программ к широкому спектру атак при их выполнении в небезопасной среде.

2.2 Translation validation (валидация трансляции)

Подход translation validation (валидация трансляции) представляет собой метод обеспечения корректности компиляции, при котором проверка соответствия исходной и скомпилированной программ выполняется не на уровне самого компилятора, а отдельно для каждого результата трансляции [11]. Данное направление развивается в рамках теории компиляторов и формальных методов и рассматривается как альтернатива полной формальной верификации компилятора.

В отличие от традиционного подхода, реализованного, например, в системах наподобие CompCert [8], где корректность компилятора доказывается один раз и распространяется на все компилируемые программы, валидация трансляции предполагает, что результат каждой конкретной компиляции сопровождается отдельной проверкой. Таким образом, вместо доказательства корректности самого компилятора осуществляется проверка того, что для данной пары «исходная код — целевая программа» сохраняется требуемое отношение эквивалентности.

Основная идея подхода заключается в следующем: после выполнения компиляции специальный валидатор анализирует исходную код и скомпилированную программы и проверяет, что они эквивалентны с точки зрения наблюдаемого поведения. При этом компилятор может рассматриваться как недоверенный компонент, а корректность обеспечивается за счет независимой процедуры проверки. Такой подход позволяет

использовать сложные оптимизирующие компиляторы без необходимости их полной формальной верификации.

Формально задача валидации трансляции сводится к проверке семантического соответствия двух программ (исходного кода и скомпилированной программы), заданных на разных уровнях абстракции. В зависимости от модели вычислений и языка программирования могут использоваться различные критерии эквивалентности, включая эквивалентность трасс выполнения, сохранение вход-выходного поведения или более строгие формы наблюдаемой эквивалентности. Важным аспектом является учёт оптимизаций, выполняемых компилятором, которые могут существенно изменять структуру программы, сохраняя при этом ее поведение.

Для реализации валидации трансляции применяются методы формальной верификации, такие как символьное исполнение, проверка достижимости состояний, а также построение и сопоставление промежуточных представлений программ. Широко используются техники, основанные на SMT-решателях и автоматическом доказательстве теорем, что позволяет эффективно проверять эквивалентность даже в присутствии нетривиальных преобразований кода.

Одним из ключевых преимуществ подхода является его практическая применимость. В отличие от полной верификации компилятора, которая требует значительных усилий и сложной формализации, валидация трансляции может быть интегрирована в существующие цепочки компиляции с относительно небольшими затратами. Это делает её особенно привлекательной для использования в промышленных системах, где применяются сложные и постоянно развивающиеся компиляторы, например, такие как LLVM.

В то же время данный подход имеет ряд ограничений. Во-первых, проверка выполняется для каждого отдельного результата компиляции, что может приводить к дополнительным накладным расходам по времени. Во-

вторых, сложность задачи эквивалентности программ (исходного кода и скомпилированной программы) может существенно возрасти при наличии агрессивных оптимизаций, побочных эффектов и взаимодействия с внешней средой. В-третьих, в некоторых случаях требуется ослабление критериев эквивалентности, что может снижать строгость гарантируемых свойств.

Как результат, валидация трансляции представляет собой компромисс между полной формальной верификацией компилятора и отсутствием формальных гарантий корректности. Она позволяет повысить доверие к результатам компиляции, обеспечивая проверку сохранения поведения программы на уровне отдельных трансляций, и является важным инструментом в разработке надежных и безопасных программных систем.

2.3 Verified compilation (верифицируемая компиляция)

Подход *verified compilation* (верифицируемая компиляция) представляет собой направление в области теории компиляторов и формальных методов, ориентированное на построение компиляторов, корректность которых доказана формально с использованием математических методов. В рамках данного подхода компилятор рассматривается как объект строгой спецификации, а его поведение доказывается соответствующим этой спецификации, что позволяет гарантировать сохранение семантики программ при трансляции.

В отличие от методов, основанных на тестировании или эмпирической проверке, верифицируемая компиляция предполагает построение формального доказательства того, что для любой допустимой исходной программы (исходного кода) результат компиляции эквивалентен ей с точки зрения наблюдаемого поведения. Это означает, что выполнение скомпилированной программы приводит к тем же результатам, что и выполнение исходной программы (как если бы она выполнялась с помощью

интерпретатора), с учетом допустимых различий, например, связанных с неопределенным поведением в языках низкого уровня.

Формально корректность компилятора обычно выражается в терминах симуляции между семантиками исходного и целевого языков. Наиболее распространенным является доказательство прямой (forward) симуляции, гарантирующей, что каждый шаг выполнения исходной программы может быть воспроизведен соответствующей последовательностью шагов целевой программы. В ряде случаев используется также обратная (backward) симуляция или бисимуляция, позволяющая устанавливать более сильные свойства соответствия.

Практическая реализация данного подхода требует формализации как исходного языка программирования, так и целевого языка (машинный код, байт-код или некоторый низкоуровневый язык, такой как IR), а также всех этапов компиляции, включая промежуточные представления. Для этого широко применяются системы автоматического доказательства теорем и интерактивные доказательные ассистенты, такие как Coq и Isabelle. В этих системах формализуются синтаксис, семантика и трансформации программ, после чего строится машинно-проверяемое доказательство корректности.

Одним из наиболее известных примеров является CompCert - компилятор языка C [8], корректность которого формально доказана в системе Coq. В данном проекте показано, что результат компиляции сохраняет поведение программы при выполнении на целевой архитектуре, что существенно повышает уровень доверия к программному обеспечению, созданному с его использованием.

Верифицируемая компиляция обеспечивает сильные гарантии корректности и надежности, что особенно важно для критически важных систем, включая авиацию, медицину и встроенные системы. В отличие от подхода translation validation (валидация трансляции), где корректность проверяется для каждой отдельной трансляции, здесь доказательство

относится ко всему компилятору и распространяется на все программы, которые он обрабатывает (компилирует).

В то же время данный подход характеризуется высокой сложностью реализации. Формализация компилятора требует значительных усилий, а доказательства могут достигать большого объёма и сложности. Это затрудняет поддержку и развитие таких систем, особенно в условиях необходимости внедрения новых оптимизаций и поддержки современных языковых конструкций. Кроме того, верификация обычно проводится для упрощенных моделей языков и архитектур, что ограничивает применимость результатов в полномасштабных промышленных компиляторах, например, таких как LLVM.

Как результат, верифицируемая компиляция представляет собой наиболее строгий подход к обеспечению корректности трансляции программ, обеспечивая формально доказанные гарантии сохранения их поведения. Несмотря на высокую стоимость разработки, данный подход играет важную роль в создании высоконадежных программных систем и служит основой для дальнейших исследований в области безопасной и доверенной компиляции.

2.4 Сравнение с используемым подходом

Давайте сравним рассмотренные выше подходы, которые используются для обеспечения безопасности при компиляции (трансляции) с тем, что предлагается использовать в данной работе, а также с подходами, которые мы будем использовать при проведении эксперимента (см. глава 6)

1) Ручная трансляция кода разработчиком.

Основная цель подхода: получить рабочую реализацию на целевом языке с учётом опыта разработчика.

Что обычно контролируется: функциональная корректность, читаемость, идиоматичность кода целевого языка.

Как учитывается безопасность: зависит от квалификации разработчика и его внимания к защитным свойствам.

Что остаётся вне явного контроля: потеря неявных защитных инвариантов, изменение интерфейса, ослабление типобезопасности, потеря перегрузок, изменение контрактов API.

Сильная сторона подхода: гибкость, возможность учитывать сложную бизнес-логику и вручную адаптировать архитектуру и подход к реализации.

Ограничение в контексте данной работы: результат трудно формализовать; разные разработчики могут получить разные варианты; инварианты безопасности обычно не фиксируются до трансляции.

Позиция относительно предлагаемой методики: используется как базовый сравнительный сценарий. Методика добавляет формальный контроль - отпечаток безопасности до/после, классификация L1–L4, фиксацию потерь и компенсаций

2) Прямая автоматическая трансляция без контроля семантики безопасности.

Основная цель подхода: автоматически получить код на целевом языке.

Что обычно контролируется: синтаксическая трансляция, часть конструкций языка, иногда сборка и запуск.

Как учитывается безопасность: обычно безопасность учитывается косвенно или проверяется постфактум.

Что остаётся вне явного контроля: может сохраняться функциональность, но теряться защитные гарантии исходного языка - строгая типизация, инкапсуляция, readonly-семантика, порядок вычисления.

Сильная сторона подхода: высокая скорость трансляции, воспроизводимость, возможность обработки большого объёма кода.

Ограничение в контексте данной работы: не гарантирует сохранение инвариантов безопасности; ошибки могут быть незаметны при прохождении модульных и функциональных тестов.

Позиция относительно предлагаемой методики: предлагаемая методика может использоваться как надстройка/контрольный слой над таким транслятором, задавая ожидаемый отпечаток безопасности и проверяя фактический результат.

3) Трансляция кода с помощью LLM.

Основная цель подхода: быстро получить целевой код с помощью большой языковой модели.

Что обычно контролируется: функциональный смысл задачи, синтаксис целевого языка, частично стиль и структура.

Как учитывается безопасность: может учитывать безопасность, если явно указать в промпте, но не гарантирует стабильного результата.

Что остаётся вне явного контроля: нестабильность результата, изменение интерфейса, неполная компенсация инвариантов безопасности L2, некорректная классификация свойств, галлюцинации, зависимость от промпта.

Сильная сторона подхода: быстрота, гибкость, способность адаптировать код к стилю целевого языка.

Ограничение в контексте данной работы: нет детерминированности; трудно строить повторяемые тесты самой процедуры; требуется внешний контроль результата.

Позиция относительно предлагаемой методики: в работе LLM рассматривается не как замена методике, а как альтернативный способ генерации целевого кода, результат которого проверяется через отпечаток безопасности.

4) Использование SAST после трансляции.

Основная цель подхода: найти потенциальные дефекты и известные классы уязвимостей в уже полученном коде.

Что обычно контролируется: шаблоны уязвимостей, небезопасные конструкции, нарушения правил безопасного кодирования.

Как учитывается безопасность: безопасность анализируется по фактическому целевому коду.

Что остаётся вне явного контроля: SAST может не увидеть потерю защитного инварианта, если она не проявилась как конкретная уязвимость; не фиксирует, какие гарантии были в исходном коде.

Сильная сторона подхода: хорошо выявляет известные дефекты и небезопасные шаблоны.

Ограничение в контексте данной работы: не отвечает на вопрос, какие свойства безопасности были потеряны именно из-за трансляции.

Позиция относительно предлагаемой методики: методика не заменяет SAST, а дополняет его; SAST может быть одним из инструментов подтверждения фактического отпечатка безопасности.

5) Анализ состава программного обеспечения (SCA).

Основная цель подхода: найти уязвимости во внешних зависимостях.

Что обычно контролируется: библиотеки, версии, известные CVE/BDU-уязвимости.

Как учитывается безопасность: безопасность оценивается через состояние зависимостей.

Что остаётся вне явного контроля: не анализирует семантику трансляции и сохранение свойств кода.

Сильная сторона подхода: важен для контроля зависимости от сторонних библиотек после трансляции.

Ограничение в контексте данной работы: не определяет классификацию L1–L4 и не показывает, какие инварианты потеряны при трансляции.

Позиция относительно предлагаемой методики: используется как внешний контроль деградации отпечатка безопасности во времени, но не подменяет классификацию L1–L4.

6) Безопасная компиляция (secure compilation).

Основная цель подхода: сохранить свойства безопасности при компиляции в менее абстрактную или потенциально небезопасную среду.

Что обычно контролируется: формальные свойства безопасности при переходе от исходного языка к целевому уровню исполнения.

Как учитывается безопасность: безопасность рассматривается строго, часто через надежное сохранение свойств безопасности (robust property preservation), полную абстракцию и формальные модели.

Что остаётся вне явного контроля: обычно не ориентирована на практическую трансляцию исходного кода между высокоуровневыми языками, например из языка C# в язык Python.

Сильная сторона подхода: сильная формальная база, глубокая научная проработка сохранения свойств безопасности.

Ограничение в контексте данной работы: слишком тяжёлый аппарат для прикладной миграции кода и прототипа ВКР.

Позиция относительно предлагаемой методики: близко по идее сохранения свойств безопасности, но отличается задачей - в данной работе рассматривается контролируемая трансляция кода между высокоуровневыми языками.

7) Валидация трансляции (translation validation).

Основная цель подхода: проверить корректность конкретного результата трансляции.

Что обычно контролируется: эквивалентность поведения исходной и целевой программы.

Как учитывается безопасность: может быть расширена на свойства безопасности, но чаще ориентирована на поведенческую эквивалентность.

Что остаётся вне явного контроля: не формирует заранее набор инвариантов безопасности и не классифицирует их по L1–L4.

Сильная сторона подхода: проверяет конкретный результат, а не требует полной верификации транслятора.

Ограничение в контексте данной работы: требует формальных моделей и может быть сложна для реальных языков и библиотек.

Позиция относительно предлагаемой методики: методика ВКР ближе к прикладной логике валидации, но проверяет не только поведение, а изменение отпечатка безопасности.

8) Верифицируемая компиляция (verified compilation).

Основная цель подхода: формально доказать корректность компилятора.

Что обычно контролируется: сохранение поведения для всех допустимых программ.

Как учитывается безопасность: может давать сильные гарантии безопасности при наличии формальной модели.

Что остаётся вне явного контроля: не предназначена для быстрой прикладной миграции кода между разными высокоуровневыми языками.

Сильная сторона подхода: максимально строгие гарантии.

Ограничение в контексте данной работы: очень высокая сложность, необходимость полной формализации языков и транслятора.

Позиция относительно предлагаемой методики: не является прямым конкурентом; задаёт высокий научный ориентир, но в данной работе выбран более прикладной и реализуемый подход.

9) Предлагаемая методика контроля семантики безопасности при трансляции.

Основная цель подхода: управляемо транслировать код между языками с контролем изменения защитных свойств.

Что обычно контролируется: отпечаток безопасности до/после, классификацию свойств безопасности L1–L4, компенсации для свойств безопасности L2, ослабления свойств безопасности L3, принадлежащих к, функциональный результат, интерфейс.

Как учитывается безопасность: безопасность рассматривается как набор защитных инвариантов, которые можно сохранить, компенсировать, зафиксировать как потерянные или обнаружить как новые.

Что остаётся вне явного контроля: не гарантирует отсутствие всех уязвимостей; не является универсальным промышленным транслятором для всех языков; не заменяет SAST/SCA/формальную верификацию.

Сильная сторона подхода: даёт предсказуемость - заранее понятно, какие свойства должны сохраниться, какие требуют компенсации, какие будут потеряны.

Ограничение в контексте данной работы: требует построения профиля языковой пары и анализа исходного отпечатка безопасности; в данной работе апробируется на пару языков C# - Python.

Позиция относительно предлагаемой методики: центральный результат работы - не конкурирует “по полноте языка” со всеми трансляторами, а закрывает задачу контроля сохранения семантики безопасности.

Из сравнения видно, что предлагаемая методика не является заменой промышленным трансляторам, статическому анализу, анализу зависимостей или формальной верификации. Её основное отличие состоит в том, что она вводит специальный контрольный слой для оценки изменения семантики безопасности при трансляции кода между языками. В отличие от подходов, ориентированных преимущественно на функциональную эквивалентность или поиск известных уязвимостей после трансляции, методика позволяет заранее сформировать ожидаемый отпечаток безопасности, классифицировать защитные инварианты по характеру их сохранения, применить компенсирующие механизмы и сопоставить ожидаемый результат с фактическим.

3 Модель безопасности

3.1 Свойства безопасности кода

Если взять какой-либо код и проанализировать его, то можно выделить некоторое множество свойств этого кода. Часть из них относятся к функциональным требованиям - например, использование метода наименьших квадратов для обработки данных; часть из них относится к реализации - например, для реализации метода обработчика данных использовался шаблон (паттерн) проектирования “Стратегия” [12]; а есть ряд свойств, которые относятся к безопасности. Давайте рассмотрим некоторые из них более подробно:

- Проверка (и экранирование) входных данных от пользователей (внешних систем) - очень много уязвимостей связано с тем, что входные данные напрямую, без каких-либо проверок и/или экранирования используются для построения результата.
- Проверка входных аргументов в функции/методе (как минимум для публичных/экспортируемых функций/методов) - отсутствие проверок позволяет передавать такие аргументы, которые приводят к ошибкам, либо к непредсказуемому поведению функции/метода.
- Правильная работа с ресурсами (отсутствие утечек ресурсов) - если неаккуратно работать с ресурсами (файлы, сетевые подключения и т.д.), то это может привести к тому, что приложение будет блокировать ресурсы, которые ему уже не нужны; в результате этого либо другие приложения не смогут получить доступ к этим ресурсам, либо в системе начнется их нехватка (из-за ограничений системы).
- Правильная работа с памятью (отсутствие утечек памяти) - если неаккуратно работать с памятью, то можно прийти к ситуации, когда не используемая приложением память остается занятой этим приложением, что в итоге приводит к нехватке памяти. Тут следует

упомянуть, что это проблема не только unmanaged языков, в managed языках точно также может быть утечка памяти.

- Корректная работа с границами выделенной памяти при доступе к этой памяти. Если не соблюдать границы памяти при записи, то легко получить ситуацию повреждения памяти (когда при записи за границами выделенной области памяти происходит порча данных, принадлежащих другим областям памяти), При чтении за границами памяти тоже возможен ряд проблем: от чтения мусора, до ошибок доступа к памяти (при попытке обратиться к области памяти, на которую у программы нет прав).
- Сохранение инкапсуляции в ООП коде; т.е. сохранение корректного доступа к приватным членам.
- Сохранение корректного доступа к унаследованным членам в ООП коде.
- Типобезопасность - свойство (языка программирования), гарантирующее, что операции выполняются только над совместимыми типами данных.
- Гарантия состояния программы к возникновению исключений; есть 4 варианта этого свойства - отсутствие гарантий, базовая гарантия, сильная гарантия и гарантия отсутствия исключений. Отсутствие гарантий означает, что любое исключение переводит состояние программы в неопределенное. Базовая гарантия означает, что все объекты остаются в валидном состоянии (но их содержимое может измениться) и ресурсы не утекают. Сильная гарантия означает, что, если операция прервана исключением, состояние программы остается таким же, каким было до начала вызова. Гарантия отсутствия исключений означает, что данный код никогда не выбрасывает исключений.

Из перечня свойств безопасности видно, что одни свойства безопасности кода определяется самим кодом (например, проверка входных аргументов у функций/методов), а другие - языком и/или платформой (например,

типовбезопасность). Очевидно, что это различие происхождения свойств безопасности нужно учитывать, если мы хотим, чтобы при трансляции кода с одного языка на другой те или иные свойства безопасности сохранялись (см. раздел 3.5).

Следует сказать, что в данной работе под свойствами безопасности мы понимаем именно свойство безопасности (инварианты безопасности) самого кода и среды его выполнения, которые могут влиять на риск появления уязвимостей, ослабления ограничений или нарушения защитных гарантий при трансляции кода с одного языка на другой. Мы не рассматриваем свойства безопасности в широком инфраструктурном смысле (например, свойство минимальности используемых привилегий).

Может возникнуть вопрос, откуда мы берем список свойств безопасности? Ответ на этот вопрос будет следующий: мы берем перечень свойств безопасности не “с потолка”, а генерируем их на основе списка Common Weakness Enumeration (CWE) [2] и спецификации исходного языка. Например, рассмотрим следующую уязвимость из списка CWE - CWE-787: Out-of-bounds Write [13]. Очевидно, что ее причина в том, что мы пишем за границами выделенного буфера. Поэтому свойство безопасности, соответствующее данному CWE-787 будет следующее: “Корректная работа с границами выделенной памяти при доступе к этой памяти”.

3.2 Понятие отпечатка безопасности

Набор всех (или интересующих нас) свойств безопасности для данной кодовой базы называется отпечаток безопасности (Security Fingerprint). Свойство безопасности может иметь одно из следующих значений (очевидно, что приведенный ниже набор значений покрывает все возможные случаи):

- поддерживается полностью;
- поддерживается частично (либо с какими-то ограничениями);
- не поддерживается.

Следует сказать, что у разных сущностей (функций, методов, типов) в кодовой базе могут быть разные значения для одних и тех же свойств безопасности. Например, в функции *Func1* проверяются все входные аргументы, в функции *Func2* проверяются только некоторые входные аргументы, а в функции *Func3* входные аргументы вообще не проверяются. В этом случае значение свойства безопасности “проверка входных аргументов” для функции *Func1* будет “поддерживается полностью”, для функции *Func2* - “поддерживается частично”, а для функции *Func3* - “не поддерживается”.

Из этого следует, что отпечаток безопасности может быть либо детализированным (когда для каждой сущности указываются свои свойства безопасности, либо агрегирующими, когда указываются общие свойства всей кодовой базы. Для агрегирующего отпечатка безопасности все свойства безопасности должны учитывать все возможные значения у всех таких же свойств среди всех сущностей кодовой базы - т.е. слияние (merge) их значений. В следующей таблице (таблица 1) приведены правила слияния двух значений (которые легко могут быть обобщены на случай произвольного количества значений):

Таблица 1 – Правила слияния двух значений

	Значение 2		
Значение 1	поддерживается полностью	поддерживается частично	не поддерживается
поддерживается полностью	поддерживается полностью	поддерживается частично	поддерживается частично
поддерживается частично	поддерживается частично	поддерживается частично	поддерживается частично
не поддерживается	поддерживается частично	поддерживается частично	не поддерживается

Также следует сказать, что родительские сущности не наследуют значения свойств безопасности при формировании отпечатка безопасности.

Пусть, например, класс *Class1* содержит метод *Method1*; пусть у метода *Method1* значение свойства безопасности “проверка входных аргументов” равно “поддерживается частично”. У класса *Class1* в этом случае не будет агрегирующего значения свойства безопасности “проверка входных аргументов” по всем методам (хотя, конечно, при необходимости его можно определить и ввести).

Давайте формализуем понятие отпечатка безопасности (полную формализацию см. раздел 3.10):

Агрегирующий отпечаток безопасности (состоящий из N свойств безопасности) мы можем записать следующим образом:

$$F_a(P_a) = (i_1, i_2, \dots, i_n), \quad (1)$$

где:

i_k - свойство безопасности (инвариант безопасности)

Пусть e_j - некоторая сущность, определенная в исходном коде программы P_A :

$$e_j \in E(P_A), \quad (2)$$

где

$E(P_A)$ - множество всех сущностей, определенных в программе P_A .

Пусть $I(e_j)$ - множество всех свойств безопасности, определенных для сущности e_j :

$$I(e_j) = \{i_1, i_2, \dots, i_m\}, \quad (3)$$

где:

i_k - свойство безопасности (инвариант безопасности)

Тогда детализированный отпечаток безопасности (состоящий из свойств безопасности M сущностей, определенных в исходном коде программы P_A), мы можем записать следующим образом:

$$F_d(P_A) = (I(e_1), I(e_2), \dots, I(e_m)). \quad (4)$$

3.3 Сравнение отпечатков безопасности

Основная цель отпечатка безопасности — это не просто сформировать набор свойств безопасности, а уметь сравнивать два набора. Для чего это нужно: в первую очередь для того, чтобы понимать, как изменился набор свойств безопасности при трансляции кода.

Первым делом давайте определим, как соотносятся между собой значения свойств безопасности (какое из значений считается более безопасным); эти правила приведены в следующей таблице (таблица 2):

Таблица 2 – Правило соотношения значений свойств безопасности

	Значение 2		
Значение 1	поддерживается полностью	поддерживается частично	не поддерживается
поддерживается полностью	одинаково безопасно	значение 1 более безопасно	значение 1 более безопасно
поддерживается частично	значение 2 более безопасно	не определено	значение 1 более безопасно
не поддерживается	значение 2 более безопасно	значение 2 более безопасно	одинаково безопасно

Следует отметить, что когда значения у сравниваемых свойств равны значению “поддерживается частично”, то результат сравнения мы считаем неопределенным. Пусть, например, мы говорим о свойстве безопасности “проверка входных аргументов” для функций **Func1** и **Func2**; у функции **Func1** проверяется только первый аргумент, а у **Func2** - только второй и третий аргументы. Какая из функций более безопасна? Очевидно, что мы не можем сказать это с определенностью; именно поэтому для этого случая результат сравнения значений свойств безопасности не определен.

Также следует сказать, что бессмысленно сравнивать значения двух разных свойств. Например, если мы сравним значения свойств безопасности “проверка входных аргументов” и “сохранение инкапсуляции”, то что даст результат их сравнения? Очевидно, что ничего осмысленного.

А теперь давайте определим, как мы будем сравнивать два набора отпечатков безопасности - один, сформированный для исходного кода, а другой - сформированный для кода, полученного в результате трансляции.

Первым делом определим, как мы сопоставляем свойства из двух отпечатков безопасности для того, чтобы сравнить их значения; возможно несколько вариантов:

1) В обоих отпечатках безопасности есть свойство с одним и тем же именем; например, свойство безопасности “проверка входных аргументов”. В этом случае все очевидно - такие свойства сопоставляются.

2) В двух отпечатках безопасности есть два свойства, имена которых совпадают по семантическому смыслу. Пусть, например, мы транслируем код с языка C# на язык Golang; в коде на языке C# у нас есть свойство безопасности “сильная гарантия к возникновению исключений”. Но в языке Golang нет исключений - вместо этого в языке Golang используются ошибки (обычно функция в языке Golang возвращает пару значение - ошибка); поэтому в коде на языке Golang будет свойство безопасности “сильная гарантия к возникновению ошибок”. Вот при сравнении двух отпечатков безопасности, мы будем сопоставлять эти два свойства в случае трансляции кода с языка C# на язык Golang. В этом случае сопоставлять два свойства нужно аккуратно - только если на 100% есть уверенность, что эти два свойства семантически эквивалентны, т.к. в противном случае мы будем сопоставлять свойства, которые сопоставлять не имеет никакого смысла.

3) Во всех остальных случаях мы считаем, что свойства из двух отпечатков безопасности сопоставить невозможно.

Давайте поговорим о сравнении двух агрегирующих отпечатков безопасности: вначале мы сопоставляем свойства безопасности в этих отпечатках безопасности, после чего сравниваем их согласно таблице 2, приведенной выше. Так как мы сравниваем два агрегирующих отпечатка безопасности от исходного кода и кода после трансляции, то мы можем считать, что набор свойств отпечатков безопасности относительно их сопоставления одинаковый. В редких случаях, когда либо в одном, либо в другом отпечатке безопасности появляется свойство, которому невозможно сопоставить пару, то мы просто будем дописывать наличие этого свойства (вместе с его значением) к результатам сравнения.

Теперь поговорим о сравнении детализированных отпечатков безопасности. Детализированный отпечаток безопасности содержит все сущности (типы, методы, функции и т.д.), определенные в коде и для них определяет свойства безопасности (см. раздел 3.1). Поэтому мы сначала определяем соответствие между сущностями в исходном коде и в коде, полученном в результате трансляции, потом для сущностей, для которых было найдено соответствие, сравниваем их свойства безопасности. В итоге мы получим детализированный результат сравнения сущностей с дополнительным списком сущностей, для которых не удалось найти пару.

Вполне может возникнуть вопрос: а имеет ли сравнивать два набора отпечатков безопасности для двух кодовых баз, которые создавались независимо, но которые решают одну и ту же задачу. Если эти два набора отпечатков безопасности будут агрегирующими, то смысл есть - мы можем оценить, насколько качественно то или иное решение с точки зрения свойств безопасности. А вот сравнивать два набора детализированных отпечатков безопасности нет никакого смысла, что очевидно.

3.4 Что такое семантика безопасности кода

Теперь мы готовы определить, что же такое семантика безопасности кода. Семантику безопасности можно определить как набор свойств безопасности (или инвариантов безопасности или отпечаток безопасности), которые должны сохраняться (вместе с их значениями) во время всего жизненного цикла программы. Если какое-либо свойство безопасности в разное время жизненного цикла программы имеет разные значения, то необходимо построить его суммарное значение, пользуясь правилами слияния значений свойств безопасности (см. раздел 3.3).

Семантика безопасности — это неотъемлемое свойство исходного кода. С ее помощью можно описывать безопасность этого кода - например, предсказывать потенциальные уязвимости. Также с ее помощью можно отслеживать как меняется безопасность кода при его трансформации: как свойства безопасности ослабляются или вообще исчезают. Это утверждение справедливо и для случая, когда мы говорим о трансляции кода; поэтому определение семантики безопасности кода является для нас одним из ключевых определений.

3.5 Классы безопасности. Эволюция отпечатка безопасности во время трансляции

Очень важно понимать, как себя ведут свойства безопасности при трансляции кода. Но первым делом следует показать, что свойства безопасности кода не обязаны сохраняться при трансляции с одного языка на другой. Давайте рассмотрим пример кода на языке C#:

Листинг 1 – Исходный код примера на языке C# для демонстрации проблемы с сохранением типобезопасности

```
namespace SomeNamespace
{
```

```
public class ClassA
{
    public void Do(string data)
    {
    }
}

public class ClassB
{
    public void Do(string data)
    {
    }
}

public class Processor
{
    public void Process(ClassA objA)
    {
        objA.Do("IDDQD");
    }
}

public class Program
{
    public static void Main(string[] args)
    {
        ClassA objA = new ClassA();
        ClassB objB = new ClassB();
    }
}
```

```

    Processor processor = new Processor();
    processor.Process(objA);
    //processor.Process(objB);
}
}
}

```

Данный код обладает свойством типобезопасности - в метод ***Process*** класса ***Processor*** можно передать только экземпляр (объект) класса ***ClassA***; если в метод ***Process*** класса ***Processor*** попробовать передать экземпляр (объект) класса ***ClassB***, то мы получим ошибку компиляции (именно поэтому последняя строка в методе ***Main*** класса ***Program*** закомментирована).

А теперь давайте посмотрим, как мог бы выглядеть подобный пример в результате трансляции на язык Python:

Листинг 2 – Результат трансляции примера на язык Python без сохранения типобезопасности

```

class ClassA:
    def Do(self, data: str) -> None:
        pass

class ClassB:
    def Do(self, data: str) -> None:
        pass

class Processor:
    def Process(self, objA: ClassA) -> None:
        objA.Do("IDDQD")

class Program:

```

```
@staticmethod
def Main(args: list[str]):
    objA = ClassA()
    objB = ClassB()
    processor = Processor()
    processor.Process(objA)
    processor.Process(objB)
```

Данный код обладает уже меньшей типобезопасностью, т.к. в метод *Process* класса *Processor* можно передать как экземпляр (объект) класса *ClassA*, так и экземпляр (объект) класса *ClassB* (так и экземпляр любого класса, у которого есть метод *Do*). С точки зрения языка Python здесь все в порядке и никаких проблем нет, но вот с точки зрения исходного кода здесь есть одна проблема - в исходном коде в метод *Process* класса *Processor* можно было передать только экземпляр (объект) класса *ClassA*, тогда как в коде, полученном в результате трансляции, в метод *Process* класса *Processor* можно передать как экземпляр (объект) класса *ClassA*, так и экземпляр (объект) класса *ClassB*. Видно, что при трансляции произошло снижение типобезопасности кода.

Давайте попробуем классифицировать поведение свойств безопасности кода при трансляции:

1) Первый тип свойств безопасности — это свойства, которые автоматически переносятся при трансляции. К этому типу в основном относятся свойства, определенные самим кодом - проверки входных аргументов в функциях/методах и т.п.

2) Второй тип свойств безопасности — это свойства, которые не поддерживаются языком/платформой, но могут быть более-менее просто симитированы (реализованы вручную).

Давайте снова вернемся к предыдущему примеру - предположим, что мы транслировали исходный код в код на языке Python следующим образом:

Листинг 3 – Результат трансляции примера на язык Python с сохранением типобезопасности

```
class ClassA:
    def Do(self, data: str) -> None:
        pass

class ClassB:
    def Do(self, data: str) -> None:
        pass

class Processor:
    def Process(self, objA: ClassA) -> None:
        if not isinstance(objA, ClassA):
            raise ValueError("obj is not ClassA instance")
        objA.Do("IDDQD")

class Program:
    @staticmethod
    def Main(args: list[str]):
        objA = ClassA()
        objB = ClassB()
        processor = Processor()
        processor.Process(objA)
        #processor.Process(objB)
```

В этом варианте мы добавили в метод *Process* класса *Processor* проверку (с помощью встроенной функции *isinstance* [14]), что тип объекта, передаваемого в аргумент *objA* — это именно *ClassA*. С такой проверкой в метод *Process* класса *Processor* уже не удастся передать экземпляр (объект) класса *ClassB* (именно поэтому последняя строка в методе *Main* класса

Program закомментирована). Таким образом, мы смогли симитировать поведение (сгенерировать компенсирующий код) в коде на языке Python, поведение кода на исходном языке. А это означает, что при трансляции мы смогли сохранить такое свойство исходного кода, как типобезопасность.

3) Третий тип свойств безопасности — это свойства, которые не поддерживаются языком/платформой и не могут быть симитированы (либо их имитация крайне сложна). Рассмотрим, например, такой принцип, применяемый в ООП, как инкапсуляция. Если посмотреть на язык С#, то в нем инкапсуляция есть; поля, свойства, методы и т.д. объявленные с помощью модификатора доступа `private` доступны только внутри класса, в котором они объявлены. Да, конечно, к ним можно получить доступ с помощью рефлексии - .NET Reflection API [15], но это явно не стандартный механизм, а некоторый “черный” ход. С другой стороны, в языке Python никакого механизма инкапсуляции нет - есть соглашение, что имена, начинающиеся с двойного символа подчеркивания — это приватные члены; к таким именам применяется механизм искажения имен (name mangling) [16] - т.е. если член с именем `__member` объявлен в классе *SomeClass*, то его имя становится `_SomeClass__member`. Но это не настоящая инкапсуляция - программист может легко получить доступ к приватному члену просто преобразуя его имя и не используя никакое специальное АПИ для этого; скорее это способ избежать случайных конфликтов имен при наследовании. Поэтому такое свойство безопасности исходного кода, как инкапсуляция (а также ограничение доступа к членам для наследников) пропадает при трансляции. Можем ли мы его как-то симитировать? Для методов и свойств ответ будет скорее всего положительным: мы можем посмотреть стек вызова данного метода или свойства (например, с помощью функции *inspect.stack()* модуля *inspect* [17]) и проверить, имеет ли права на вызов данного члена вызывающий код (для приватного члена вызывающий код должен находиться в одном из членов того же класса, в котором определен проверяемый приватный член).

Однако для полей мы ничего сделать не можем. Таким образом, фактически мы не можем сохранить такое свойство безопасности исходного кода, как инкапсуляция при трансляции исходного кода с языка C# на язык Python.

4) Четвертый тип свойств безопасности - это свойства, которые отсутствовали в исходном коде, но появились в коде после трансляции, причем не важно из-за действий транслятора или из-за свойств языка/платформы. Предположим, что мы транслируем код с языка C на язык Python; предположим, что в коде на языке C для работы со строками используются такие небезопасные функции, как *strcpy*, *strcat* и другие (т.е. функции, которые не проверяют границы буфера при записи данных) [18]. Очевидно, что в таком коде на языке C такое свойство, как безопасность строковых операций отсутствует. Однако, как только мы транслируем этот код на язык Python, так сразу вся работа со строками станет безопасной, т.к. это фундаментальное свойство языка Python и его среды выполнения. Поэтому после трансляции у нашего кода появится такое свойство безопасности, как безопасность строковых операций.

Можно показать, что приведенный выше набор классов покрывает основные типы поведения свойств безопасности кода при трансляции. Таким образом, мы можем считать нашу классификацию поведения свойств безопасности кода при трансляции достаточной для наших задач.

Обозначим типы (классы) свойств безопасности следующим образом:

- L1 - свойства безопасности, которые автоматически сохраняются при трансляции;
- L2 - свойства безопасности, поддержка которых отсутствует в языке/платформе, на который мы транслируем код, но которые мы можем симитировать (с помощью дополнительного кода, генерируемого при трансляции);

- L3 - свойства безопасности, поддержка которых отсутствует в языке/платформе, на который мы транслируем код, и которые мы не можем симитировать (либо их имитация крайне сложна);
- L4 - свойства безопасности, поддержка которых отсутствует в исходном коде, но которые появляются в коде после трансляции, причем не важно из-за действий транслятора или из-за свойств языка/платформы.

А теперь давайте посмотрим на эти типы (классы) свойств безопасности с точки зрения того, как мы будем обрабатывать при трансляции соответствующие свойства, принадлежащие тому или иному классу:

- L1 - для сохранения свойств этого класса ничего делать не нужно (мы их просто отслеживаем), т.к. они автоматически переносятся при трансляции кода.
- L2 - для сохранения свойств этого класса требуется генерация дополнительного кода (компенсирующих механизмов), т.к. в противном случае они не сохранятся при трансляции кода.
- L3 - свойства этого класса сохранить невозможно (без переработки исходного кода), поэтому мы можем только зафиксировать их исчезновение как допустимое или недопустимое для нас ослабление итогового отпечатка безопасности.
- L4 - свойства этого класса являются “приятным бонусом” при трансляции кода; мы просто фиксируем их появление в коде после трансляции.

Можно оформить эту обработку в виде функции принятия решения следующего вида (таблица 3):

Таблица 3 – Функция принятия решения

Класс свойств безопасности	Действие над свойствами безопасности
L1	Ничего не делаем (отслеживаем)

L2	Генерируем дополнительный код (компенсирующие механизмы)
L3	Фиксируем допустимое или недопустимое (для нас) ослабление (исчезновение свойства безопасности)
L4	Фиксируем улучшение

Давайте повторим одну из самых главных мыслей о классификации свойств безопасности еще раз: исчезновение свойств безопасности, принадлежащих классу L3, не является какой-либо ошибкой или недоработкой транслятора; это происходит из-за особенностей языка/платформы, на которую мы транслируем исходный код. Например, то, что исчезает инкапсуляция при трансляции кода с языка C# на язык Python — это фундаментальное свойство языка Python.

Следует сделать еще следующее замечание: класс (тип) какого-либо свойства безопасности зависит от пары языков - исходного и на который происходит трансляция; если пара языков изменится, то и класс (тип) этого свойства безопасности тоже может измениться. Так, например, свойство безопасности “сохранение инкапсуляции” для пары языков C# - Python имеет класс (тип) L3; однако это же свойство для пары языков C# - C++ имеет класс (тип) L1, т.к. в языке C++ есть полная поддержка инкапсуляции.

3.5.1 Попытка сохранения правильного доступа к членам при трансляции кода с языка C# на язык Python

Так как мы часто упоминаем проблему с исчезновением инкапсуляции и модификаторов доступа при трансляции кода с языка C# на язык Python, то давайте рассмотрим этот пример более подробно. Вот исходный код на C#, который демонстрирует, что инкапсуляция и модификаторы доступа работают так, как от них это ожидается:

Листинг 4 – Исходный код примера на языке C# для демонстрации проблемы с инкапсуляцией и модификаторами доступа

```
namespace SomeNamespace
{
    public class ClassA
    {
        public void Do(string data)
        {
            Do2(data);
            Do3(data);
            value1 = 1;
            value2 = 2;
            value3 = 3;
        }
        protected void Do2(string data)
        {
        }
        private void Do3(string data)
        {
        }
        public int value1;
        protected int value2;
        private int value3;
    }

    public class ClassB : ClassA
    {
        public void Make(string data)
```

```

    {
        Do(data);
        Do2(data);
        //Do3(data);
        value1 = 111;
        value2 = 222;
        //value3 = 3;
    }
}

public class Program
{
    public static void Main(string[] args)
    {
        ClassA objA = new ClassA();
        ClassB objB = new ClassB();
        objA.Do("IDDQD");
        //objA.Do2("IDDQD");
        //objA.Do3("IDDQD");
        objB.Do("IDKFA");
        objB.Make("IDKFA");
        Console.WriteLine(objA.value1);
        //Console.WriteLine(objA.value2);
        //Console.WriteLine(objA.value3);
        Console.WriteLine(objB.value1);
        //Console.WriteLine(objB.value2);
    }
}

```

```
}
```

В связи с тем, что в языке C# инкапсуляция и модификаторы доступа поддерживаются полностью, часть строк в коде закомментирована; если их раскомментировать, то мы получим ошибку компиляции.

А теперь давайте посмотрим, как мог бы выглядеть подобный пример в результате трансляции на язык Python:

Листинг 5 – Результат трансляции примера на язык Python без сохранения инкапсуляции и модификаторов доступа

```
class ClassA:
    def __init__(self):
        self.value1 = 0
        self._value2 = 0
        self.__value3 = 0
    def Do(self, data: str) -> None:
        self._Do2(data)
        self.__Do3(data)
        self.value1 = 1
        self._value2 = 2
        self.__value3 = 3
    def _Do2(self, data: str) -> None:
        pass
    def __Do3(self, data: str) -> None:
        pass

class ClassB(ClassA):
    def Make(self, data: str) -> None:
        self.Do(data)
        self._Do2(data)
```

```
self._ClassA__Do3(data)
self.value1 = 111
self._value2 = 222
self._ClassA__value3 = 333
```

```
class Program:
```

```
    @staticmethod
```

```
    def Main(args: list[str]) -> None:
```

```
        objA = ClassA()
        objB = ClassB()
        objA.Do("IDDQD")
        objA._Do2("IDDQD")
        objA._ClassA__Do3("IDDQD")
        objB.Make("IDKFA")
        print(objA.value1)
        print(objA._value2)
        print(objA._ClassA__value3)
        print(objB.value1)
        print(objB._value2)
```

Из примера, полученного в результате трансляции, на языке Python видно (по сравнению с исходным примером на языке C#), что в языке Python инкапсуляция не поддерживается совсем; модификаторов доступа как таковых нет, но разделение на публичные (public), защищенные (protected) и приватные (private) члены происходит с помощью префиксов имен (имена защищенных членов начинаются с одного символа подчеркивания, имена приватных членов - с двух). Как итог, в примере на языке Python мы имеем полный доступ ко всем членам, с учетом механизма искажения имен (name mangling) [16] для приватных (private) членов (для членов, имя которых начинается с двух символов подчеркивания).

Давайте модифицируем пример на языке Python так, чтобы поведение для методов соответствовало поведению для методов в исходном примере на языке C#:

Листинг 6 – Результат трансляции примера на язык Python с сохранением модификаторов доступа для методов, но без сохранения инкапсуляции

```
import inspect

class ClassA:
    def __init__(self):
        self.value1 = 0
        self._value2 = 0
        self.__value3 = 0
    def Do(self, data: str) -> None:
        self._Do2(data)
        self.__Do3(data)
        self.value1 = 1
        self._value2 = 2
        self.__value3 = 3
    def _Do2(self, data: str) -> None:
        stack = inspect.stack()
        caller = stack[1].frame.f_locals.get('self') if len(stack) > 1 else None
        if not (caller and isinstance(caller, ClassA)):
            raise ValueError("Bad caller")
        pass
    def __Do3(self, data: str) -> None:
        stack = inspect.stack()
        if len(stack) < 2:
            raise ValueError("Bad caller")
```

```

caller_method = stack[1].function
caller_code = stack[1].frame.f_code
is_good_caller = False
for current_cls in self.__class__.__mro__:
    if caller_method in current_cls.__dict__:
        method = current_cls.__dict__[caller_method]
        if hasattr(method, '__code__') and method.__code__ is caller_code:
            is_good_caller = current_cls is ClassA
            break
if not is_good_caller:
    raise ValueError("Bad caller")
pass

```

```

class ClassB(ClassA):
    def Make(self, data: str) -> None:
        self.Do(data)
        self._Do2(data)
        #self._ClassA__Do3(data)
        self.value1 = 111
        self._value2 = 222
        self._ClassA__value3 = 333

```

```

class Program:
    @staticmethod
    def Main(args: list[str]) -> None:
        objA = ClassA()
        objB = ClassB()
        objA.Do("IDDQD")

```

```
#objA._Do2("IDDQD")
#objA._ClassA__Do3("IDDQD")
objB.Make("IDKFA")
print(objA.value1)
print(objA._value2)
print(objA._ClassA__value3)
print(objB.value1)
print(objB._value2)
```

Из модифицированного примера на Python видно следующее (по сравнению с исходным примером на языке C#):

- Мы смогли за счет дополнительного кода получить такое же поведение для методов, которое в языке C# может быть получено с помощью модификаторов доступа `public`, `protected`, `private`.
- Этот дополнительный код работает через анализ стека вызовов; он достаточно сложен и не тривиален (и не факт, что быстрый).
- Самое что неприятное - защитить таким же способом доступ к полям в языке Python возможности нет

Таким образом, свойства безопасности “сохранение инкапсуляции” и “правильная работа модификаторов доступа” при трансляции кода с языка C# на язык Python имеет класс L3 по нашей классификации свойств безопасности.

3.6 Проблемы с внешними зависимостями

Отдельно следует рассмотреть проблему со внешними зависимостями (библиотеками) в разрезе свойств безопасности и их классов. Любой код (любая кодовая база) зависит так или иначе от некоторого набора внешних библиотек, с помощью которых он реализует свою функциональность. Даже в самом простом случае, у любого кода есть зависимость от базовой библиотеки (.NET Base Class Library, Python Standard Library, C++ Standard Library и т.д.),

если не брать такие граничные случаи, как, например, ПО, которое напрямую работает с оборудованием.

С этими внешними зависимостями (библиотеками) есть одна большая проблема, связанная со свойствами безопасности — это наличие уязвимостей в этих зависимостях (библиотеках). Не для кого не является секретом, что во многих версиях многих зависимостей (библиотек) со временем исследователи или хакеры находят уязвимости той или иной степени критичности. Соответственно, как только это происходит, это сразу же меняет впечатление безопасности либо для исходного кода, либо для кода, полученного в результате трансляции, либо для них обоих. Следует сказать, что при этом в классификации свойств безопасности новых классов не появляется. Также и состав (набор свойств) впечатления безопасности не меняется, но могут поменяться значения свойств. Например, значение свойства безопасности с “поддерживается” может измениться на “поддерживается частично” или “не поддерживается”, а значение “поддерживается частично” может измениться на “не поддерживается”. То есть, происходит “деградация” значений свойств безопасности. Соответственно, если мы не хотим, чтобы такая “деградация” впечатления безопасности со временем происходила, то мы должны периодически проверять используемые внешние зависимости (библиотеками) с помощью Software Composition Analysis (SCA) или анализа состава программного обеспечения [19]; после чего обновлять внешние зависимости (библиотеками) для которых обнаружены неприемлемые уязвимости. К сожалению, это далеко не такой простой процесс как может показаться:

- Никто не гарантирует, что более новая версия по АПИ или по поведению совместима со старой, особенно, если изменился мажорный номер версии внешней зависимости (библиотеки) - вполне возможно, что замена внешней зависимости (библиотеки) на более новую потребует значительных доработок либо в исходном коде, либо в коде, полученном в результате трансляции, либо и там, и там.

- Вполне возможна ситуация, что новых версий какой-либо внешней зависимости (библиотеки) нет (например, ее забросили), а аналогов либо нет вообще, либо они очень сильно отличаются по дизайну АПИ и/или функционалу. В этом случае вполне допустима ситуация, что мы продолжаем использовать старую внешнюю зависимость (библиотеку), например, через некоторый промежуточный слой кода, который вводит дополнительные проверки, преобразования данных и т.д., чтобы минимизировать возможность использования уязвимостей в этой внешней зависимости (библиотеки).

Из этого можно сделать следующий вывод: внешние зависимости являются внешним фактором, который способен изменять состояние свойств безопасности после трансляции с течением времени и, как итог, приводить к “деградации” отпечатка безопасности. Другими словами, с течением времени из-за внешних зависимостей семантика безопасности может становиться “слабее” уже после трансляции.

Есть еще одна потенциальная проблема с внешними зависимостями при трансляции кода: вполне возможна ситуация, что будут появляться новые сущности, либо исчезать сущности, которые есть в исходном коде при трансляции кода с одного языка на другой именно из-за несоответствия между внешними зависимостями (библиотеками) для исходного кода и для кода, полученного в результате трансляции. Это не такая большая проблема, как проблема с возникновением уязвимостей, но это несоответствие между сущностями влияет на сравнение детализированных отпечатков безопасности для исходного кода и для кода, полученного в результате трансляции (см. раздел 3.2).

3.7 Сохранение семантики безопасности при трансляции

Мы видели выше из классификации (см. раздел 3.5) свойств безопасности, что свойства безопасности, принадлежащие классу L1,

автоматически сохраняются при трансляции кода, а свойства безопасности, принадлежащие классу L2, могут быть симитированы. Поэтому мы можем сказать, что семантика безопасности при трансляции кода с одного языка на другой сохраняется, если все свойства безопасности исходного кода, принадлежащие классам L1 и L2 сохраняются в коде после трансляции. Не сохранение свойств, принадлежащих классу L3, может быть крайне чувствительным при трансляции кода, но, пожалуй, единственный способ уменьшить их количество - это ручное изменение исходного кода (но даже это ручное изменение исходного кода не всегда помогает - например, с потерей инкапсуляции при трансляции кода с языка C# на язык Python мы ничего сделать не можем из-за природы языка Python). Свойства, принадлежащие классу L4, на сохранение семантики безопасности никак не влияют; однако они влияют на ее улучшение.

Исходя из написанного выше (а также с учетом сохранения функциональных требований и поведения) мы будем считать трансляцию кода успешной, если:

- 1) Все функциональные требования были сохранены при трансляции.
- 2) Поведение исходного кода и кода, полученного в результате трансляции, совпадает.
- 3) Все свойства безопасности, принадлежащие классам L1 и L2, будут сохранены.
- 4) Для нас приемлемо, что все свойства безопасности, принадлежащие классу L3, будут утеряны. Например, если потеря инкапсуляции при трансляции кода с языка C# на язык Python для нас неприемлема (инкапсуляция при такой трансляции является свойством безопасности, принадлежащим классу L3 - см. раздел 3.5), то в таком случае мы трансляцию кода будем считать неуспешной.

5) Все свойства безопасности, принадлежащие классу L4, будут для нас “приятным бонусом” - они не влияют на успешность или неуспешность трансляции.

3.8 Влияние окружения (контекста использования)

Программный код запускается не сам по себе - он существует в некотором окружении или контексте. И это окружение (контекст использования) определяет, как это код используется и может влиять в том числе и на требования безопасности, и на свойства безопасности. Окружение (контекст использования) легко учесть, когда мы его заранее знаем, но бывают случаи, когда программный код может запускаться в разных окружениях (контекстах использования) с разными требованиями к безопасности и разными свойствами безопасности.

Чтобы понять, как может влиять окружение (контекст использования) на программный код, давайте сначала посмотрим, как вообще мы можем запустить и/или использовать программный код. Варианты запуска и/или использования программного кода у нас есть следующие:

- 1) Запуск в виде standalone приложения.
- 2) Запуск в виде сервиса в некоторой программно-аппаратной конфигурации.
- 3) Использование в виде библиотеки.

Очевидно, что какой из вариантов запуска и/или использования программного кода доступен, зависит от того, как организован код и что мы с ним делаем. Если код организован в виде приложения, то его можно использовать как приложение, как сервис и, иногда, в виде библиотеки (например, в результате компиляции приложения, написанного на языке C#, мы получаем сборку, которую другое приложение может использовать как библиотечный код). Если код организован в виде библиотеки, то обычно мы можем использовать его только, как библиотеку. Сервисами обычно являются

приложения, хотя в некоторых случаях сервисами могут быть и динамические библиотеки.

А сейчас давайте на примерах посмотрим в каких случаях у программного кода одно окружение (контекст использования), а в каких случаях больше одного:

1) Обычно, у standalone приложений одно окружение (контекст использования), в котором оно запускается и, как итог - у них один набор требований безопасности и свойств безопасности. Однако бывают случаи, когда у standalone приложений может быть больше одного окружения (контекста использования): например, когда приложение должно себя по-разному ввести, когда оно запущено от имени обычного пользователя и когда оно запущено от имени администратора (обычно это свойственно системным утилитам, например, для Unix/Linux). Очевидно, что количество окружений (контекстов использования), которые должно поддерживать приложение зависит от создателя приложения и является четко определенной величиной на момент его создания.

2) У сервисов может быть как одно окружение (контекст использования), так и несколько, в которых эти сервисы могут использоваться. Например, web-сервис может использоваться как одиночный сервис, так и в составе некоторого кластера Kubernetes; и в этих двух разных сценариях использования web-сервиса у него вполне может быть два разных окружения (контекста использования) с разными наборами требований безопасности и свойств безопасности. Но также, как и в случае standalone приложений, количество окружений (контекстов использования), которые должен поддерживать сервис зависит от создателя сервиса и является четко определенной величиной на момент его создания.

3) А вот с библиотеками все уже не так однозначно, так создатель библиотеки не может предусмотреть все варианты использования его библиотеки: она может быть использована и в консольном приложении, и в

приложении с GUI и в разнообразных сервисах и даже другими библиотеками. Понятно, что создатель библиотеки выбирает некоторый набор требований безопасности и свойств безопасности, которым должна удовлетворять создаваемая им библиотека. Рассмотрим, например, некоторую библиотеку. При ее создании, автор может добавить свойство безопасности “проверка входных аргументов функций” в свойства безопасности, которыми должна обладать библиотека; он даже может добавить свойство безопасности “корректная обработка ввода пользователя при формировании SQL-запросов” чтобы избежать потенциальных SQL-инъекций в коде. Но вот свойство безопасности “правильная работа с путями” в этой библиотеке вполне возможно, что отсутствует; и использование этой библиотеки в некотором web-сервисе, потенциально вносит уязвимость Path Traversal [20]. Должен ли был автор добавить свойство безопасности “правильная работа с путями” в список свойств безопасности библиотеки? Если библиотека изначально разрабатывалась для использования в среде web, то да; иначе - не обязательно. Таким образом видно, что наибольшую важность окружение (контекст использования) использования имеет для библиотек, т.к. авторы библиотек далеко не всегда могут предусмотреть все варианты их использования.

С точки зрения математической формализации (см. раздел 3.10), это означает, что отпечаток безопасности (отпечаток безопасности) для программы P_A зависит еще и от контекста использования этой программы (программного кода):

$$F = F(P_A, C), \quad (5)$$

где

C - окружение (контекст использования).

Дальше, для упрощения модели, мы будем считать, что окружение (контекст использования) у нас везде один; но при необходимости, мы всегда можем обобщить наши результаты на случай, когда окружений (контекстов использования) несколько.

3.9 Цели трансляции и влияние на требования к сохранению семантики безопасности

Рассмотрим цели, для которых может применяться процесс трансляции кода более подробно (см. таблица 4). При этом стоит учесть, что сама цель трансляции влияет на то, какие ослабления допустимы, какие инварианты критичны, а какие можно принять как ограничение целевой среды.

Таблица 4 – Цели трансляции кода

Цель трансляции	Описание
Выпуск библиотеки на другом языке	Пример ситуации: Есть библиотека для языка C#, нужно выпустить версию для языка Python. Что важно сохранить: API-контракты, типовые ограничения, поведение публичных методов, обработку ошибок. Что может стать критичным: Потеря перегрузок, изменение интерфейса, потеря readonly-семантики, ослабление типобезопасности. Как реагирует методика: Формируется отпечаток безопасности публичного API; для свойств безопасности L2 генерируются компенсации, потери свойств безопасности L3 фиксируются как допустимые или недопустимые.
Миграция унаследованного (legacy) кода	Пример ситуации: Старый код переносится на новую платформу. Что важно сохранить: Функциональное поведение, проверки входных данных, обработку исключений, работу с ресурсами. Что может стать критичным:

	Неявные контракты, плохо документированная логика, скрытые зависимости. Как реагирует методика: Методика фиксирует, какие инварианты удалось выявить, а какие остаются ограничением из-за качества исходного кода.
Импортозамещение или технологическая миграция	Пример ситуации: Необходимо уйти с одной платформы на другую. Что важно сохранить: Защитные свойства кода и управляемость процесса переноса. Что может стать критичным: Замена библиотек, новые зависимости, деградация безопасности во времени. Как реагирует методика: Дополнительно учитываются внешние зависимости и возможность деградации отпечатка безопасности
Поддержка продукта, поддерживающего несколько платформ	Пример ситуации: Один продукт поддерживается на нескольких языках или на разных платформах. Что важно сохранить: Единообразие защитных свойств в разных реализациях. Что может стать критичным: Расхождение версий по семантике безопасности. Как реагирует методика: Отпечатки безопасности разных реализаций сравниваются между собой.

Эксперимент: проверка переносимости	Пример ситуации: Проверяется возможность безопасного переноса на новую платформу. Что важно сохранить: Предсказуемость изменений, список потерь и компенсаций. Что может стать критичным: Невозможность сохранить инварианты безопасности L3. Как реагирует методика: Методика позволяет заранее понять, достижима ли приемлемая трансляция.
Перенос внутреннего standalone- приложения	Пример ситуации: Внутренняя утилита переносится на другой язык. Что важно сохранить: Функциональность, базовые проверки, обработку ошибок. Что может стать критичным: Невозможность сохранить все инварианты безопасности L3. Как реагирует методика: Потери для большого количества инвариантов безопасности L3 могут быть признаны допустимыми при низком внешнем риске.
Перенос публичной библиотеки или SDK	Пример ситуации: Код будет использоваться внешними разработчиками. Что важно сохранить: Строгие API-контракты, типобезопасность, контроль внутреннего состояния.

	Что может стать критичным: Потеря инкапсуляции, изменение интерфейса, неочевидное поведение Как реагирует методика: Критичность потерь инвариантов безопасности L3 выше; некоторые потери могут быть признаны недопустимыми.
--	--

3.10 Математическая формализация семантики безопасности кода

Давайте формализуем с точки зрения математики некоторые определения, которые мы уже ввели или введем далее.

3.10.1 Формальная модель программы и трансляции

Пусть программа P_A на языке A представлена как кортеж:

$$P_A = (AST_A, S_A, I_A), \quad (6)$$

где:

AST_A - синтаксическое дерево (abstract syntax tree) программы P_A ;

S_A - множество семантических свойств поведения программы P_A ;

I_A - множество свойств безопасности (инвариантов безопасности) программы P_A .

Оператор трансляции T программы (исходного кода) на языке A в программу (исходного кода) на языке B определяется как отображение:

$$T: P_A \rightarrow P_B, \quad (7)$$

где:

P_A - программа на языке A ;

P_B - программа на языке B .

3.10.2 Модель свойств безопасности

Множество свойств безопасности (инвариантов безопасности) I_A задается следующим образом:

$$I_A = \{i_1, i_2, \dots, i_n\}, \quad (8)$$

где каждое свойство безопасности (инвариант безопасности) i_k — это функция над программой P_A (можно сказать, что это 3-значный предикат):

$$i_k: P_A \rightarrow \{0, 1/2, 1\}, \quad (9)$$

где:

- значение 0 означает, что соответствующее свойство безопасности имеет значение “не поддерживается”;
- значение 1/2 означает, что соответствующее свойство безопасности имеет значение “поддерживается частично”;
- значение 1 означает, что соответствующее свойство безопасности имеет значение “поддерживается полностью”.

Семантическое сопоставление свойств безопасности (см. раздел 3.3) можно записать следующим образом:

$$\mu(I_A, I_B): I_A \rightarrow I_B \cup \emptyset. \quad (10)$$

Мы считаем, что при трансляции T свойство безопасности (инвариант безопасности) i_k сохраняется, если:

$$i_k(P_A) \neq 0 \wedge i_k(P_B) = i_k(P_A). \quad (11)$$

3.10.3 Классификация уровней сохранения

Мы ввели (см. раздел 3.5) следующие типы (классы) свойств безопасности:

- L1 - свойства безопасности, которые автоматически сохраняются при трансляции T ;
- L2 - свойства безопасности, поддержка которых отсутствует в языке/платформе, на который мы транслируем код, но которые мы можем симитировать при трансляции T ;

- L3 - свойства безопасности, поддержка которых отсутствует в языке/платформе, на который мы транслируем код, и которые мы не можем симитировать при трансляции T;
- L4 - свойства безопасности, поддержка которых отсутствует в исходном коде, но которые появляются в коде при трансляции T.

Тогда функция классификации может быть определена следующим образом:

$$\varphi(i_k) \in \{L1, L2, L3, L4\}. \quad (12)$$

3.10.4 Отпечаток безопасности

Как уже говорилось (см. раздел 3.2), у нас есть два типа отпечатков безопасности: агрегирующие и детализированные.

Агрегирующий отпечаток безопасности (состоящий из N свойств безопасности) мы можем записать следующим образом:

$$F_a(P_A) = (i_1, i_2, \dots, i_n), \quad (13)$$

где:

i_k - свойство безопасности (инвариант безопасности)

Пусть e_j - некоторая сущность, определенная в исходном коде программы P_A :

$$e_j \in E(P_A), \quad (14)$$

где

$E(P_A)$ - множество всех сущностей, определенных в программе P_A .

Пусть $I(e_j)$ - множество всех свойств безопасности, определенных для сущности e_j

$$I(e_j) = \{i_1, i_2, \dots, i_n\}, \quad (15)$$

где:

i_k - свойство безопасности (инвариант безопасности)

Тогда детализированный отпечаток безопасности (состоящий из свойств безопасности M сущностей, определенных в исходном коде программы P_A , мы можем записать следующим образом:

$$F_d(P_A) = (I(e_1), I(e_2), \dots, I(e_m)). \quad (16)$$

3.10.5 Метрика допустимого ослабления

Как уже говорилось (см. раздел 3.7), мы будем считать трансляцию кода успешной, если:

- Все свойства безопасности, принадлежащие классам $L1$ и $L2$, будут сохранены.
- Для нас приемлемо, что все свойства безопасности, принадлежащие классу $L3$, будут утеряны.

Поэтому допустимое ослабление отпечатка безопасности может быть определена следующим образом:

$$\Delta(P_A, P_B) = |\{i_k \in I_A : \varphi(i_k) = L3 \wedge i_k(P_A) \neq 0 \wedge i_k(P_B) = 0\}|, \quad (17)$$

При этом, обязательно должно выполняться условие:

$$|\{i_k \in I_A : \varphi(i_k) \in \{L1, L2\} \wedge i_k(P_A) \neq 0 \wedge i_k(P_B) = 0\}| = 0, \quad (18)$$

Можно еще ввести метрику сохранения, которая определяется следующим образом:

$$Match(P_A, P_B) = |i_k \in I_A : i_k(P_A) = i_k(P_B)| / |I_A|. \quad (19)$$

На основании этой метрики, можно ввести допустимый порог потери свойств безопасности (которые принадлежат классу $L3$):

$$1 - Match(P_A, P_B) \leq \varepsilon, \quad (20)$$

где:

ε - оценка того, сколько свойств безопасности мы позволяем себе потерять.

Следует заметить, что эта оценка не учитывает важность свойств безопасности, т.к. не все свойства безопасности равнозначны (это зависит от проекта). Так, например, если для нас критически важно, чтобы инкапсуляция

не терялась, а мы транслируем исходный код с языка C# на язык Python, то в этом случае для нас трансляция будет не успешной, даже если мы теряем всего одно это свойство.

3.10.6 Гипотеза симплификации

О симплификации мы будем говорить далее (см. раздел 4.6), но формализацию гипотезы приведем здесь.

Пусть $C(AST)$ - сложность трансляции, пропорциональная количеству типов узлов, о которых должен знать транслятор (которые должен уметь обрабатывать транслятор). Очевидно (из определения того, что делает утилита для симплификации), что $C(AST)$ после симплификации всегда будет меньше или равно $C(AST)$ до симплификации:

$$C_{after}(AST) \leq C_{before}(AST). \quad (21)$$

Можно выдвинуть следующую гипотезу:

$$P_{after}(Error) \leq P_{before}(Error), \quad (22)$$

где:

$P_{before}(Error)$ - вероятность появления дефекта при трансляции до симплификации;

$P_{after}(Error)$ - вероятность появления дефекта при трансляции после симплификации.

3.11 Нормативные и методические основания формирования отпечатка безопасности

Для формирования отпечатка безопасности для некоторого множества кода (например, для метода или класса) необходимо провести анализ этого кода и выделить свойства безопасности. Чтобы централизованно идентифицировать, какие свойства безопасности вообще присутствуют в анализируемом исходном коде, нужны нормативные, методические и

справочные источники. Ниже перечислены ряд таких источников, которые можно использовать для решения такой задачи.

CWE (Common Weakness Enumeration) [2] - классификатор типовых слабостей реализации и проектирования. В отличие от списка уязвимостей (CVE), CWE описывает дефект на уровне абстракции “неправильное обращение с буфером”, “некорректная обработка целочисленного переполнения” и т.д. (хотя в некоторых ситуациях для формирования отпечатка безопасности необходимо работать и со списком уязвимостей CVE [21], например, когда мы работаем с кодом, у которого в более ранних версиях были известные CVE). При трансляции CWE применяется для идентификации потенциальных свойств безопасности исходя из языка программирования, на котором написан исходный код, и самого исходного кода. Фиксация факта наличия слабости по классификатору CWE означает, что в коде присутствует нарушение определённого свойства безопасности.

CERT Secure Coding [22] - набор правил безопасного кодирования для различных языков. Правила описывают корректные и некорректные паттерны использования конструкций и позволяют на их основе находить свойства безопасности исходного кода для заданного языка. Наличие в исходном коде нарушения правила CERT указывает на отсутствие некоторого защитного свойства (например, отсутствует проверка возврата выделения памяти).

OWASP [23] - используется в тех случаях, когда трансляции подвергается код, взаимодействующий с веб-интерфейсами или API. Источники - OWASP Top 10 API Security Risks и ASVS. Эти документы вводят требования к валидации входных данных, управлению сессиями, безопасной сериализации. Применение OWASP позволяет выявить свойства безопасности, относящиеся к взаимодействию через web.

ГОСТ Р 56939-2024 “Защита информации. Разработка безопасного программного обеспечения. Общие требования” [24]. Стандарт обязывает вести реестр опасных конструкций языка. Для целей трансляции это означает,

что из исходного кода могут быть извлечены опасные конструкции - например, небезопасные функции работы со строками в C. Эти конструкции указывают на отсутствие соответствующего свойства безопасности.

ГОСТ Р 58412-2019 “Защита информации. Анализ угроз безопасности информации при разработке программного обеспечения” [25] задаёт порядок построения модели угроз. В контексте трансляции этот стандарт используется для того, чтобы связать отсутствие или наличие тех или иных свойств в коде с конкретными угрозами. Например, отсутствие проверки границ массива — это не просто отсутствие свойства безопасности “проверка выхода за границы массива”, а угроза переполнения буфера. Такая привязка позволяет обосновать важность контроля соответствующего свойства.

Методика ФСТЭК России 2021 года (оценка угроз безопасности информации) [26] и БДУ ФСТЭК (банк данных угроз) [27] обеспечивают формальную связь между типами слабостей, методами их реализации и угрозами. Потенциально, эта связь может быть использована для того, чтобы для каждого выявленного свойства указать, какую именно угрозу оно блокирует (если свойство присутствует) либо какую угрозу создаёт его отсутствие.

Приказ ФСТЭК России от 01.12.2023 № 240 (“Об утверждении порядка проведения сертификации процессов безопасной разработки программного обеспечения средств защиты информации”) [28] не является прямым нормативным основанием для предлагаемой методики трансляции. Приказ регулирует сертификацию процессов, а не автоматическое преобразование кода. Вместе с тем он может рассматриваться как косвенный элемент контекста: при миграции и трансформации кода должна сохраняться управляемость защитных свойств. Процесс трансляции должен быть контролируемым и документированным. В данной работе приказ № 240 не используется для сертификации и не предъявляется как обязательное требование к результату трансляции.

Таким образом, перечисленные источники решают задачу выявления свойств безопасности в исходном коде и их привязки к угрозам. Нормативные документы задают, какие свойства вообще стоит рассматривать при анализе исходного кода перед трансляцией и какие угрозы связаны с отсутствием или нарушением этих свойств.

3.12 Угрозы безопасности при трансляции

Давайте рассмотрим какие угрозы нарушения семантики безопасности могут возникать при трансляции программного кода (см. таблица 5). При этом будем рассматривать только трансляцию кода с языка C# на язык Python, согласно ограничениям, введенным в данной работе (см. раздел 1.1 2).

Таблица 5 – Возможные угрозы нарушения семантики безопасности при трансляции с языка C# на язык Python

Угроза при трансляции	Описание
Ослабление типобезопасности	Причина возникновения: Переход от статической типизации в языке C# к динамической типизации в языке Python. Нарушаемый инвариант: Типобезопасность. Возможное последствие: Передача объекта неверного типа, вызов неподходящей логики, позднее обнаружение ошибки. Класс инварианта безопасности: L2. Реакция методики: Генерация проверок времени выполнения, например, с помощью функции <i>isinstance</i>.
Потеря инкапсуляции	Причина возникновения:

	В языке Python отсутствуют полноценные <code>private</code> и <code>protected</code> модификаторы доступа. Нарушаемый инвариант: Инкапсуляция, контроль доступа к членам класса. Возможное последствие: Доступ к внутреннему состоянию объекта, обход ожидаемых ограничений. Класс инварианта безопасности: L3. Реакция методики: Фиксация ослабления как допустимого или недопустимого; частичная эмуляция для методов возможна, но для полей нет.
Нарушение корректной поддержки перегрузок	Причина возникновения: Язык Python не поддерживает перегрузку методов. Нарушаемый инвариант: Безопасность API-контракта. Возможное последствие: Вызов не той логики, изменение интерфейса, неоднозначная обработка аргументов. Класс инварианта безопасности: L2. Реакция методики: Генерация выбора (dispatch) нужной перегрузки во время выполнения на основе числа и типов аргументов.
Потеря readonly-семантики	Причина возникновения: В языке Python нет прямого аналога <code>readonly</code>-полей языка C#. Нарушаемый инвариант:

	Целостность состояния объекта после инициализации. Возможное последствие: Возможность изменения состояния, которое в исходном коде считалось неизменяемым. Класс инварианта безопасности: L3. Реакция методики: Фиксация ослабления как допустимого или недопустимого; возможна частичная эмуляция с помощью свойств без сеттер-методов.
Потеря проверок входных аргументов	Причина возникновения: Ошибка транслятора, ручная трансляция или трансляция с помощью LLM без сохранения проверок входных аргументов. Нарушаемый инвариант: Проверка входных аргументов. Возможное последствие: Некорректные данные попадают в бизнес-логику. Класс инварианта безопасности: L1, если проверки были явно в коде. Реакция методики: Проверяется сохранение в отпечатке безопасности; потеря свойства безопасности L1 считается неуспешной трансляцией.
Изменение модели исключений	Причина возникновения: Различия в типах исключений и некоторых правилах их обработки. Нарушаемый инвариант:

	Гарантия состояния при исключениях (exception safety). Возможное последствие: Изменение в поведении кода на языке Python при возникновении исключения. Класс инварианта безопасности: в основном L1, в редких случаях L2. Реакция методики: Использование классов-оберток при трансляции исключений, тесты, проверка поведения.
Утечки ресурсов	Причина возникновения: Несоответствие между конструкцией using в языке C# и with в языке Python. Нарушаемый инвариант: Корректное управление ресурсами. Возможное последствие: Незакрытые файлы, соединения, дескрипторы. Класс инварианта безопасности: L2. Реакция методики: Генерация try-finally конструкции или адаптеров для использования с менеджером контекста (с конструкцией with).
Изменение порядка вычисления	Причина возникновения: Различия семантики языков и порядка вычисления выражений (только для некоторых случаев). Нарушаемый инвариант: Детерминированный порядок вычислений. Возможное последствие:

	Различие в поведении при вычислении выражений; как итог – потенциально разный результат работы кода при одних и тех же входных данных. Класс инварианта безопасности: L2. Реакция методики: Упрощение выражений, вынос подвыражений в отдельные шаги.
Потеря ленивой семантики	Причина возникновения: Несоответствие в реализации конструкций, вычисление которых происходит лениво, в языке C# и в языке Python. Нарушаемый инвариант: Безопасность ленивых вычислений. Возможное последствие: Выполнение кода, который не должен был выполняться, ошибка времени выполнения. Класс инварианта безопасности: в основном L2. Реакция методики: Генерация соответствующих адаптеров при трансляции кода; использование явных if-elif-else конструкций языка Python.
Новые риски зависимостей	Причина возникновения: Замена библиотек или API при трансляции. Нарушаемый инвариант: Безопасность зависимостей (dependency safety) Возможное последствие: Появление новых CVE/BDU-уязвимостей, supply chain risk

	Класс инварианта безопасности: не является инвариантом безопасности L1–L4. Реакция методики: Анализ состава программного обеспечения (SCA), фиксация деградации отпечатка безопасности во времени
Информационные утечки	Причина возникновения: Отличия repr, сообщений исключений, логирования. Нарушаемый инвариант: Безопасность при раскрытии информации. Возможное последствие: Раскрытие деталей реализации или внутренних данных. Класс инварианта безопасности: L2 (зависит от конструкции и контекста). Реакция методики: Анализ ошибок, логов и сообщений исключений
Ослабление проверки граничных значений (boundary validation)	Причина возникновения: Изменение границ API, модулей или публичных методов Нарушаемый инвариант: Проверка граничных значений. Возможное последствие: Увеличение поверхности атаки, появление неожиданных точек входа. Класс инварианта безопасности: L2 / L3. Реакция методики:

	Включение инвариантов безопасности, связанных с проверкой граничных значений, в отпечаток безопасности
Ошибки сериализации и десериализации	Причина возникновения: Различие в механизмах сериализации на разных платформах. Нарушаемый инвариант: Безопасность сериализации Возможное последствие: Небезопасная обработка внешних данных. Класс инварианта безопасности: L2 (зависит от конструкции и контекста). Реакция методики: Анализ используемых библиотек, SCA, тесты негативных сценариев.

Рассматриваемая в данной работе методика не моделирует конкретные цепочки атак и не заменяет полноценную модель угроз промышленной системы. Ее задача — выявить и контролировать изменения инвариантов защиты, которые могут создать условия для появления уязвимостей или усиления последствий ошибок после переноса кода.

3.13 Построение методики трансляции

На данный момент мы умеем определять свойства безопасности, строить и сравнивать отпечатки безопасности, классифицировать свойства безопасности при трансляции (классы L1, L2, L3, L4), определили, что такое семантика безопасности, как она сохраняется при трансляции и какие критерии у нас есть, чтобы считать трансляцию успешной. Мы также формализовали все это с математической точки зрения. Наш следующий шаг

— это построение методики автоматической трансляции кода с сохранением семантики безопасности на основе подходов, описанных выше.

4 Методика автоматической трансляции

4.1 Теоретическая часть: что такое компиляция. Как она работает - лексический, синтаксический анализ, AST, семантика, генерация кода

Компиляция представляет собой процесс преобразования программы, записанной на языке высокого уровня, в эквивалентную программу на более низком уровне абстракции, пригодную для непосредственного выполнения или дальнейшей обработки [29], [30], [31], [32], [33], [34], [35]. Как правило, результатом компиляции является машинный код либо промежуточное представление, используемое, например, в инфраструктурах наподобие LLVM. Основной целью компиляции является сохранение функционального поведения программы при одновременном обеспечении эффективности ее выполнения. Также целью многих компиляторов является и обеспечение безопасности полученного результата (см. выше *secure compilation*, *translation validation*, *verified compilation* - глава 2).

Первым этапом компиляции является лексический анализ, в ходе которого исходный текст программы разбивается на последовательность элементарных единиц - токенов. Токены представляют собой ключевые слова, идентификаторы, операторы и другие синтаксические элементы языка. На этом этапе устраняются (специальным образом обрабатываются) незначащие символы, такие как пробелы и комментарии, а также выявляются лексические ошибки.

Следующим этапом является синтаксический анализ, задача которого — установить, соответствует ли последовательность токенов грамматике языка программирования. Для этого используются формальные грамматики, чаще всего контекстно-свободные, задающие правила построения корректных программ. В процессе анализа строится синтаксическое представление программы, как правило, в виде абстрактного синтаксического дерева (AST), отражающего иерархическую структуру выражений и операторов

После построения AST выполняется семантический анализ, направленный на проверку корректности программы с точки зрения ее смысла. На данном этапе осуществляется проверка типов, областей видимости идентификаторов, корректности использования переменных и функций. Семантический анализ позволяет выявить ошибки, которые не могут быть обнаружены на уровне синтаксиса, например, использование необъявленных переменных или несоответствие типов.

Завершающим этапом первой фазы является генерация кода, в ходе которой абстрактное синтаксическое дерево преобразуется в целевое представление. Это может быть машинный код, байт-код или промежуточный язык. На данном этапе часто выполняются оптимизации, направленные на повышение производительности и уменьшение объема кода. Результирующая программа должна сохранять поведение исходной, обеспечивая корректное выполнение в целевой среде.

Вторая фаза компиляции — компоновка (linking) — заключается в объединении полученных объектных модулей в единый исполняемый файл или библиотеку, предназначенные для конкретной целевой операционной системы. На этом этапе разрешаются внешние ссылки между модулями, подключаются необходимые библиотеки, а также формируется окончательная структура бинарного файла. Компоновщик учитывает особенности целевой платформы, включая формат исполняемых файлов и соглашения о вызовах функций. В результате формируется готовая программа, которая может быть загружена и выполнена в соответствующей среде.

Таким образом, компиляция представляет собой многоэтапный и двухфазный процесс, включающий трансляцию исходного кода в объектные модули и их последующую компоновку в конечный исполняемый файл. Каждый из этапов играет важную роль в обеспечении корректности, эффективности и совместимости программы с целевой системой.

Следует сказать, что на каждом шаге каждой фазы обеспечение безопасности кода играет важную роль, поэтому большинство современных компиляторов на каждом шаге проверяют состояние свойств безопасности (инвариантов безопасности) кода, с которым они работают.

4.2 Что такое автоматическая трансляция. Технические сложности, возникающие при трансляции

С учетом определений, полученных выше при обсуждении того, что такое компиляция (см. раздел 4.1), давайте определим, что такое автоматическая трансляция кода с одного языка на другой. Как уже говорилось выше, компиляция состоит из 2 фаз:

1) трансляция кода с предметно-ориентированного высокоуровневого языка (иногда, с нескольких языков) на машинно-ориентированный низкоуровневый язык (машинный код, низкоуровневый код для некоторой виртуальной машины, низкоуровневый промежуточный код для последующей JIT-компиляции);

2) компоновка результирующего бинарного файла (программы, библиотеки, и т.п.) для целевой ОС из сгенерированных на предыдущей фазе (фазе трансляции) объектных модулей.

Фаза 1 (фаза трансляции) обычно состоит из следующих шагов:

1) Лексический анализ (токенизация) - процесс разбора входной последовательности символов на распознанные группы - лексем/токены.

2) Синтаксический анализ - процесс сопоставления линейной последовательности лексем/токенов формального языка с формальной грамматикой. Результатом является дерево разбора (синтаксическое дерево, AST).

3) Кодогенерация - процесс генерации последовательности инструкций, которые могут выполняться на целевой машине. Обычно, кодогенерация выполняется на синтаксическом дереве/AST.

Если на шаге кодогенерации фазы трансляции мы вместо генерирования последовательности инструкций, которые могут выполняться на целевой машине, будем генерировать сущностей кода (типы, функции, операторы, выражения и т.п.) на некотором языке, то это и будет называться автоматической трансляцией кода с исходного языка на некоторый другой язык.

Транслятором кода с исходного языка на некоторый другой язык называется программа, которая эту автоматическую трансляцию выполняет.

Существует ряд технических сложностей, с которыми неизменно придется столкнуться при создании транслятора кода - рассмотрим некоторые из них:

1) Построение AST из исходного кода. Если для платформы, на которой запускается исходный код есть библиотеки для построения AST (Roslyn для .NET [36], Clang LibTooling для C++ [37]), то делать ничего и не нужно. Если же нет - то нужно как при построении компилятора написать правила для лексики и синтаксиса, добавить действия для правил синтаксиса для генерации AST, сгенерировать лексический и синтаксический парсеры по правилам (например, с помощью ANTLR [38]), с их помощью получить AST для исходного кода. Кроме получения AST нужно также уметь получать информацию о типах. Облегчает задачу тот факт, что для большинства современных языков все же есть библиотеки для получения AST.

2) В некоторых случаях нам нужна возможность изменения AST и генерации по ней кода на исходном языке (например, при симплификации исходного кода - см. раздел 4.6). Опять же, если есть библиотеки, которые предоставляют такую функциональность (Roslyn для .NET, Clang LibTooling для C++), то делать ничего и не нужно. Если же нет, то эту функциональность необходимо создавать самому.

3) Генерация необходимых файлов для сборки. Помимо трансляции исходного кода необходимо также создать необходимые файлы с данными для

сборки для кода, полученного в результате трансляции (в тех случаях, когда это нужно). Например, для кода на С# — это должны быть MSBuild файлы, для С++ - СMake или Make файлы, для Java - Maven или Gradle файлы. Без подобных файлов с данными для сборки код, полученный в результате трансляции, собрать будет крайне сложно.

4.3 Неформальная классификация языков и платформ

Проведем неформальную (полу формальную) классификацию языков, чтобы показать, какие между ними есть отличия и какие могут быть трудности при трансляции с одного языка на другой язык; в том числе и точки зрения сохранения семантики безопасности (см. раздел 3.7). Далее будет рассмотрено несколько возможных разбиений множества языков на классы.

4.3.1 Подход к управлению памятью

По подходу к управлению памятью языки можно разделить на `managed` и `unmanaged` языки:

- `Managed` языки - примером таких языков являются С#, Java, Golang, Python и т.д. (надо сказать, что большинство языков в современном мире - `managed` языки). В этих языках реализован подход, что освобождением неиспользуемой памяти занимается среда выполнения с помощью такого подхода, как сборка мусора [39]. При таком подходе, большинство проблем с памятью (например, утечки памяти), которые свойственны `unmanaged` языкам, даже и не возникают. Тем не менее, даже в `managed` языках можно сделать утечку памяти: для этого, например, мы можем создавать новые объекты и складывать их в список с глобальной областью видимости и никогда из него не удалять объекты; в этом случае потребляемая память будет все время расти, сборщик мусора в освобождении памяти от таких объектов нам не поможет и в какой-то момент времени у нас закончится доступная нам память.

- Unmanaged языки - примером таких языков являются C, C++, Rust. В этих языках временем жизни объектов в памяти (в куче) управляет сам разработчик. Конечно, в более высокоуровневых языках (таких как C++ и Rust) есть средства, упрощающие это управление - такие как интеллектуальные указатели в C++ (*std::shared_ptr*, *std::weak_ptr*) и специальные типы в Rust (*std::boxed::Box*, *std::rc::Rc*, *std::sync::Arc*). Однако, все эти средства не спасают от того, что разработчик на ровном месте (если он будет не аккуратен) может получить утечку памяти - например, из-за проблемы циклических ссылок [40]. Есть также совершенно отличный от стандартного подхода, подход экосистемы Qt, когда родительский объект отвечает за время жизни дочерних объектов.

Следует сказать, что в managed языках тем не менее есть некоторые средства для ручного управления памятью: так, например, в языке C# можно создавать объекты и вручную освобождать память, занятую ими в unmanaged памяти, есть возможность создавать слабые (weak) ссылки [41]; в языке go lang есть возможность создавать “арены” в памяти и вручную управлять временем жизни объектов внутри такой арены; в языке Python есть два механизма управления объектами памяти - сборщик мусора и механизм подсчета ссылок (который используют для целей оптимизации) и т.п.

4.3.2 Статически и динамически типизированные языки

Один из подходов разделения языков по их типизации — это статически и динамически типизированные языки:

- Статически типизированные языки - примером таких языков является C++, C#, Java, Golang. У языков со статической типизацией тип любого выражения известен во время компиляции и не может быть изменен позже. Статическая типизация дает самый простой машинный код; к тому же многие ошибки исключаются уже на стадии компиляции.

- Динамически типизированные языки - примером таких языков являются Python, JScript, PHP. У языков с динамической типизацией отсутствует информация о типе любого выражения во время компиляции. Это приводит к тому, что программы, созданные на языках с динамической типизацией обычно менее производительны, чем соответствующие программы, созданные на языках со статической типизацией. К тому же, все те проверки, которые делает компилятор языка со статической типизацией, естественно отсутствуют для программы, созданной на языке с динамической типизацией. Поэтому, по-хорошему, эти проверки необходимо реализовать в виде тестов — это увеличивает кодовую базу и время выполнения (закрытия) задач и выпуска новой функциональности (новых версий кода).

Следует также отметить, что в некоторых языках с динамической типизацией появилась возможность аннотировать типы (так, например, в языке Python они называются `type hints`); эти аннотации никак не влияют на выполнение программы и предназначены исключительно для информирования разработчика. Поэтому вполне может произойти такая ситуация, когда эти аннотации типов говорят одно, а на самом деле типы объектов совсем другие.

4.3.3 Языки с сильной и слабой типизацией

Другой подход разделения языков по их типизации - языки с сильной и слабой типизацией:

- Языки с сильной (строгой) типизацией - примером таких языков являются F#, C#, Java, Python. У языков со строгой типизацией установлены достаточно жесткие правила по возможным преобразованиям типов, особенно не явным (В этом плане, одним из самых “строгих” языков программирования является F# - в нем даже расширяющее преобразование типов в большинстве случаев должно

быть явным). С другой стороны — это большой плюс таких языков: шаг влево - шаг вправо и уже компилятор не позволяет пользователю создать неожиданный для него результат; если пользователь хочет использовать какое-либо преобразование - он явно должен его использовать.

- Языки со слабой типизацией - примером таких языков являются JScript, PHP, C, C++. В языках со слабой типизацией компилятор (интерпретатор, JIT-компилятор) позволяет автоматически преобразовывать типы данных в широком диапазоне (а не только расширяющее преобразование данных). Так, например, в JScript можно сложить число со строкой `6 + "66"` и получить в результате строку `"666"` (а совсем не ошибку). Языки C и C++ такого, конечно, не позволяют, но у них есть возможность приведение объекта одного типа к объекту любого другого типа с помощью приведения типов языка C, либо оператора `reinterpret_cast` в языке C++ соответственно.

4.3.4 Парадигмы (стили), поддерживаемые языками

Существует множество парадигм, поддерживаемых теми или иными языками; взглянуть на классификацию языков с этой точки зрения стоит обязательно:

- Процедурная парадигма (процедурный стиль) - примерами таких языков являются C, Pascal, Fortran. Это императивный подход к программированию, при котором программа разбивается на процедуры и функции (или подпрограммы). Не смотря на все свои минусы, процедурный подход все еще широко используется в программировании, особенно при написании драйверов и скриптов (из-за своей простоты). Следует сказать, что многие современные языки поддерживают процедурную парадигму - к таким языкам относятся C++, Golang, Python; более того, даже такие ООП языки, как C# и Java,

фактически поддерживают данную парадигму - с помощью статических методов.

- ООП - примерами таких языков являются C#, Java, C++, Python, Kotlin. Это парадигма разработки, при которой во главу угла ставятся объекты - сущности, объединяющие данные (атрибуты) и код/поведение (методы). Следует, сказать, что это одна из основных парадигм современных языков программирования.
- Языки с неполной поддержкой ООП - примерами таких языков являются JScript, Golang, Rust. В JScript ООП реализовано через прототипы (прототип - это объект-образец, от которого другие объекты наследуют свойства и методы). В Golang есть частичная реализация ООП - в нем есть композиция типов и интерфейсы (возможность объявлять интерфейсы и их реализовывать), но нет наследования; при этом для интерфейсов язык Golang поддерживает утиную типизацию. В Rust используется система трейтов (trait) для полиморфизма и структуры (struct, impl) для инкапсуляции данных и поведения, но также нет наследования.
- Мультипарадигменные языки - большинство современных языков программирования являются мультипарадигменными (пускай некоторые парадигмы они реализуют и не полностью). Так, например, язык C# является ООП языком, при этом он позволяет писать код в процедурной парадигме (с помощью статических членов и классов), а также реализует многие концепции из функциональной парадигмы (лямбда функции, функции высшего порядка, pattern matching и т.п.); язык Python является ООП языком (с рядом ограничений), при этом он также позволяет писать код в процедурной парадигме, и точно также реализует многие концепции из функциональной парадигмы.

Мы упомянули здесь далеко не все парадигмы, используемые при создании языков программирования: есть еще и функциональная парадигма, и

метапрограммирование на этапе компиляции и ряд других парадигм. Все их мы рассматривать не будем; наша основная цель - показать насколько сильно могут различаться языки программирования, что это может повлиять как на сложность трансляции (вне зависимости от того, ручная это трансляция, автоматическая или с помощью LLM), так и на сохранение семантики безопасности при трансляции с одного языка на другой (например, смотри пример с потерей свойства безопасности “инкапсуляция” при трансляции с языка C# на язык Python - раздел 3.5)

4.4 Проблемы при трансляции кода и возможные пути их решения

После того, как мы сделали неформальную (полу формальную) классификацию языков, давайте рассмотрим примеры проблем (очевидно, что мы рассмотрим далеко не все возможные проблемы), которые могут возникать при трансляции кода с одного языка на другой и возможные методы их решения. Также мы поговорим о том, какие свойства безопасности могут при этих проблемах теряться.

4.4.1 Трансляция кода с *managed* языков на *unmanaged* языки

Основной проблемой, которая возникает при трансляции кода с *managed* языка на *unmanaged* язык — это проблема очистки памяти от неиспользуемых объектов. В *managed* языках этим занимается сборщик мусора: он обходит граф объектов, начиная с корней (глобальные переменные и переменные в стеке), помечает каждый посещенный объект, пока не обойдет их все; объекты, которые сборщик мусора при этом не обойдет (не пометит) считаются недостижимыми объектами и могут быть удалены. В *unmanaged* языках ничего такого нет - в них памятью либо вообще управляют вручную (как, например, в C), либо с помощью умных указателей на основе счетчика ссылок (*std::shared_ptr* в C++, *std::rc::Rc* в Rust). Умные указатели сильно упрощают жизнь по сравнению с ручным управлением памятью, но у них есть

один фундаментальный недостаток - они просто считают количество ссылок на данный объект и уничтожают его, когда оно равно 0. Соответственно, если два объекта связаны циклической ссылкой через умные указатели (т.е. когда объект А ссылается на объект В, а объект В ссылается на объект А), то эти два объекта никогда не будут удалены, даже если они ниоткуда больше не достижимы - и мы получим классическую утечку памяти. Решение такой проблемы заключается в том, что одна из ссылок должна быть сильной (через *std::shared_ptr*), а другая слабой (через *std::weak_ptr*). Однако правильная расстановка сильных и слабых ссылок совсем не тривиальная задача и далеко не всегда может быть выполнена автоматически. Особенно с учетом того факта, что многие структуры данных подразумевают внутри себя циклические зависимости: двунаправленный связанный список, дерево с ссылками на родителей (когда не только родители знают о своих детях, но и дети знают о своих родителях), граф. Рассмотрим, например, дерево с ссылками на родителей. Кажется, что наиболее естественный подход сделать сильными ссылки от родителей к детям, а ссылки от детей к родителям сделать слабыми. Это будет работать ровно до той поры, пока нам не понадобится метод, который возвращает какой-то узел дерева, и мы захотим из этого узла подниматься вверх к родительским узлам; это будет работать только тогда, когда мы сохраняем ссылку на корень дерева. Однако, на managed языках такое требование не обязательно - мы можем вернуть узел дерева не сохраняя ссылку на корень дерева и потом сможем с помощью этого узла подняться вверх до корня. Поэтому трансляция кода с managed языков на unmanaged языки должно уметь решать такие проблемы. При этом решение будет ручным - мы далеко не всегда можем выбрать в автоматическом режиме, какие ссылки делать сильными, а какие слабыми. Но и расстановка какие ссылки должны быть сильными, а какие слабыми тоже не всегда помогает - в некоторых случаях приходится “привязывать” время жизни родительского объекта ко

времени жизни дочернего объекта (как это происходит в managed языках) - очевидно, что это сильно усложняет процедуру трансляции.

Следует также сказать и об альтернативном подходе - использовании внешних (в виде внешних библиотек) сборщиков мусора в unmanaged языках. Например, для C++ есть консервативный сборщик мусора, реализованный в библиотеке Boehm-Demers-Weiser [42]; для Rust есть простой сборщик мусора rust-gc [43] и т.д. Плюсы этого подхода очевидны - код с managed языка на unmanaged язык в вопросах управления объектами транслируется один в один без каких-либо ухищрений. Но у этого подхода есть и очевидные минусы. Во-первых, сборка мусора — это всегда не детерминистический процесс в отличие от очистки памяти либо напрямую, либо с помощью умных указателей - мы не можем предсказать, в какой момент времени она произойдет. Во-вторых, все пользователи нашего кода должны быть использовать механизм, связанный со сборкой мусора, в том числе и для создания новых объектов. Это приемлемо, когда мы транслируем приложение; однако, когда мы транслируем библиотеку, то это накладывает слишком жесткие ограничения на ее пользователей.

Очевидно, что если мы транслируем код в unmanaged язык и используем либо обычные, либо умные указатели, то у нас есть потенциальные проблемы при работе с памятью: это либо утечки памяти (из-за проблемы циклических ссылок [40]), либо попытка использования памяти, которая уже удалена (из-за разного времени жизни объектов в исходном коде и коде, полученном в результате трансляции). Соответственно, в данном случае следующие свойства безопасности, связанные с консистентностью памяти могут быть утеряны (при неаккуратной трансляции): отсутствие утечек памяти, контроль за тем, чтобы удаленная память не использовалась и т.д.

Если же мы транслируем код в unmanaged язык и используем подход со сборкой мусора, то таких проблем практически нет (у сборщиков мусора могут быть иногда ложные срабатывания, что приводит к тому, что часть памяти

очищается позже, чем это ожидается, но это достаточно редкая ситуация, которая не приводит к утечке памяти). Однако у этого подхода есть свои минусы и его используют крайне редко.

4.4.2 Трансляция кода с unmanaged языков на managed языки

В данном случае все зависит от того, как происходит работа с памятью в unmanaged языках. Если используются обычные умные указатели, то делать ничего особо не нужно: даже не нужно расставлять сильные и слабые ссылки при формировании графа объектов. Однако, если используются, например, умные указатели с пользовательскими функциями удаления или, например, объекты с пользовательскими деструкторами (например, для реализации RAII [44]), то в данном случае трансляция становится гораздо сложнее, т.к. в managed языках деструкторов либо нет, либо они выполняются совсем не в тот момент времени, как это происходит в unmanaged языках. Однако, в большинстве современных managed языках есть специальные инструменты для очистки ресурсов - такие, как IDisposable в C#, менеджер контекста в Python - их и следует использовать.

Очевидно, что здесь есть потенциальные проблемы с утечками памяти в более сложных случаях, чем простое использование умных указателей и объектов без деструкторов; это означает, что свойство безопасности “отсутствие утечек памяти” может быть утеряно при неаккуратной трансляции.

4.4.3 Трансляция кода с динамически типизированных языков на языки со статической типизацией

У языков с динамической типизацией тип выражения неизвестен во время компиляции и становится известен во время выполнения. У языков же со статической типизацией тип каждого выражения должен быть известен на этапе компиляции. Это приводит к значительным трудностям при трансляции

кода с языка с динамической типизацией (например, Python) на язык со статической типизацией (например, C#). Вариантов решения этой проблемы два: или использовать специальные аннотации (type hints в Python) для аннотирования типов выражений в тех языках, где они есть, или попытаться самому восстановить возможные типы выражений.

Вариант с использованием специальных аннотаций прост - например, в том же языке Python аннотации типов отображаются в AST. Но у него есть следующие недостатки:

1) Никто не гарантирует (как компилятор в языках со статической типизацией), что аннотации типов корректные. Никто не мешает разработчику, на функцию, которая возвращает строку навесить аннотацию типа, что данная функция возвращает число; а компилятор эту ситуацию (в отличие от компилятора для языка со статической типизацией) никак не обрабатывает.

2) Никто не гарантирует, что ко всем объявленным функциям, переменным и членам классов будут добавлены аннотации. Никто не мешает разработчику, например, для какой-то из функций вообще не добавлять аннотации; а компилятор эту ситуацию (в отличие от компилятора для языка со статической типизацией) также никак не обрабатывает.

3) Обычно никто не добавляет аннотации для переменных и полей классов; поэтому даже если ко всем функциям добавлены полные и корректные аннотации это не решает поставленную задачу.

Вариант с восстановлением возможных типов для всех выражений состоит в следующем: мы с помощью компилятора строим AST; мы можем вычислить для всех листьев, которые соответствуют литералам их типы; мы также знаем типы для аргументов и возвращаемых значений для всех функций/методов базовой библиотеки и всех используемых библиотек. Обладая этой информацией, мы можем обойти дерево, начиная с указанных выше листьев и восстановить возможные типы для всех выражений. Основная

проблема в том, что для некоторых выражений невозможно однозначно восстановить его тип - возможно лишь восстановить множество типов, который может принять выражение. Так, например, возвращаемое значение следующей функции на Python

```
def do_something(source):
```

```
    if source == 1:
```

```
        return 666
```

```
    if source == 2:
```

```
        return "iddqd"
```

```
    return [13,13]
```

может быть либо целое число, либо строка, либо список. Другими словами, можно сказать, что возвращаемое значение является некоторый алгебраический тип данных (tagged union). Поэтому в языке, на который происходит трансляция кода должен быть некоторый тип для представления такого алгебраического типа - например, в C++ для этого служит тип `std::variant`. При этом код, полученный в результате трансляции, будет сложнее исходного - т.к. он должен поддерживать работу с экземплярами таких алгебраических типов.

Видно, что самая большая проблема при такой трансляции — это либо невозможность полностью восстановить используемые типы в автоматическом режиме (например, когда используется сторонняя библиотека, для которой у нас нет информации о типах/функциях), либо сложность восстановленной системы типов (когда у нас появляется много вариантных типов - алгебраический тип данных). Понятно, что такая ситуация является нормой для динамически типизированных языков программирования (например, для Python) в силу его природы, но для языков со статической типизацией это достаточно большая проблема. Как итог, при такой трансляции может быть утеряно такое свойство безопасности, как “логичность используемой системы типов” и даже, “безопасность системы типов”.

4.4.4 Трансляция кода с языков со статической типизацией на динамически типизированные языки

Трансляция кода с языков со статической типизацией на динамически типизированные языки обычно не представляет какую-либо проблему, кроме одной - ухудшение безопасности типов (нельзя сказать, что отсутствие, т.к. даже в динамических языках есть какая-то система проверки типов). Выражается это, например, в следующем: в языке со статической типизацией в параметр метода можно передать объект только вполне определенного типа - за этим следит компилятор; а вот в динамически типизированных языках в параметр метода можно передать любой объект - самое главное, чтобы он поддерживал операции, применяемые к нему внутри метода (например, вызовы методов).

Однако, свойство безопасности “безопасность системы типов” обычно является свойством класса L2, т.е. может быть более-менее просто симитировано (по крайней мере, при трансляции с языка C# на язык Python - см. раздел 3.5). Поэтому это не является особо большой проблемой.

Следует тут добавить следующее, отсутствие инкапсуляции и модификаторов доступа не является свойством динамически типизированных языков: в том же JavaScript есть инкапсуляция, а в PHP есть и инкапсуляция и модификаторы доступа; поэтому проблема отсутствия инкапсуляции и модификаторов доступа — это такой дизайн языка Python.

4.4.5 Трансляция кода с ООП языка на языки с частичной поддержкой ООП

При трансляции кода с ООП языка на язык с частичной поддержкой ООП (например, при трансляции кода с C# на Golang) может возникнуть ситуация, что часть концепций вообще никак не транслируется и это ухудшает безопасность кода, полученного в результате трансляции, в целом. Так, например, предположим, что исходный код был написан на C#, содержит

некоторую иерархию наследования классов и мы транслируем этот код на Golang. При трансляции, конечно, возникнет ряд проблем, т.к. Golang наследования не поддерживает. Для решения этих проблем, мы заменяем иерархию наследования при трансляции композицией, а также объявлением и реализацией интерфейсов. Однако, при таком подходе есть один принципиальный изъян - мы теряем модификаторы доступа. И если члены с публичным доступом (с модификатором доступа `public`) могут быть транслированы как экспортируемые, а члены с приватным доступом (с модификатором доступа `private`) могут быть транслированы (с очень большой натяжкой, т.к. внутри пакета инкапсуляция нарушается), как не экспортируемые, то при трансляции членов с защищенным доступом (с модификатором доступа `protected`) возникают проблемы. Они не могут быть не экспортируемыми, т.к. к ним должен быть доступ у всех производных классов, и они не могут быть экспортируемыми, т.к. к ним не должен быть доступ отовсюду. По итогу получается, что концепция защищенных членов (с модификатором доступа `protected`) отсутствует в коде, полученном в результате трансляции. Это не проблема, когда мы транслируем приложение (т.к. приложение является самодостаточным), но это является проблемой, когда мы транслируем библиотеку, которую будут использовать в других приложениях и библиотеках. Точно такие же проблемы будут, когда мы попытаемся транслировать, например, абстрактные классы: в исходном коде мы не можем создавать экземпляр абстрактного класса, а в коде после трансляции нам никто не мешает это сделать.

Следует также сказать, что подобные проблемы могут возникать и при трансляции между ООП языками. Так, например, в языке Python полностью отсутствуют модификаторы доступа: вместо них используется специальный подход к именованию объектов (имена `protected` членов должны начинаться с одного символа подчеркивания, имена `private` членов - с двух символов

подчеркивания) и механизма `name mangling` (искажение имени). Очевидно, что такой подход плохая замена модификаторам доступа.

В данном случае видно, что во многих случаях будут потеряны такие свойства безопасности как “поддержка инкапсуляция” (инкапсуляция теряется не всегда - в языке Rust, например, все члены структуры по умолчанию являются приватными) и “поддержка модификаторов доступа”. Оба эти свойства по классификации являются свойствами класса L3 (см. раздел 3.5); это означает, что никак отсутствие поддержки этих свойств со стороны языка, на который происходит трансляция, нам не симитировать.

4.4.6 Другие проблемы при трансляции между языками

Давайте кратко упомянем еще ряд проблем, возникающих при трансляции кода с одного языка на другой. К таким проблемам относятся:

- необходимость трансляции шаблонов и метапрограммирования в C++;
- необходимость трансляции макросов, механизмов заимствования и времени жизни в Rust;
- необходимость трансляции ряда функциональных концепций в языки, в которых их поддержка отсутствует (например, трансляция выражений `pattern matching` с языка C# на язык C++);
- необходимость трансляции асинхронных конструкций в языки, в которых их поддержка отсутствует.

Очевидно, что здесь перечислены не все проблемы. Одни эти проблемы вообще невозможно решить без полной переработки исходного кода, другие - могут приводить к потере ряда свойств безопасности, например, связанных с консистентностью работы с памятью. Мы не будем рассматривать все эти проблемы в рамках этой работы более подробно, но стоит помнить, что подобные (или даже другие) проблемы могут существовать для любой пары языков.

4.4.7 Вывод

После рассмотрения классификации языков программирования и проблем при трансляции с одного языка на другой можно сделать следующие выводы:

- Чем ближе языки друг к другу относительно их классификации (пусть и неформальной), тем легче производить трансляцию между этими языками. Близость языков друг к другу означает, что у них совпадает как минимум один класс, которому они принадлежат (чем больше, тем лучше). Идеальными языками, трансляцию между которыми достаточно легко реализовать, являются C# и Java: они оба являются managed и ООП языками со статической строгой типизацией и (т.е. совпадают по 4 классам).
- Наоборот, чем дальше языки друг от друга относительно их классификации (пусть и неформальной), тем сложнее производить трансляцию между этими языками. В некоторых случаях, даже разница в одном классе делает задачу трансляции достаточно сложной. Как, пример, трансляция из Python в C#: оба языка являются managed и ООП языками со строгой типизацией, только вот C# - язык со статической типизацией, а Python - динамически типизированный язык.
- При трансляции кода между языками, чем проще конструкция в исходном языке, тем проще ее транслировать. Точно так же, чем некоторая сущность в исходном языке как можно сильнее похожа на некоторую сущность в языке, на который происходит трансляция, тем проще трансляцию этой сущности осуществить (см. далее раздел 4.6).
- Если осуществить трансляцию некоторой сущности достаточно сложно, то проще не изобретать какой-либо сложный механизм, а либо изменить исходный код, либо при трансляции воспользоваться возможностью ручной кастомизации, например, тела метода. Примером такой сущности является ключевое слово *yield* в C#.

Можно выдвинуть следующую гипотезу: чем больше совпадают языки, между которыми происходит трансляция кода, друг с другом, тем больше свойств безопасности будут принадлежать классу L1 (см. раздел 3.5); чем дальше языки, между которыми происходит трансляция кода, друг от друга, тем больше свойств будут принадлежать классам L2 и L3 (см. раздел 3.5).

4.5 Проблема согласования АПИ между языками

Огромной проблемой при трансляции кода является несовпадение АПИ базовой библиотеки для исходного языка и для языка, на который происходит трансляция.

Проблемы здесь могут быть следующие:

1) Несовпадение имен функций, выполняющих одну и ту же задачу - в данном случае решение тривиально.

2) Несовпадение количества параметров функций и/или ожидаемых значений - здесь уже все несколько сложнее, т.к. при трансляции кода возможно понадобятся дополнительные шаги по преобразованию данных и/или созданию новых сущностей/объектов.

3) Вызов метода в исходном коде транслируется в последовательность шагов в коде, полученном в результате трансляции.

4) Аналога функциональности из исходного кода в коде, полученном в результате трансляции, нет (очень часто этим грешит C++, у которого стандартная библиотека достаточно бедна). В этом случае необходимо использовать некоторые внешние библиотеки — это усложняет, как саму процедуру трансляции (так как появляются внешние зависимости, которые нужно учитывать), так и увеличивает проблемы с безопасностью (так как внешние библиотеки часто бывают источником уязвимостей, который нужно учитывать и с которым нужно работать).

Решение этих проблем приводит к следующим сложностям при трансляции кода:

1) Если в исходном коде задана цепочка вызовов функций - например

```
T result = obj.Method1(...).Method2(...).Method3(...);
```

то далеко не факт, что в коде, полученном в результате трансляции, это тоже будет такой же по структуре цепочкой вызовов соответствующих функций. Отсюда следует вывод, что перед трансляцией подобную цепочку вызовов лучше всего упрощать (симплифицировать) - в данном случае разбивать; т.е. генерировать следующий код для приведенного выше примера:

```
T1 result1 = obj.Method1();  
T2 result2 = result1.Method2();  
T result = result2.Method3();
```

Несмотря на разбухание кода после такого разбиения и появления новых переменных (особенно, когда цепочка вызовов функций сразу же используется внутри другого выражения), это упростит структуру транслятора и структуру генерируемого кода и позволит избежать всяческих граничных случаев (например, с появлением некорректно работающего кода после трансляции).

2) Код транслятора, отвечающий за трансляцию АПИ базовой библиотеки будет самой большой частью в приложении для трансляции кода - так, например, если в исходном АПИ базовой библиотеки 1000 функций (что не очень много), то все эти 1000 функций приложение для трансляции кода должно уметь обрабатывать. Соответственно, на такой объем кода так просто не создать модульные тесты и не проверить вручную; это означает, что какое-то время эта часть транслятора будет проверена не самым лучшим образом.

Какие же есть подходы для согласования АПИ между двумя языками:

1) Как уже было написано выше - переложить одну часть работу по преобразованию АПИ на приложение для упрощения (симплификации) кода, а другую часть работы - на приложение для трансляции кода.

2) Сделать библиотеку (паттерн адаптер) для языка, на который происходит трансляция кода, которая бы копировала интерфейс АПИ базовой библиотеки исходного языка один в один. При этом реализовывалась бы вся необходимая функциональность через соответствующее АПИ базовой библиотеки языка, на который происходит трансляция кода. Плюсы этого подхода очевидны - не нужно упрощать код, связанный с цепочкой вызовов функций, и не нужно писать гигантский объем кода в приложении для трансляции кода, который бы преобразовывал вызовы АПИ базовой библиотеки - все вызовы были бы транслированы один в один. Минусы — это гигантская работа, которую необходимо выполнить (с учетом написания тестов и возможно ручного тестирования).

Следует сказать, что при первом подходе код по преобразованию вызовов АПИ базовой библиотеки можно добавлять инкрементально по мере необходимости, если для всех не поддерживаемых случаев генерировать ошибку.

4.6 Проблема сложности трансляции. Симплификация исходного кода как путь упрощения кода транслятора

Как уже говорилось выше - транслятор, это программа, реализующая фазу трансляции компилятора, в которой на шаге кодогенерации мы вместо генерирования последовательности инструкций, которые могут выполняться на целевой машине, будем генерировать сущности кода (типы, функции, операторы, выражения и т.п.) на некотором языке. Если предположить, что сложности с построением AST у нас нет (например, за нас это делает используемая нами библиотека, как, например, в Roslyn [36]), то основная работа транслятора — это генерация сущностей кода (типы, функции, операторы, выражения и т.п.) на некотором языке на основе полученной AST. Очевидно, что чем больше различных типов узлов AST должен обрабатывать транслятор, тем он будет сложнее (тем больше цикломатическая сложность

[45] транслятора). Это также приводит к тому, что такой транслятор крайне сложно как протестировать вручную, так и создать модульные тесты, которые бы покрывали все возможные случаи (все возможные потоки данных в трансляторе). С другой стороны, чем меньше различных типов узлов AST должен обрабатывать транслятор, тем он будет проще (тем меньше цикломатическая сложность [45] транслятора); в таком случае протестировать транслятор (все возможные потоки данных в трансляторе) будет проще: как с помощью ручного тестирования, так и с помощью модульных тестов.

Рассмотрим потенциальную сложность транслятора в случае, когда исходный язык — это C# и используется Roslyn [36] для построения и работы с AST (при этом язык, на который выполняется трансляция кода - Python). Если скомпилировать и запустить следующий код под .net9:

Листинг 7 – Подсчет количества типов узлов AST и разных значений перечисления SyntaxKind, определенных в Roslyn

```
Type[] knownNodeTypes = typeof(CSharpSyntaxNode)
    .Assembly
    .GetTypes()
    .Where(t => !t.IsAbstract && typeof(CSharpSyntaxNode).IsAssignableFrom(t))
    .OrderBy(t => t.Name)
    .ToArray();
SyntaxKind[] syntaxKindValues = Enum
    .GetValues(typeof(SyntaxKind))
    .Cast<SyntaxKind>()
    .ToArray();
Console.WriteLine($"Node types count = {knownNodeTypes.Length}");
Console.WriteLine($"SyntaxKind values count = {syntaxKindValues.Length}");
```

то можно получить следующий результат:

```
Node types count = 241
```

SyntaxKind values count = 561

Из этого можно сделать следующие выводы:

- Количество разных типов узлов AST, определенных в библиотеке Roslyn, равно 241.
- Количество разных значений перечисления *SyntaxKind*, определенных в библиотеке Roslyn, равно 561.
- Перечисление SyntaxKind определяет тип данных, содержащийся в узле AST. В Roslyn некоторые узлы могут содержать разные данные, тип которых как раз определяется значением SyntaxKind. Так, например, выражение `++i` в AST будет представлено узлом типа *PrefixUnaryExpressionSyntax* со значением типа данных *SyntaxKind.PreIncrementExpression*, а выражение `!flag` в AST будет представлено узлом типа *PrefixUnaryExpressionSyntax* со значением типа данных *SyntaxKind.LogicalNotExpression*. Т.е., в данном случае для обоих выражений используется один и тот же тип узла AST - *PrefixUnaryExpressionSyntax* с разными типами данных *SyntaxKind*.
- Как итог - максимальное количество случаев, которое необходимо уметь обрабатывать в трансляторе - 561. Очевидно, что это достаточно много.

Поэтому базовая идея для упрощения структуры транслятора следующая: давайте мы не будем обрабатывать все возможные случаи - все возможные комбинации типов узлов AST и типов данных *SyntaxKind*. Очевидно, что для этого нам нужен некоторый автоматизированный подход, т.к. просто договариваться, что мы не используем те или иные конструкции в исходном коде на C# достаточно “хрупкая” идея (хотя и такой подход используется в некоторых командах разработки).

Рассмотрим в качестве примера следующий фрагмент кода на языке C#, в котором мы создаем объект с помощью выражения `object initializer`:

Листинг 8 – Пример создания объекта на языке C# с помощью выражения `object initializer`

```

SomeData data = new SomeData
{
    Value1 = 666,
    Value2 = "IDDQD",
    Value3 = new ComplexData
    {
        Data1 = 777,
        Data2 = "IDKFA"
    }
};

```

Рассмотрим, также, эквивалентный упрощенный код на языке C#, в котором мы создаем тот же объект без помощи выражения object initializer:

Листинг 9 – Пример эквивалентного упрощенного кода на языке C# для создания объекта без помощи выражения object initializer

```

SomeData data = new SomeData();
data.Value1 = 666;
data.Value2 = "IDDQD";
data.Value3 = new ComplexData();
data.Value3.Data1 = 777;
data.Value3.Data2 = "IDKFA";

```

Эквивалентный упрощенный фрагмент кода выглядит чуть более многословным, но очевидно, что он намного проще исходного с точки зрения трансляции. Действительно, это фрагмент кода может практически один в один быть транслирован на многие языки, тогда как исходный фрагмент должен быть переработан перед трансляцией. Поэтому, один из подходов к упрощению структуры транслятора: это упрощение исходного кода к максимально простому уровню.

Рассмотрим в качестве другого примера следующее определение цикла **for** в языке C#:

Листинг 10 – Пример определения цикла **for** на языке C#

```
for (int index = 0; index < 100; ++index)
{
    SomeProcess(index);
}
```

AST этого цикла **for** (полученное с помощью метода *Dump*) будет выглядеть следующим образом:

Листинг 11 – Вид AST для цикла **for**, определенного на листинге 10

```
ForStatement
├─ForKeyword "for"
├─OpenParenToken "("
├─VariableDeclaration
│   ├─PredefinedType
│   │   └─IntKeyword "int"
│   └─VariableDeclarator
│       ├─IdentifierToken "index"
│       └─EqualsValueClause
│           ├─EqualsToken "="
│           └─NumericLiteralExpression
│               └─NumericLiteralToken "0"
├─SemicolonToken ";"
├─LessThanExpression
│   ├─IdentifierName "index"
│   └─LessThanToken "<"
└─NumericLiteralExpression
    └─NumericLiteralToken "100"
```

```

└─SemicolonToken ";"
└─PreIncrementExpression
| └─PlusPlusToken "++"
|   └─IdentifierName "index"
└─CloseParenToken ")"
└─Block
  └─OpenBraceToken "{"
  └─ExpressionStatement
    └─InvocationExpression
      └─IdentifierName "SomeProcess"
      └─ArgumentList
        └─OpenParenToken "("
        └─Argument
          └─IdentifierName "index"
          └─CloseParenToken ")"
        └─SemicolonToken ";"
      └─CloseBraceToken "}"

```

Давайте рассмотрим реализацию того же самого примера с помощью цикла **while**:

Листинг 12 – Пример определения цикла while на языке C#, эквивалентного определению цикла for на листинге 10

```

int index = 0;
while (index < 100)
{
    SomeProcess(index);
    ++index;
}

```

AST этого цикла **while** (полученное с помощью метода Dump) будет выглядеть следующим образом:

Листинг 13 – Вид AST для цикла while, определенного на листинге 12

```
LocalDeclarationStatement
├─VariableDeclaration
│  ├─PredefinedType
│  │  └─IntKeyword "int"
│  └─VariableDeclarator
│     ├─IdentifierToken "index"
│     └─EqualsValueClause
│        ├─EqualsToken "="
│        └─NumericLiteralExpression
│           └─NumericLiteralToken "0"
└─SemicolonToken ";"

WhileStatement
├─WhileKeyword "while"
├─OpenParenToken "("
├─LessThanExpression
│  ├─IdentifierName "index"
│  └─LessThanToken "<"
│     └─NumericLiteralExpression
│        └─NumericLiteralToken "100"
├─CloseParenToken ")"
└─Block
   ├─OpenBraceToken "{"
   └─ExpressionStatement
      └─InvocationExpression
         └─IdentifierName "SomeProcess"
```

```

| | └─ArgumentList
| |   └─OpenParenToken "("
| |     └─Argument
| |       └─IdentifierName "index"
| |         └─CloseParenToken ")"
| └─SemicolonToken ";"
└─ExpressionStatement
  └─PreIncrementExpression
    └─PlusPlusToken "++"
      └─IdentifierName "index"
        └─SemicolonToken ";"
          └─CloseBraceToken "}"

```

А теперь давайте рассмотрим реализацию той же самой функциональности на языке Python с помощью цикла **while** (в языке Python есть цикл **for**, но он является аналогом цикла **foreach** языка C#):

Листинг 14 – Пример реализации цикла **while** на языке Python, эквивалентного определению цикла **while** на языке C# из листинга 12

```

index = 0
while index < 100:
    some_process(index)
    index += 1

```

AST этого цикла **while** (полученное с помощью модуля *ast*) будет выглядеть следующим образом:

Листинг 15 – Вид AST для цикла **while**, определенного на листинге 14

```

Assign(
    targets=[Name(id='index', ctx=Store())],
    value=Constant(value=0)),

```

```

While(
  test=Compare(
    left=Name(id='index', ctx=Load()),
    ops=[Lt()],
    comparators=[Constant(value=100)]),
  body=[
    Expr(
      value=Call(
        func=Name(id='some_process', ctx=Load()),
        args=[Name(id='index', ctx=Load())])),
    AugAssign(
      target=Name(id='index', ctx=Store()),
      op=Add(),
      value=Constant(value=1)))]

```

Если сравнить AST решения на языке Python с AST двух эквивалентных решений на языке C#, то легко можно увидеть, что AST решения на Python очень похоже на AST решения на C# с помощью цикла **while**; и менее похоже на AST решения на C# с помощью цикла **for**. Очевидно, что из-за этой похожести, трансляцию на язык Python решения на языке C# с помощью цикла **while** реализовать проще, чем трансляцию решения на языке C# с помощью цикла **for**. Отсюда возникает следующая идея - давайте преобразовывать конструкции исходного языка так, чтобы их AST максимально возможно походила на AST некоторой конструкции языка, на который мы транслируем исходный код.

Давайте также вернемся к функциональным требованиям: когда мы разбирали работу с ними в разрезе процесса трансляции кода (см. раздел 1.9), то упоминали тот факт, что трансляция кода помимо этого должна учитывать изменение поведения тех или иных конструкций языка при трансляции. Так, например, порядок вычисления значений аргументов функций четко

определен в языке C# и менее четко определен в языке C++; поэтому при трансляции кода с C# на C++ этот момент надо учитывать, чтобы поведение исходного и кода, полученного в результате трансляции, совпадало. Следующие два фрагмента кода на C# полностью эквивалентны:

```
TResult result = SomeMethod(SomeMethod2(),  
                             SomeMethod3(),  
                             SomeMethod4());
```

и

```
TArg1 arg1 = SomeMethod2();  
TArg2 arg2 = SomeMethod3();  
TArg3 arg3 = SomeMethod4();  
TResult result = SomeMethod(arg1, arg2, arg3);
```

Однако, с точки зрения трансляции с языка C# на язык C++ второй фрагмент гораздо более прост - в трансляторе не надо делать преобразования, эквивалентные преобразованию первого фрагмента во второй. Отсюда возникает идея, что преобразования исходного кода, учитывающее возможные изменения в поведении кода, полученного в результате трансляции, также упрощают структуру транслятора.

Как итог - мы можем реализовать следующие преобразования исходного кода, которые упростят трансляцию, структуру транслятора, уменьшат потенциальные ошибки в трансляторе и увеличат покрытие транслятора тестами:

- Преобразование сложных конструкций, аналога которым нет в языке, на который производится трансляция, в более простые конструкции.
- Преобразование конструкций таким образом, чтобы их AST максимально была похожей на AST некоторых конструкций языка, на который производится трансляция.

- Преобразование конструкций с учетом возможного изменения поведения этих конструкций в языке, на который производится трансляция.

Симплификатор — это программа, которые эти преобразования кода на исходном языке реализует. В результате ее работы получается код также на исходном языке, но более простой для процедуры трансляции. Этот код точно также может быть скомпилирован, запущен, в нем могут быть запущены тесты. При этом, если мы применяем симплификатор перед трансляцией, то транслятору нужно обрабатывать далеко не все возможности языка (не все валидные комбинации разных типов узлов AST и разных значений перечисления *SyntaxKind*), что упрощает его структуру и цикломатическую сложность кода.

Здесь мы можем выдвинуть следующую, одну из центральных, гипотез - если симплификатор реализован корректно, то:

- правила симплификации могут быть спроектированы таким образом, чтобы сохранять семантику безопасности; корректность конкретного правила проверяется через функциональные тесты и сравнение отпечатка безопасности до и после упрощения;
- он уменьшает вероятность ошибки/дефекта в трансляторе из-за упрощения структуры и цикломатической сложности кода транслятора.

Симплификатор можно реализовать так, чтобы каждое упрощение исходного кода было независимо от других. При такой архитектуре, отдельные упрощения можно будет независимо включать и выключать, например, с помощью конфигурационного файла, что повышает его универсализм (возможность использования для разных пар языков перед трансляцией). Например, упрощение для фиксации порядка вычисления аргументов при вызове функций/методов нужно только при трансляции исходного кода на язык C++ и не нужно в других случаях.

4.7 Возможность ручного управления трансляцией

Далеко не все сущности в исходном коде может быть транслированы в автоматическом режиме без вмешательства разработчика - очень часто ему нужно вмешаться в процесс и сконфигурировать процесс трансляции: например, ему нужно поменять имя метода в коде, полученном в результате трансляции, указать, какие ссылки (например, при трансляции с кода на C# в код на C++) должны быть сильными, а какие слабыми, какой-то метод или даже фрагмент кода реализовать вручную и т.д. Соответственно, эту информацию нужно как-то передать в программу для трансляции кода. И тут есть несколько возможностей:

1) Добавление метаинформации в исходный код с помощью атрибутов (например, в C#). Плюсы этого подхода в том, что он поддерживается компилятором, легкий, информативный, всегда расположен рядом с сущностью, к которой он применяется. Минусы - не всеми языками поддерживается, в атрибуты можно передать только информацию, вычисляемую во время компиляции и не во всех случаях этот подход применим (например, если мы захотим реализовать часть метода вручную, то мы не сможем с помощью атрибутов сделать пометку внутри кода метода).

2) С помощью комментариев в коде, сформированных особым образом. Плюсы - можно использовать с любым языком и в любом месте (в том числе и в середине метода), всегда расположен с сущностью или с местом (если мы говорим о середине метода), к которому он применяется. Минусы - нужно соблюдать специальный формат (если в нем ошибиться, то не будет распознан), не поддерживается компилятором (для компилятора любой комментарий просто комментарий), для передачи сложных данных необходимо выполнять дополнительные шаги (например, десериализовать данные). Также стоит упомянуть, что обычно обработка комментариев в исходном коде более сложна, чем работа с обычными конструкциями языка.

3) В специальном конфигурационном файле с указанием номера строки сущности (начала сущности, либо начала и конца сущности в случае фрагмента кода). Плюсы - можно использовать с любым языком и для ссылки на любое место; т.к. все подобные определения находятся в одном файле, то легко увидеть общую картину. Минусы - Каждое такое определение находится не рядом с кодом, к которому оно применяется (для того, чтобы понять, применяется ли какое-либо определение к сущности или к блоку кода нужно смотреть в этот конфигурационный файл, что очень неудобно); определения, связанные с номерами строк очень хрупкие - стоит вставить даже пустую строку в файл и определения для этого файла после этой строки сразу же становятся недействительным.

Очевидно, что несмотря на все свои плюсы, подход с использованием конфигурационного файла самый хрупкий, в первую очередь из-за того, что даже случайное изменение исходного файла (например, добавление пустой строки) все может сломать.

4.8 Применимость методики трансляции

Следует сделать следующее важно замечание по рассматриваемой методике. Предлагаемая методика не является универсальным транслятором для произвольных языков. Универсальным является её контрольный каркас: выявление защитных инвариантов, построение отпечатка безопасности, классификация свойств (на классы L1–L4), выполнение трансляции, построение отпечатка безопасности целевого кода и сравнение результата. Конкретные правила трансляции, состав компенсирующих механизмов и принадлежность отдельных свойств к классам L1–L4 зависят от пары исходного и целевого языков. В рамках данной работы методика апробируется на следующей паре: исходный язык C# - целевой язык Python.

4.9 Общая последовательность шагов при трансляции

Давайте соберем все вместе и посмотрим, как должна выглядеть общая последовательность шагов при трансляции:

1) Анализ исходного кода на предмет наличия свойств безопасности. Мы можем его выполнять либо на основе исходного кода, либо с помощью AST, предварительно построив ее. Очевидно, если проводить такой анализ вручную, то его проще выполнять на основе исходного кода; если использовать какие-либо автоматизированные средства, то такой анализ проще выполнять на основе уже построенной AST. В результате этого анализа у нас будет список свойств безопасности (или отпечаток безопасности) для данного кода, который мы собираемся транслировать.

2) Классификация полученных свойств безопасности. Каждому свойству безопасности, полученному на предыдущем шаге (см. раздел 3.5), мы сопоставляем один из типы (классы) свойств безопасности L1-L4. Здесь класс L1 соответствует свойствам безопасности, которые автоматически сохраняются при трансляции; класс L2 соответствует свойствам безопасности, поддержка которых отсутствует в языке/платформе, на который мы транслируем код, но которые мы можем симитировать (с помощью дополнительного кода, генерируемого при трансляции); класс L3 соответствует свойствам безопасности, поддержка которых отсутствует в языке/платформе, на который мы транслируем код, и которые мы не можем симитировать (либо их имитация крайне сложна); класс L4 соответствует свойствам безопасности, поддержка которых отсутствует в исходном коде, но которые появляются в коде после трансляции, причем не важно из-за действий транслятора или из-за свойств языка/платформы.

3) После получения свойств безопасности исходного кода и их классификации необходимо принять решение устраивает ли нас то, как изменится набор свойств безопасности кода после его трансляции. А именно: устраивает ли нас, что свойства безопасности, которые принадлежат классу L3

будут потеряны; а также устраивает ли нас цена компенсирующих мер для свойств безопасности, которые принадлежат классу L2. Если ответ нет, то в данном случае мы прекращаем работы по трансляции кода на данном этапе; в данном случае, мы можем только менять исходный код так, чтобы нас устраивало изменение набора свойств безопасности кода после его трансляции (либо мы можем изменить подход к оценке, какие изменения набора свойств безопасности кода после его трансляции нас устраивают). Но даже переработка исходного кода не гарантирует, что удастся избавиться от утери того или иного свойства безопасности (которое принадлежит классу L3); так, например, при трансляции кода с языка C# на язык Python, как бы мы не пытались изменить исходный код на языке C#, мы все равно не сможем избавиться от утери свойства безопасности “инкапсуляция” (т.к. это связано с фундаментальными особенностями языка C#).

4) Упрощение исходного кода с помощью симплификатора. В результате получаем код на том же исходном языке, но который стал проще для процедуры трансляции (см. раздел 4.6). Полученный упрощенный код должен компилироваться; все тесты, которые были в исходном коде должны быть и в коде после симплификации и все эти тесты должны выполняться успешно (как и в исходном коде до симплификации). Если эти условия не выполняются, то мы считаем, что симплификация исходного кода выполняется неудачно - в этом случае необходимо исправлять, либо дорабатывать симплификатор.

5) Проверка гипотезы о том, что правила симплификации могут быть спроектированы таким образом, чтобы сохранять семантику безопасности (никак не меняют отпечаток безопасности для исходного кода). Это опциональный шаг, т.е. его выполнять совсем не обязательно. Если же в результате этого шага мы обнаруживаем, что семантика безопасности первоначального кода не сохраняется (т.е. происходит изменение отпечатка безопасности для исходного кода), то мы считаем, что симплификация

исходного кода выполняется неудачно - в этом случае необходимо исправлять, либо дорабатывать симплификатор.

6) Трансляция исходного кода с генерацией компенсирующих механизмов для сохранения свойств безопасности, которые принадлежат классу L2. На данном этапе происходит трансляция исходного кода с одного языка на другой. Во время этой трансляции происходит генерация компенсирующих механизмов для сохранения свойств безопасности, которые принадлежат классу L2. Так, например, если мы транслируем код с языка C# на язык Python и хотим, чтобы свойство безопасности “типобезопасность” было сохранено (это свойство безопасности принадлежит классу L2 - см. раздел 3.5), то именно в момент трансляции кода с языка C# на язык Python должны быть сгенерированы дополнительные проверки. После трансляции мы проверяем полученный код на предмет того, что он компилируется и все полученные (в результате трансляции) тесты выполняются успешно. Не для всех случаев необходимо проверять, что полученный в результате трансляции код компилируется; например, для случая трансляции кода с языка C# на язык Python, проверка кода, полученного в результате трансляции, на то, что он компилируется не нужна, т.к. Python — это преимущественно интерпретируемый язык, хотя при запуске кода на Python происходит Just-In-Time (JIT) компиляция для ускорения работы.

7) Анализ полученного в результате трансляции кода и построение набора свойств безопасности (отпечатка безопасности) для него. Также, как и для исходного кода (см. пункт 1), мы должны провести анализ полученного в результате трансляции кода. В результате этого анализа у нас будет список свойств безопасности (или отпечаток безопасности) для кода, полученного в результате трансляции.

8) Сравнение набора свойств безопасности (отпечатка безопасности) исходного кода и кода, полученного в результате трансляции. Мы сопоставляем два набора свойств безопасности (отпечатков безопасности), как

это описано в главе 3.3 и получаем результат их сравнения для дальнейшего анализа; причем мы можем сравнивать как агрегирующие наборы свойств безопасности (отпечатки безопасности), так и детализированные (и по всем результатам сравнения мы можем провести дальнейший анализ).

9) Анализ результатов сравнения наборов свойств безопасности (отпечатков безопасности) исходного кода и кода, полученного в результате трансляции. У нас есть классификация свойств безопасности относительно трансляции: согласно этой классификации, свойства безопасности, которые принадлежат классам L1 и L2 должны сохраняться. Соответственно, в первую очередь необходимо проверить именно это. Если это не так, то очевидно, что трансляция кода была выполнена не успешно, т.к. не были сохранены те свойства безопасности, которые должны быть сохранены. Также, с помощью анализа результатов сравнения, мы можем найти свойства безопасности, которые принадлежат классу L4 (см. раздел 3.5); это свойства безопасности, поддержка которых отсутствует в исходном коде, но которые появляются в коде после трансляции, причем не важно из-за действий транслятора или из-за свойств языка/платформы. Появление таких свойств безопасности мы обычно просто отслеживаем.

4.10 Корректность и полнота реализации транслятора

Следует сказать, что, когда мы говорим о классификации свойств безопасности (см. раздел 3.5) относительно трансляции, мы всегда предполагаем, что транслятор реализован корректно и его реализация является полной (например, с языка C# на язык Python). Под корректностью и полнотой реализации понимается следующее:

1) Транслятор должен создавать такой код, который удовлетворяет функциональным требованиям и соответствует поведению исходного кода (см. раздел 1.9).

2) Вся функциональность, определенная на исходном языке, может быть обработана и транслирована в соответствующие конструкции на языке, на который происходит трансляция. Этим мы сохраняем свойства безопасности кода, которые принадлежат классу безопасности L1.

3) Генерируются соответствующие компенсирующие механизмы (функциональность) для всех потенциальных свойств безопасности, которые принадлежат классу безопасности L2.

Если реализация трансляции в чем-то не является корректной и/или полной, то мы можем прийти к одной (или даже нескольким) из следующих ситуаций:

1) Полученный в результате трансляции код не удовлетворяет функциональным требованиям и/или не соответствует поведению исходного кода. В этом случае мы говорим о полном провале трансляции, останавливаемся и идем доделывать транслятор и/или симплификатор (для того, чтобы транслятору некоторые конструкции вообще не попадались - см. раздел 4.6).

2) Полученный в результате трансляции код теряет одно или несколько свойств безопасности, которые принадлежат классу безопасности L1 (но при этом удовлетворяет функциональным требованиям и соответствует поведению исходного кода). Так как такие свойства безопасности, которые принадлежат классу безопасности L1, не сохраняются при трансляции, то это мы считаем либо ограничением транслятора, либо ошибкой в его реализации.

3) Для одного или нескольких свойств безопасности, которые принадлежат классу безопасности L2, не генерируются соответствующие компенсирующие механизмы (функциональность) при трансляции исходного кода. Так как такие свойства безопасности, которые принадлежат классу безопасности L2, не сохраняются при трансляции, то это мы считаем либо ограничением транслятора, либо ошибкой в его реализации.

Таким образом, если у нас ситуация, когда код удовлетворяет функциональным требованиям и соответствует поведению исходного кода, но одно или несколько свойств безопасности, которые принадлежат классам L1 и L2, не сохраняются, то мы можем либо временно принять такую деградацию свойств безопасности и работать с кодом, полученном в результате трансляции, либо ждать доработок в трансляторе (такая ситуация возможна, например, когда транслятор активно разрабатывается и не вся необходимая функциональность уже реализована).

5 Реализация

5.1 Общие положения, принятые для реализации

Как уже говорилось выше (см. раздел 1.10), главная пара языков, на которой сконцентрировано внимание в данной работе — это C# и Python. В рамках данной работы мы главным образом будем изучать трансляцию кода, написанного на языке C#, в код на языке Python, и сохранение свойств безопасности при такой трансляции, а все остальные пары языков используются для примеров при обсуждении теории. Так как, исходным языком является C#, то для создания AST и работы с ней будет использоваться функциональность компилятора Roslyn [36]. Следует отметить, что AST, которую мы создаем с помощью компилятора Roslyn, является неизменяемым объектом, поэтому все попытки ее изменения всегда приводят к созданию новой AST.

При реализации функциональности для трансляции кода мы будем использовать Unix-like подход - когда для решения отдельной задачи создается отдельное приложение (отдельная утилита). В рамках данной работы это означает, что симплификатор и транслятор будут двумя разными приложениями (утилитами), каждое из которых при запуске должно будет создавать свой экземпляр AST для выполнения своей работы.

Также следует сказать следующее о процессе сбора свойств безопасности и формировании отпечатка безопасности (см. разделы 3.1 и 3.2) - в рамках данной работы мы это будем делать вручную, как для исходного кода, так и для кода, полученного в результате трансляции. Кажется, что этот процесс можно автоматизировать на основе получения AST для кода и последующего ее анализа, но это достаточно большая работа, которая заслуживает отдельного внимания.

5.2 Минимальная последовательность шагов для запуска трансляции

Минимальная последовательность шагов для трансляции кода с языка C# на язык Python имеет следующий вид:

1. Анализ исходного кода на предмет свойств безопасности. Может выполняться как вручную, так и с помощью автоматизированных средств. На данный момент выполняется вручную.
2. Анализ полученного набора свойств безопасности (отпечатка безопасности) исходного кода и предсказание итогового набора свойств безопасности (отпечатка безопасности) кода после трансляции.
3. Запуск симплификатора. На входе: проект с исходным кодом на языке C#. На выходе: проект с упрощенным кодом на языке C#.
4. Запуск транслятора. На входе: проект с упрощенным кодом на языке C#. На выходе: пакет с кодом, полученном в результате трансляции, на языке Python.
5. Анализ кода, полученного в результате трансляции, на предмет свойств безопасности. Может выполняться как вручную, так и с помощью автоматизированных средств. На данный момент выполняется вручную.
6. Сравнение ожидаемого набора (полученного на шаге 2) свойств безопасности (отпечатка безопасности), для кода после трансляции, с полученным набором свойств безопасности (отпечатка безопасности) в результате трансляции. Принятие решения об успехе или неудаче процесса трансляции.

5.3 Максимальная (полная) последовательность шагов для запуска трансляции

Максимально возможная последовательность шагов для трансляции кода с языка C# на язык Python имеет следующий вид:

1. Компиляция исходного кода, проверка на предупреждения (warnings).
Запуск тестов.
2. Запуск инструментов для анализа исходного кода и зависимостей: SAST, DAST, SCA.
3. Запуск утилиты для анализа исходного кода на возможность трансляции (не рассматривается в рамках данной работы, но используется в промышленном решении). Это дает возможность понять возможна ли трансляция еще до фазы самой трансляции. Например, если транслятор с языка C# на язык Python не поддерживает трансляцию ключевого **yield**, а оно есть в исходном коде на C#, то, очевидно, что трансляция будет неудачной. На входе: проект с исходным кодом на языке C#. На выходе: информация о том, возможна ли трансляция или нет.
4. Анализ исходного кода на предмет свойств безопасности. Может выполняться как вручную, так и с помощью автоматизированных средств. На данный момент выполняется вручную.
5. Анализ полученного набора свойств безопасности (отпечатка безопасности) исходного кода и предсказание итогового набора свойств безопасности (отпечатка безопасности) кода после трансляции.
6. Запуск симплификатора. На входе: проект с исходным кодом на языке C#. На выходе: проект с упрощенным кодом на языке C#.
7. Запуск утилиты для генерации обязательного кода, например, проверок входных аргументов публичных методов, если они отсутствуют (не рассматривается в рамках данной работы, но используется в промышленном решении). На входе: проект с упрощенным кодом на языке C#. На выходе: проект с упрощенным кодом на языке C# с возможными улучшениями кода.
8. Запуск транслятора. На входе: проект с упрощенным кодом на языке C# с возможными улучшениями кода. На выходе: пакет с кодом, полученном в результате трансляции, на языке Python.

9. Запуск инструментов для анализа кода, полученного в результате трансляции, и его зависимостей: SAST, DAST, SCA.

10. Анализ кода, полученного в результате трансляции, на предмет свойств безопасности. Может выполняться как вручную, так и с помощью автоматизированных средств. На данный момент выполняется вручную.

11. Сравнение ожидаемого набора (полученного на шаге 4) свойств безопасности (отпечатка безопасности), для кода после трансляции, с полученным набором свойств безопасности (отпечатка безопасности) в результате трансляции. Принятие решения об успехе или неудаче процесса трансляции.

5.4 Симплификатор. Детали реализации

Как уже говорилось выше (см. раздел 4.6), симплификатор — это программа, которая реализует ряд преобразований кода на исходном языке таким образом, что в итоге получается код также на исходном языке, но более простой для процедуры трансляции. Для этого симплификатор получает AST исходного кода, анализирует ее, модифицирует, если это необходимо и восстанавливает обратно код из AST; если в результате работы симплификатора было выполнено какие-либо изменения AST, эти изменения попадут в код в момент восстановления кода обратно из AST.

Как уже говорилось выше (см. раздел 5.1), AST, которые мы создаем с помощью компилятора Roslyn, являются неизменяемыми объектами, поэтому любое изменение AST реализуется через создание нового объекта AST на базе AST до изменений и соответственно, самих изменений (реализуется это с помощью функциональности, реализованной в классах *Microsoft.CodeAnalysis.CSharp.CSharpSyntaxRewriter* и *Microsoft.CodeAnalysis.Editing.DocumentEditor*). Может возникнуть вопрос, что если мы на каждое изменение пересоздаем AST, то такой подход может занимать очень много времени. Здесь есть одна хитрость: мы можем

обрабатывать проект с исходным кодом на C# пофайлово и создавать AST только для текущего обрабатываемого файла (если у нас в коде нет partial-классов [46]); вся остальная информация о типах и методах, которой нет в AST для текущего обрабатываемого файла, получается из информации о семантической модели, которая создается при компиляции проекта. Поэтому получается, что многократные изменения AST для текущего обрабатываемого файла не так уж сильно влияют на общее время работы симплификатора.

Давайте рассмотрим возможные варианты изменений в AST в рамках симплификации и как они влияют на процесс обработки AST при симплификации:

1) Замена некоторого узла в AST на другой узел, который будет принадлежать измененной AST (т.е. в пропорции 1:1). Это самый простой случай, который реализуется с помощью создания класса, родителем которого является класс *Microsoft.CodeAnalysis.CSharp.CSharpSyntaxRewriter*, перегрузки методов, соответствующих типу узлов AST, которые необходимо заменить и возврат из этих методов новых узлов, если замену для данного узла необходимо сделать. С помощью такого подхода можно заменить оператор *nameof* на его значение в виде строкового литерала.

2) Замена одного множества узлов в AST на другое множество узлов в AST (т.е. в пропорции M:N). Это более сложный случай замены, при котором нужно сначала найти исходные узлы, потом создать новые узлы, после чего создать новую AST с заменой исходных узлов на новые с помощью методов класса *Microsoft.CodeAnalysis.Editing.DocumentEditor*. С помощью такого подхода можно упростить такую функциональность, как объявление **out** переменной внутри метода. Другими словами преобразовать, например, такой вызов метода (фрагмент кода на языке C#):

```
SomeMethod(value1, value2, out int i);
```

в следующий набор конструкций:

```
int i;  
SomeMethod(value1, value2, out i);
```

В данном примере, нам необходимо преобразовать один узел AST - вызов метода *SomeMethod* в два узла AST - объявление переменной *i* и вызов метода *SomeMethod* (т.е. преобразование узлов в пропорции 1:2).

3) Замены, которые приводят к созданию новых сущностей в AST (типы, члены классов). Основная проблема в этом варианте изменений в том, что информации о семантической модели ничего не знает об этой новой сущности. Поэтому, после создания этой новой сущности необходимо либо пересоздавать семантическую модель (т.е. перекомпилировать проект), либо кэшировать информацию о новых сущностях где-то отдельно. К счастью, изменения этого типа приходится делать редко при симплификации исходного кода.

Симплификатор реализован в виде отдельных, независимых задач по симплификации, которые упрощают отдельные конструкции в исходном коде независимо друг от друга. За счет этого можно гибко конфигурировать симплификатор: включать и выключать отдельные задачи на симплификацию в зависимости от того, какие конструкции и функциональность необходимо упростить (например, в зависимости от языка, на который будет производиться дальнейшая трансляция). Таким образом, симплификатор получается достаточно универсальным инструментом.

На данный момент созданы следующие задачи на симплификацию в рамках симплификатора (см. таблица 6):

Таблица 6 – Существующие задачи на симплификацию

Задача на симплификацию	Описание
Выражения nameof	Заменяет выражение <i>nameof(name)</i> на выражение <i>"name"</i> .

	Построена на основе подхода 1. По умолчанию включена.
Интерполяция строк	Заменяет выражения интерполяции строк на вызовы метода <i>System.String.Format</i>. Построена на основе подхода 1. По умолчанию выключена (т.к. используется для трансляции кода с языка C# на язык Python для версий младше 3.6).
Инициализаторы объектов	Заменяет выражения, использующие инициализаторы объектов более простыми версиями. Построена на основе подхода 2. По умолчанию включена.
Объявление out переменной внутри метода	Выносит объявление out переменной за пределы метода. Построена на основе подхода 2. По умолчанию включена.
Null-conditional операторы ?. и ?[]	Заменяет выражения, использующие Null-conditional операторы более простыми версиями. Построена на основе подхода 2. По умолчанию включена.
Преобразователь циклов for в циклы while	Преобразует циклы for (циклы for в языке Python являются аналогом циклов foreach в языке C#) в циклы while. Построена на основе подхода 2. По умолчанию включена.

5.5 Транслятор. Детали реализации

Как уже говорилось выше (см. раздел 4.2 и раздел 5.1), транслятор — это программа, которая преобразует код, написанный на языке C#, в код, написанный на языке Python. Для этого транслятор получает AST исходного кода, анализирует ее, после чего на основе результатов анализа генерирует код на языке Python, оформляя его в виде модулей и пакетов на основе имен файлов с исходным кодом на C# и используемых в этом исходном коде пространств имен.

При этом нам приходится решать ряд технических задач, т.к. между языками Python и C# нет полной совместимости. Давайте рассмотрим некоторые из них.

5.5.1 Проблема с перегруженными методами

В языке C# есть поддержка перегруженных методов; в языке Python такой поддержки нет. Это является серьезной проблемой при реализации транслятора, поэтому ее необходимо уметь решать. Перегруженными называются методы, которые определены в одном классе, имеют одинаковые имена, но разные сигнатуры. Соответственно, с перегруженными методами есть две проблемы, которые необходимо уметь решать: это выбор лучшей (наиболее подходящей) перегрузки и обработка ситуаций, когда выбор между перегруженными методами неоднозначен. Давайте рассмотрим следующий пример на C#:

Листинг 16 – Исходный код примера на языке C# с демонстрацией проблемы с перегруженными методами

```
namespace SomeNamespace
{
    public class ClassA
    {
```

```

    }
    public class ClassB : ClassA
    {
    }
    public class Program
    {
        public static void M(String obj)
        {
            Console.WriteLine("In M(String)");
        }
        public static void M(ClassA obj)
        {
            Console.WriteLine("In M(ClassA)");
        }
        public static void M(ClassB obj)
        {
            Console.WriteLine("In M(ClassB)");
        }
        public static void Main(string[] args)
        {
            M("");
            M(new ClassA());
            M(new ClassB());
            //M(null);
        }
    }
}

```

Если мы запустим этот код, то на экране увидим следующее:

In *M(String)*

In *M(ClassA)*

In *M(ClassB)*

Видно, что для вызова *M("")* компилятор C# выбирает перегруженную версию *M(String)*, для вызова *M(new ClassA())* компилятор C# выбирает перегруженную версию *M(ClassA)*, для вызова *M(new ClassB())* компилятор C# выбирает перегруженную версию *M(ClassB)*, а вот для вызова *M(null)* компилятор C# выбрать перегруженную версию метода *M* не может (именно поэтому этот вызов закомментирован, т.к. в противном случае мы бы получили ошибку компиляции).

Для решения этой проблемы с перегруженными методами на языке Python мы будем делать следующее:

1. Если метод в коде на языке C# не является перегруженным, то мы его транслируем как есть - т.е. с обычными обязательными позиционными аргументами; имена этих аргументов в коде на языке Python совпадают с именами аргументов в исходном коде на языке C# (см. раздел 5.5.3).

2. Если два или три метода в коде на языке C# являются перегруженными, но имеют разные модификаторы доступа (*public*, *protected*, *private*), то из-за изменения имен методов с модификаторами доступа *protected* и *private* в языке Python (см. раздел 5.5.3), такие методы перестают быть перегруженными.

3. В остальных случаях перегруженные методы есть. Предположим, что в исходном коде на языке C# у класса *ClassA* есть несколько перегруженных методов с именем *SomeMethod* и одним модификатором доступа - для простоты пусть это будет *public*. В этом случае, в коде на Python у класса *ClassA* мы определим только один метод с именем *SomeMethod*, с переменным количеством позиционных аргументов (**args*), а мы будем проверять по этим позиционным аргументам все возможные комбинации, соответствующие перегруженным методам. При этом нам нужно решить две задачи (как

говорилося вище): вибір кращої (найбільш підходящої) перегрузки і обробка ситуацій, коли вибір між перегруженими методами неоднозначен. Перша задача вирішується з допомогою сортування всіх комбінацій типів аргументів, по яким проводиться пошук, при цьому комбінації з більш конкретними типами аргументів повинні йти раніше комбінації з більш загальними типами аргументів. Друга задача — це переконатися, що краща (найбільш підходяща) перегрузка тільки одна. Розглянемо ще раз наведений вище приклад: для виклику *M(new ClassB())* підходять наступні перегружені версії функції *M* - *M(ClassA)* і *M(ClassB)*, але компілятор С# вибирає *M(ClassB)*, т.к. вона підходить краще (т.к. тип аргумента найбільш близький до типу значення). Для виклику *M(null)* уже підходять всі перегружені версії функції *M* - *M(String)*, *M(ClassA)* і *M(ClassB)*, причому кращими (найбільш підходящими) перегрузками є дві - *M(String)*, і *M(ClassB)*; в цьому випадку компілятор С# вибрати перегружену версію методу *M* не може. Друга задача трохи більш складна, ніж перша, тому для простоти в межах даної роботи ми її вирішувати не будемо (т.к. її рішення нам принципово нічого нового не дасть), хоча в промисловому коді вона успішно вирішується. Тому для властивості безпеки “правильна обробка перегружених методів” значення буде рівно “підтримується частково” (див. розділ 3.2).

Давайте ще раз повернемося до наведеному вище прикладу і покажемо, як він буде виглядати після трансляції на мову Python:

Листинг 17 – Результат трансляції прикладу на мову Python з збереженням підтримки перегружених методів

```
class ClassA:
    pass
class ClassB(ClassA):
    pass
```

```

class Program:
    @staticmethod
    def M(*args):
        if (len(args) == 1) and ((args[0] is None) or isinstance(args[0], str)):
            print("In M(String)")
            return
        if (len(args) == 1) and ((args[0] is None) or isinstance(args[0], ClassB)):
            print("In M(ClassB)")
            return
        if (len(args) == 1) and ((args[0] is None) or isinstance(args[0], ClassA)):
            print("In M(ClassA)")
            return
        raise ValueError("Unknown combination of arguments")
    @staticmethod
    def Main(args):
        Program.M("")
        Program.M(ClassA())
        Program.M(ClassB())
        Program.M(None)
        #Program.M(666)
if __name__ == "__main__":
    Program.Main([])

```

Если мы запустим этот пример, то мы увидим следующий вывод на экране:

```

In M(String)
In M(ClassA)
In M(ClassB)
In M(String)

```

Видно, что наша реализация на Python для перегруженного метода *M* выбирает лучший (наиболее подходящий) вариант для обработки аргументов в тех случаях, когда неоднозначности нет (точно так же, как это работает и в исходном коде на языке C#); однако, когда есть неоднозначность, в реализации на Python происходит выбор первого подходящего варианта, тогда как в исходном коде на языке C# будет ошибка компиляции (именно поэтому для свойства безопасности “правильная обработка перегруженных методов” значение будет равно “поддерживается частично”). Также стоит обратить внимание на закомментированный вариант вызова метода *M* с неподдерживаемым типом значения (в данном случае — это целое число 666); в этом случае мы получим ошибку при вызове метода *M* (что эквивалентно поведению исходного кода на языке C# - здесь мы получим ошибку времени компиляции).

4. Еще следует сказать о такой проблеме, как перегрузка, например, по разным числовым типам. В языке Python только два числовых типа - **int** для целых чисел и **float** для действительных чисел. Поэтому мы не сможем транслировать с языка C# на язык Python, например, две перегрузки только по целочисленным типам. В данной работе в таком случае мы будем генерировать ошибку во время трансляции, но в промышленном коде можно выбирать, например, перегрузку для самого большого целочисленного типа и транслировать только ее (либо конфигурировать трансляцию таких ситуаций вручную - см. раздел 4.7).

5.5.2 Проблема согласования АПИ между языками

В данной реализации транслятора мы используем подход с созданием библиотеки (паттерн адаптер) для языка Python (на который происходит трансляция кода), чтобы она копировала интерфейс .NET Framework (базовой библиотеки для языка C#) один в один (см. раздел 4.5). Однако для ряда типов сделано исключение и вместо использования реализаций из библиотеки

адаптера используются нативные типы языка Python. Описание соответствия между типами языка C# и типами языка Python приведено в следующей таблице (таблица 7):

Таблица 7 – Соответствие между типами языка C# и типами языка Python

Тип для языка C#	Тип для языка Python
System.Boolean	bool
Все целочисленные числовые типы: System.SByte, System.Byte и т.д.	int
Все типы действительных (вещественных) чисел: System.Single, System.Double и т.д.	float
Строки: System.String	str
Символы: System.Char	str
Массивы	list
System.Object	object
Все остальные типы	Соответствующий тип из библиотеки адаптера

Так, например, для типа ***System.Text.StringBuilder*** языка C# будет создан тип ***StringBuilder*** в пакете ***system.text*** для языка Python.

5.5.3 Правила именования объектов

У языка Python есть ключевой документ, регламентирующий правила именования объектов в Python - PEP 8 - Style Guide for Python Code [47]. И в коммерческих системах трансляции кода с языка C# на язык Python мы должны придерживаться этого набора правил. Однако, этот набор правил ничего нам не дает для нашей проблемы сохранения набора свойств безопасности (отпечатка безопасности) при трансляции кода с языка C# на язык Python, но при этом усложняет код транслятора, т.к. при этом нам нужно

хранить информацию для всего транслируемого проекта о соответствии между именами сущностей для языка C# и именами сущностей для языка Python. Поэтому для транслятора, который применяется в данной работе, мы не будем придерживаться этого набора правил и будем использовать следующий очень простой набор правил, который приведен в следующей таблице (таблица 8):

Таблица 8 – Набор правил для именования объектов

Имя сущности для языка C#	Имя сущности для языка Python
Пространство имен - например, System.Text	Имя пакета в нижнем регистре - например, system.text
Член класса с модификатором доступа protected - например SomeMethod	Член класса, имя которого начинается с одного подчеркивания, после чего следует оригинальное имя без изменений - например, _SomeMethod
Член класса с модификатором доступа private - например SomeMethod	Член класса, имя которого начинается с двух подчеркиваний, после чего следует оригинальное имя без изменений - например, __SomeMethod
Все остальные случаи	Оригинальное имя без изменений

6 Эксперимент

Перед проведением эксперимента важно сказать следующее. В рамках данной работы реализован собственный исследовательский прототип симплификатора для исходного кода на языке C# и транслятора исходного кода с языка C# на язык Python. При этом предложенная методика может использоваться не только как основа собственного транслятора, но и как контрольный слой для анализа результатов ручной, полуавтоматической, автоматической трансляции кода или трансляции кода с помощью LLM.

В качестве эксперимента мы будем сравнивать трансляцию кода, приведенного ниже, с языка C# на язык Python с помощью следующих подходов:

- 1) Автоматическая трансляция с помощью симплификатора и транслятора
- 2) Ручная трансляция, как это обычно делается при разработке.
- 3) Автоматическая трансляция с помощью LLM.

6.1 Исходный код

Исходный код, с которым мы будем работать (проводить эксперимент) выглядит следующим образом (это упрощенная и переработанная часть кода реального проекта для работы с графическими примитивами):

Листинг 18 – Исходный код на языке C# для проведения эксперимента

```
namespace ExperimentExample1
{
    public abstract class Step
    {
        protected abstract Boolean Check();
        public abstract String GetRepresentation();
    }
}
```

```

public class Move : Step
{
    public Move(Int32 xPosValue, Int32 yPosValue)
    {
        xPos = xPosValue;
        yPos = yPosValue;
    }
    protected override Boolean Check()
    {
        return (xPos >= 0) && (yPos >= 0);
    }
    public override String GetRepresentation()
    {
        if (!Check())
            throw new InvalidOperationException("Bad data");
        return $"move({xPos},{yPos})";
    }
    private readonly Int32 xPos;
    private readonly Int32 yPos;
}

public class Color : Step
{
    public Color(String colorValue)
    {
        color = colorValue;
    }
}

```

```

protected override Boolean Check()
{
    return (color != null) && (color.Length > 0);
}
public override String GetRepresentation()
{
    if (!Check())
        throw new InvalidOperationException("Bad data");
    return $"color({color})";
}
private readonly String color;
}

public class Point : Step
{
    public Point(Int32 xPosValue, Int32 yPosValue)
    {
        xPos = xPosValue;
        yPos = yPosValue;
    }
    protected override Boolean Check()
    {
        return (xPos >= 0) && (yPos >= 0);
    }
    public override String GetRepresentation()
    {
        if (!Check())
            throw new InvalidOperationException("Bad data");
    }
}

```

```

        return $"point({xPos},{yPos})";
    }
    private readonly Int32 xPos;
    private readonly Int32 yPos;
}

public class Rectangle : Step
{
    public Rectangle(Int32 xLeftValue, Int32 yTopValue, Int32
xRightValue,Int32 yBottomValue)
    {
        xLeft = xLeftValue;
        yTop = yTopValue;
        xRight = xRightValue;
        yBottom = yBottomValue;
    }
    public Rectangle(Int32 xLeftValue, Int32 yTopValue, Int32 size)
    {
        xLeft = xLeftValue;
        yTop = yTopValue;
        xRight = xLeftValue + size;
        yBottom = yTopValue + size;
    }
    protected override Boolean Check()
    {
        return (xLeft >= 0) && (yTop >= 0) && (xRight >= 0) && (yBottom >= 0)
&& (xRight > xLeft) && (yBottom > yTop);
    }
}

```

```

public override String GetRepresentation()
{
    if (!Check())
        throw new InvalidOperationException("Bad data");
    return $"rectangle({xLeft},{yTop},{xRight},{yBottom})";
}

private readonly Int32 xLeft;
private readonly Int32 yTop;
private readonly Int32 xRight;
private readonly Int32 yBottom;
}

public class Circle : Step
{
    public Circle(Int32 xCenterValue, Int32 yCenterValue, Int32 radiusValue)
    {
        xCenter = xCenterValue;
        yCenter = yCenterValue;
        radius = radiusValue;
    }

    protected override Boolean Check()
    {
        Int32 minX = xCenter - radius;
        Int32 minY = yCenter - radius;
        return (xCenter >= 0) && (yCenter >= 0) && (radius > 0) && (minX >= 0)
&& (minY >= 0);
    }

    public override String GetRepresentation()

```

```

    {
        if (!Check())
            throw new InvalidOperationException("Bad data");
        return $"circle({xCenter},{yCenter},{radius})";
    }
    private readonly Int32 xCenter;
    private readonly Int32 yCenter;
    private readonly Int32 radius;
}

public class StepStorage
{
    public StepStorage()
    {
        steps = new List<Step>();
    }
    public IList<Step> GetSteps()
    {
        return steps;
    }
    public void AddMove(Move move)
    {
        if (move == null)
            throw new ArgumentNullException("move");
        steps.Add(move);
    }
    public void AddMove(Int32 x, Int32 y)
    {

```

```

        steps.Add(new Move(x, y));
    }
    public void AddColor(Color color)
    {
        if (color == null)
            throw new ArgumentNullException("color");
        steps.Add(color);
    }
    public void AddColor(String color)
    {
        if (color == null)
            throw new ArgumentNullException("color");
        steps.Add(new Color(color));
    }
    public void AddPoint(Point point)
    {
        if (point == null)
            throw new ArgumentNullException("point");
        steps.Add(point);
    }
    public void AddPoint(Int32 x, Int32 y)
    {
        steps.Add(new Point(x, y));
    }
    public void AddRectangle(Rectangle rectangle)
    {
        if (rectangle == null)
            throw new ArgumentNullException("rectangle");
    }

```

```

        steps.Add(rectangle);
    }
    public void AddRectangle(Int32 xLeft, Int32 yTop, Int32 xRight, Int32
yBottom)
    {
        steps.Add(new Rectangle(xLeft, yTop, xRight, yBottom));
    }
    public void AddRectangle(Int32 xLeft, Int32 yTop, Int32 size)
    {
        steps.Add(new Rectangle(xLeft, yTop, size));
    }
    public void AddCircle(Circle circle)
    {
        if (circle == null)
            throw new ArgumentNullException("circle");
        steps.Add(circle);
    }
    public void AddCircle(Int32 xCenter, Int32 yCenter, Int32 radius)
    {
        steps.Add(new Circle(xCenter, yCenter, radius));
    }
    private IList<Step> steps;
}

public interface IPainter
{
    void Paint(IList<Step> steps);
}

```

```

public class SimplePainter : IPainter
{
    public void Paint(ICollection<Step> steps)
    {
        if (steps == null)
            throw new ArgumentNullException("steps");
        foreach (Step step in steps)
        {
            Console.WriteLine(step.GetRepresentation());
        }
    }
}

public class Program
{
    public static void Main(String[] args)
    {
        StepStorage storage = new StepStorage();
        storage.AddMove(3, 5);
        storage.AddColor("red");
        storage.AddPoint(10, 10);
        storage.AddMove(100,100);
        storage.AddRectangle(12,14,55);
        storage.AddCircle(16,16,13);
        IPainter simplePainter = new SimplePainter();
        simplePainter.Paint(storage.GetSteps());
    }
}

```

```
}  
}
```

Давайте проведем анализ этого кода и найдем его свойства безопасности (и, сразу классифицируем их - см. раздел 3.5):

- Проверка входных аргументов; это свойство безопасности принадлежит классу L1.
- Сильная гарантия состояния программы к возникновению исключений; это свойство безопасности принадлежит классу L1.
- Корректная работа с абстрактными типами и методами - невозможность создания объекта абстрактного типа и вызова абстрактного метода; это свойство безопасности принадлежит классу L1, т.к., мы и не можем создать экземпляр абстрактного класса в языке Python и тем самым не можем вызвать абстрактный метод.
- Типобезопасность (т.е. невозможность передачи объектов другого типа в качестве параметра метода или возвращаемого значения); это свойство безопасности принадлежит классу L2 (см. раздел 3.5).
- Корректная поддержка перегруженных методов; это свойство безопасности принадлежит классу L2, т.к. в самом языке Python перегрузка методов не поддерживается.
- Инкапсуляция и поддержка модификаторов доступа; это свойство безопасности принадлежит классу L3 (см. раздел 3.5).
- Поддержка readonly полей: это свойство безопасности принадлежит классу L3.

Также, у нас есть следующие функциональные и нефункциональные требования (помимо сохранения свойств безопасности, принадлежащих классам L1 и L2):

- Поведение кода, полученного в результате трансляции, должно полностью совпадать с поведением исходного кода.

- Интерфейс кода (интерфейс типов), полученного в результате трансляции, должен по максимуму совпадать с интерфейсом исходного кода. Допускается только изменение имен методов с модификаторами доступа `protected` и `private` в соответствии с правилами языка Python.

Данный исходный код является законченной консольной программой; это было сделано для простоты проверки его работоспособности. В результате работы этого исходного кода мы получаем следующий результат (на который будем ориентироваться при проверке работоспособности кода, полученного в результате трансляции):

```
move(3,5)
color(red)
point(10,10)
move(100,100)
rectangle(12,14,67,69)
circle(16,16,13)
```

6.2 Результат трансляции кода с использованием симплификатора и транслятора

В первую очередь рассмотрим, что же у нас получается, если транслировать исходный код с помощью симплификатора и транслятора: Листинг 19 – Результат трансляции на язык Python с применением описываемой методики (с помощью симплификатора и транслятора)

```
# -*- coding: utf-8 -*-

import system
import system.collections.generic
import abc
```

```

class Step(abc.ABC):
    def __init__(self):
        raise system.InvalidOperationException("Abstract method call")

    @abc.abstractmethod
    def _Check(self):
        raise system.InvalidOperationException("Abstract method call")

    @abc.abstractmethod
    def GetRepresentation(self):
        raise system.InvalidOperationException("Abstract method call")

class Move(Step):
    def __init__(self, xPosValue, yPosValue):
        self.__xPos = 0
        self.__yPos = 0
        if isinstance(xPosValue, int) and isinstance(yPosValue, int):
            self.__xPos = xPosValue
            self.__yPos = yPosValue
        else:
            raise system.InvalidOperationException("Unrecognized combination of
arguments")

    def _Check(self):
        return (self.__xPos >= 0) and (self.__yPos >= 0)

```

```

def GetRepresentation(self):
    if not self._Check():
        raise system.InvalidOperationException("Bad data")
    return f"move({self.__xPos},{self.__yPos})"

class Color(Step):
    def __init__(self, colorValue):
        self.__color = ""
        if (isinstance(colorValue, str) or colorValue is None):
            self.__color = colorValue
        else:
            raise system.InvalidOperationException("Unrecognized combination of
arguments")

    def _Check(self):
        return (self.__color != None) and (len(self.__color) > 0)

    def GetRepresentation(self):
        if not self._Check():
            raise system.InvalidOperationException("Bad data")
        return f"color({self.__color})"

class Point(Step):
    def __init__(self, xPosValue, yPosValue):
        self.__xPos = 0
        self.__yPos = 0
        if isinstance(xPosValue, int) and isinstance(yPosValue, int):
            self.__xPos = xPosValue

```

```

        self.__yPos = yPosValue
    else:
        raise system.InvalidOperationException("Unrecognized combination of
arguments")

def _Check(self):
    return (self.__xPos >= 0) and (self.__yPos >= 0)

def GetRepresentation(self):
    if not self._Check():
        raise system.InvalidOperationException("Bad data")
    return f"point({self.__xPos},{self.__yPos})"

class Rectangle(Step):
    def __init__(self, *args):
        self.__xLeft = 0
        self.__yTop = 0
        self.__xRight = 0
        self.__yBottom = 0
        if (len(args) == 3) and isinstance(args[0], int) and isinstance(args[1], int) and
isinstance(args[2], int):
            xLeftValue = args[0]
            yTopValue = args[1]
            size = args[2]
            self.__xLeft = xLeftValue
            self.__yTop = yTopValue
            self.__xRight = xLeftValue + size
            self.__yBottom = yTopValue + size

```

```

        elif (len(args)== 4) and isinstance(args[0], int) and isinstance(args[1], int) and
isinstance(args[2], int) and isinstance(args[3], int):
            xLeftValue = args[0]
            yTopValue = args[1]
            xRightValue = args[2]
            yBottomValue = args[3]
            self.__xLeft = xLeftValue
            self.__yTop = yTopValue
            self.__xRight = xRightValue
            self.__yBottom = yBottomValue
        else:
            raise system.InvalidOperationException("Unrecognized combination of
arguments")

    def _Check(self):
        return (self.__xLeft >= 0) and (self.__yTop >= 0) and (self.__xRight >= 0) and
(self.__yBottom >= 0) and (self.__xRight > self.__xLeft) and (self.__yBottom >
self.__yTop)

    def GetRepresentation(self):
        if not self._Check():
            raise system.InvalidOperationException("Bad data")
        return
f"rectangle({self.__xLeft},{self.__yTop},{self.__xRight},{self.__yBottom})"

class Circle(Step):
    def __init__(self, xCenterValue, yCenterValue, radiusValue):
        self.__xCenter = 0

```

```

        self.__yCenter = 0
        self.__radius = 0
        if isinstance(xCenterValue, int) and isinstance(yCenterValue, int) and
isinstance(radiusValue, int):
            self.__xCenter = xCenterValue
            self.__yCenter = yCenterValue
            self.__radius = radiusValue
        else:
            raise system.InvalidOperationException("Unrecognized combination of
arguments")

    def _Check(self):
        minX = self.__xCenter - self.__radius
        minY = self.__yCenter - self.__radius
        return (self.__xCenter >= 0) and (self.__yCenter >= 0) and (self.__radius > 0)
and (minX >= 0) and (minY >= 0)

    def GetRepresentation(self):
        if not self._Check():
            raise system.InvalidOperationException("Bad data")
        return f'circle({self.__xCenter},{self.__yCenter},{self.__radius})'

class StepStorage:
    def __init__(self):
        self.__steps = system.collections.generic.List()

    def AddCircle(self, *args):
        if (len(args) == 1) and (isinstance(args[0], Circle) or args[0] is None):

```

```

        circle = args[0]
        if circle == None:
            raise system.ArgumentNullException("circle")
        self.__steps.Add(circle)
    elif (len(args) == 3) and isinstance(args[0], int) and isinstance(args[1], int) and
isinstance(args[2], int):
        xCenter = args[0]
        yCenter = args[1]
        radius = args[2]
        self.__steps.Add(Circle(xCenter, yCenter, radius))
    else:
        raise system.InvalidOperationException("Unrecognized combination of
arguments")

def AddColor(self, *args):
    if (len(args) == 1) and (isinstance(args[0], Color) or args[0] is None):
        color = args[0]
        if color == None:
            raise system.ArgumentNullException("color")
        self.__steps.Add(color)
    elif (len(args) == 1) and (isinstance(args[0], str) or args[0] is None):
        color = args[0]
        if color == None:
            raise system.ArgumentNullException("color")
        self.__steps.Add(Color(color))
    else:
        raise system.InvalidOperationException("Unrecognized combination of
arguments")

```

```

def AddMove(self, *args):
    if (len(args) == 1) and (isinstance(args[0], Move) or args[0] is None):
        move = args[0]
        if move == None:
            raise system.ArgumentNullException("move")
        self.__steps.Add(move)
    elif (len(args) == 2) and isinstance(args[0], int) and isinstance(args[1], int):
        x = args[0]
        y = args[1]
        self.__steps.Add(Move(x, y))
    else:
        raise system.InvalidOperationException("Unrecognized combination of
arguments")

def AddPoint(self, *args):
    if (len(args) == 1) and (isinstance(args[0], Point) or args[0] is None):
        point = args[0]
        if point == None:
            raise system.ArgumentNullException("point")
        self.__steps.Add(point)
    elif (len(args) == 2) and isinstance(args[0], int) and isinstance(args[1], int):
        x = args[0]
        y = args[1]
        self.__steps.Add(Point(x, y))
    else:
        raise system.InvalidOperationException("Unrecognized combination of
arguments")

```

```

def AddRectangle(self, *args):
    if (len(args) == 1) and (isinstance(args[0], Rectangle) or args[0] is None):
        rectangle = args[0]
        if rectangle == None:
            raise system.ArgumentNullException("rectangle")
        self.__steps.Add(rectangle)
    elif (len(args) == 3) and isinstance(args[0], int) and isinstance(args[1], int) and
isinstance(args[2], int):
        xLeft = args[0]
        yTop = args[1]
        size = args[2]
        self.__steps.Add(Rectangle(xLeft, yTop, size))
    elif (len(args) == 4) and isinstance(args[0], int) and isinstance(args[1], int) and
isinstance(args[2], int) and isinstance(args[3], int):
        xLeft = args[0]
        yTop = args[1]
        xRight = args[2]
        yBottom = args[3]
        self.__steps.Add(Rectangle(xLeft, yTop, xRight, yBottom))
    else:
        raise system.InvalidOperationException("Unrecognized combination of
arguments")

def GetSteps(self):
    return self.__steps

class IPainter(abc.ABC):

```

```

@abc.abstractmethod
def Paint(self, steps):
    if (isinstance(steps, system.collections.generic.IList) or steps is None):
        raise system.InvalidOperationException("Abstract method call")
    else:
        raise system.InvalidOperationException("Unrecognized combination of
arguments")

class SimplePainter(IPainter):
    def __init__(self):
        pass

    def Paint(self, steps):
        if (isinstance(steps, system.collections.generic.IList) or steps is None):
            if steps == None:
                raise system.ArgumentNullException("steps")
            for step in steps:
                system.Console.WriteLine(step.GetRepresentation())
        else:
            raise system.InvalidOperationException("Unrecognized combination of
arguments")

class Program:
    def __init__(self):
        pass

    @staticmethod
    def Main(args):

```

```

if (isinstance(args, list) or args is None):
    storage = StepStorage()
    storage.AddMove(3, 5)
    storage.AddColor("red")
    storage.AddPoint(10, 10)
    storage.AddMove(100, 100)
    storage.AddRectangle(12, 14, 55)
    storage.AddCircle(16, 16, 13)
    simplePainter = SimplePainter()
    simplePainter.Paint(storage.GetSteps())
else:
    raise system.InvalidOperationException("Unrecognized combination of
arguments")

if __name__ == "__main__":
    Program.Main([])

```

Если запустить этот результат, то мы получим следующий вывод (который совпадает с выводом исходного кода):

```

move(3,5)
color(red)
point(10,10)
move(100,100)
rectangle(12,14,67,69)
circle(16,16,13)

```

Можно сделать следующие выводы о результате трансляции исходного кода с помощью симплификатора и транслятора:

- Все свойства безопасности, относящиеся к классам L1 и L2, сохраняются (свойство безопасности “корректная поддержка

перегруженных методов” сохраняется для набора перегруженных методов, использованных в экспериментальном примере).

- Все свойства безопасности, относящиеся к классу L3, теряются. Мы считаем, что для нас это приемлемо (из-за особенностей языка Python).
- Свойств безопасности, относящихся к классу L4, нет.
- Результат выполнения полученного кода совпадает с результатом выполнения исходного кода.
- Интерфейс кода (интерфейс типов), полученного в результате трансляции, совпадает с интерфейсом исходного кода, за исключением изменения имен методов с модификаторами доступа `protected` и `private` в соответствии с правилами языка Python.

Таким образом, мы можем считать данную трансляцию кода успешной (см. раздел 3.7).

6.3 Результат ручной трансляции кода

Давайте рассмотрим, что же у нас получается, если транслировать исходный код вручную. Следует сказать, что для чистоты эксперимента данная ручная трансляция кода осуществлялась не автором (конечно, для статистической чистоты необходимо, чтобы таких вариантов было несколько и, желательно, как можно больше, но тогда нужно уметь определять, что такое “средний” код среди всех возможных вариантов).

Листинг 20 – Результат трансляции на язык Python вручную

```
# -*- coding: utf-8 -*-  
  
import abc  
  
class Step(abc.ABC):
```

```
@abc.abstractmethod
```

```
def _Check(self):
```

```
    pass
```

```
@abc.abstractmethod
```

```
def GetRepresentation(self):
```

```
    pass
```

```
class Move(Step):
```

```
    def __init__(self, xPosValue, yPosValue):
```

```
        self.__xPos = xPosValue
```

```
        self.__yPos = yPosValue
```

```
    def _Check(self):
```

```
        return (self.__xPos >= 0) and (self.__yPos >= 0)
```

```
    def GetRepresentation(self):
```

```
        if not self._Check():
```

```
            raise ValueError("Bad data")
```

```
        return f"move({self.__xPos},{self.__yPos})"
```

```
class Color(Step):
```

```
    def __init__(self, colorValue):
```

```
        self.__color = colorValue
```

```
    def _Check(self):
```

```
        return (self.__color != None) and (len(self.__color) > 0)
```

```
def GetRepresentation(self):
    if not self._Check():
        raise ValueError("Bad data")
    return f"color({self.__color})"
```

```
class Point(Step):
```

```
    def __init__(self, xPosValue, yPosValue):
        self.__xPos = xPosValue
        self.__yPos = yPosValue
```

```
    def _Check(self):
        return (self.__xPos >= 0) and (self.__yPos >= 0)
```

```
    def GetRepresentation(self):
        if not self._Check():
            raise ValueError("Bad data")
        return f"point({self.__xPos},{self.__yPos})"
```

```
class Rectangle(Step):
```

```
    def __init__(self, xLeftValue, yTopValue, size=None, xRightValue=None,
yBottomValue=None):
```

```
        self.__xLeft = xLeftValue
        self.__yTop = yTopValue
```

```
        if size is not None:
```

```
            self.__xRight = xLeftValue + size
            self.__yBottom = yTopValue + size
```

```
        elif (xRightValue is not None) and (yBottomValue is not None):
            self.__xRight = xRightValue
```

```

        self.__yBottom = yBottomValue
    else:
        raise ValueError("Bad data")

    def _Check(self):
        return (self.__xLeft >= 0) and (self.__yTop >= 0) and (self.__xRight >= 0) and
        (self.__yBottom >= 0) and (self.__xRight > self.__xLeft) and (self.__yBottom >
        self.__yTop)

    def GetRepresentation(self):
        if not self._Check():
            raise ValueError("Bad data")
        return
        f'rectangle({self.__xLeft},{self.__yTop},{self.__xRight},{self.__yBottom})'

class Circle(Step):
    def __init__(self, xCenterValue, yCenterValue, radiusValue):
        self.__xCenter = xCenterValue
        self.__yCenter = yCenterValue
        self.__radius = radiusValue

    def _Check(self):
        minX = self.__xCenter - self.__radius
        minY = self.__yCenter - self.__radius
        return (self.__xCenter >= 0) and (self.__yCenter >= 0) and (self.__radius > 0)
        and (minX >= 0) and (minY >= 0)

    def GetRepresentation(self):

```

```

    if not self._Check():
        raise ValueError("Bad data")
    return f"circle({self.__xCenter},{self.__yCenter},{self.__radius})"

class StepStorage:
    def __init__(self):
        self.__steps = []

    def AddCircle(self, circle=None, xCenter=None, yCenter=None, radius=None):
        if circle is not None:
            self.__steps.append(circle)
        elif (xCenter is not None) and (yCenter is not None) and (radius is not None):
            self.__steps.append(Circle(xCenter, yCenter, radius))
        else:
            raise ValueError("Bad data")

    def AddColor(self, color=None, colorString=None):
        if color is not None:
            self.__steps.append(color)
        elif colorString is not None:
            self.__steps.append(Color(colorString))
        else:
            raise ValueError("Bad data")

    def AddMove(self, move=None, x=None, y=None):
        if move is not None:
            self.__steps.append(move)
        elif (x is not None) and (y is not None):

```

```

        self.__steps.append(Move(x, y))
    else:
        raise ValueError("Bad data")

def AddPoint(self, point=None, x=None, y=None):
    if point is not None:
        self.__steps.append(point)
    elif (x is not None) and (y is not None):
        self.__steps.append(Point(x, y))
    else:
        raise ValueError("Bad data")

def AddRectangle(self, rectangle=None, xLeft=None, yTop=None, size=None,
xRight=None, yBottom=None):
    if rectangle is not None:
        self.__steps.append(rectangle)
    elif (xLeft is not None) and (yTop is not None) and (size is not None):
        self.__steps.append(Rectangle(xLeft, yTop, size=size))
    elif (xLeft is not None) and (yTop is not None) and (xRight is not None) and
(yBottom is not None):
        self.__steps.append(Rectangle(xLeft, yTop, xRightValue=xRight,
yBottomValue=yBottom))
    else:
        raise ValueError("Bad data")

def GetSteps(self):
    return self.__steps

```

```

class IPainter(abc.ABC):
    @abc.abstractmethod
    def Paint(self, steps):
        pass

class SimplePainter(IPainter):
    def Paint(self, steps):
        for step in steps:
            print(step.GetRepresentation())

class Program:
    @staticmethod
    def Main():
        storage = StepStorage()
        storage.AddMove(x=3, y=5)
        storage.AddColor(colorString="red")
        storage.AddPoint(x=10, y=10)
        storage.AddMove(x=100, y=100)
        storage.AddRectangle(xLeft=12, yTop=14, size=55)
        storage.AddCircle(xCenter=16, yCenter=16, radius=13)
        simplePainter = SimplePainter()
        simplePainter.Paint(storage.GetSteps())

if __name__ == "__main__":
    Program.Main()

```

Если запустить этот результат, то мы получим следующий вывод (который совпадает с выводом исходного кода):

```

move(3,5)

```

```
color(red)
point(10,10)
move(100,100)
rectangle(12,14,67,69)
circle(16,16,13)
```

Можно сделать следующие выводы о результате трансляции исходного кода вручную:

- Все свойства безопасности, относящиеся к классу L1, сохраняются.
- Свойство безопасности типобезопасность, которое принадлежит классу L2, не сохраняется.
- Свойство безопасности корректная поддержка перегруженных методов, которое принадлежит классу L2, поддерживается частично за счет именованных параметров; поведение такого подхода отличается от поведения перегруженных методов в исходном коде. Более того, если использовать обычные параметры вместо именованных (например, по неосторожности), то можно получить неожиданное поведение. Поэтому считаем, что это свойство безопасности не сохраняется.
- Все свойства безопасности, относящиеся к классу L3, теряются. Мы считаем, что для нас это приемлемо (из-за особенностей языка Python).
- Свойств безопасности, относящихся к классу L4, нет.
- Результат выполнения полученного кода совпадает с результатом выполнения исходного кода.
- Интерфейс кода (интерфейс типов), полученного в результате трансляции, не совпадает с интерфейсом исходного кода как раз из-за реализации поддержки перегруженных методов.

Таким образом, мы не можем считать данную трансляцию кода успешной, т.к. хотя функциональные требования полностью выполнены, нефункциональные требования выполнены лишь частично, особенно в области безопасности кода (см. раздел 3.7).

6.4 Результат трансляции кода с помощью LLM

В первую очередь, следует сделать следующие замечания об использовании и взаимодействии с LLM:

- Будет использоваться только deepseek; никаких дополнительных исследований и сравнений результатов работы разных LLM в рамках данной работы производиться не будет.
- Будет использоваться ограниченное число промптов для LLM; никаких дополнительных исследований и сравнений результатов работы для разных промптов (с целью поиска наилучшего) производиться не будет.
- Периодически LLM может выдавать не работающий код (при запуске которого возникает ошибка парсинга или ошибка времени выполнения); для решения подобных проблем используются уточняющие промпты. Здесь они и промежуточные некорректные результаты не будут приведены.
- Все приведенные ниже варианты при запуске генерируют вывод, совпадающий с выводом исходного кода; т.е. с соблюдением функциональных требований нет проблем у всех вариантов.

Попытка номер 1.

Использовался следующий промпт:

Тебе нужно транслировать следующий код с языка C# на язык Python.
Делай так, чтобы транслированный код был по максимуму похож на исходный.
Не используй комментарии в коде.

В результате был получен следующий код:

Листинг 21 – Результат трансляции на язык Python с помощью LLM в рамках подхода 1

```

class Step:
    def Check(self):
        raise NotImplementedError()

    def GetRepresentation(self):
        raise NotImplementedError()

class Move(Step):
    def __init__(self, xPosValue, yPosValue):
        self._xPos = xPosValue
        self._yPos = yPosValue

    def Check(self):
        return (self._xPos >= 0) and (self._yPos >= 0)

    def GetRepresentation(self):
        if not self.Check():
            raise InvalidOperationExcption("Bad data")
        return f"move({self._xPos},{self._yPos})"

class Color(Step):
    def __init__(self, colorValue):
        self._color = colorValue

    def Check(self):
        return (self._color is not None) and (len(self._color) > 0)

    def GetRepresentation(self):

```

```

        if not self.Check():
            raise InvalidOperationException("Bad data")
        return f"color({self._color})"

class Point(Step):
    def __init__(self, xPosValue, yPosValue):
        self._xPos = xPosValue
        self._yPos = yPosValue

    def Check(self):
        return (self._xPos >= 0) and (self._yPos >= 0)

    def GetRepresentation(self):
        if not self.Check():
            raise InvalidOperationException("Bad data")
        return f"point({self._xPos},{self._yPos})"

class Rectangle(Step):
    def __init__(self, xLeftValue, yTopValue, xRightValue, yBottomValue=None):
        if yBottomValue is None:
            size = xRightValue
            self._xLeft = xLeftValue
            self._yTop = yTopValue
            self._xRight = xLeftValue + size
            self._yBottom = yTopValue + size
        else:
            self._xLeft = xLeftValue
            self._yTop = yTopValue

```

```

        self._xRight = xRightValue
        self._yBottom = yBottomValue

    def Check(self):
        return (self._xLeft >= 0) and (self._yTop >= 0) and (self._xRight >= 0) and
        (self._yBottom >= 0) and (self._xRight > self._xLeft) and (self._yBottom >
        self._yTop)

    def GetRepresentation(self):
        if not self.Check():
            raise InvalidOperationExcption("Bad data")
        return
        f'rectangle({self._xLeft},{self._yTop},{self._xRight},{self._yBottom})'

class Circle(Step):
    def __init__(self, xCenterValue, yCenterValue, radiusValue):
        self._xCenter = xCenterValue
        self._yCenter = yCenterValue
        self._radius = radiusValue

    def Check(self):
        minX = self._xCenter - self._radius
        minY = self._yCenter - self._radius
        return (self._xCenter >= 0) and (self._yCenter >= 0) and (self._radius > 0) and
        (minX >= 0) and (minY >= 0)

    def GetRepresentation(self):
        if not self.Check():

```

```

        raise InvalidOperationException("Bad data")
    return f"circle({self._xCenter},{self._yCenter},{self._radius})"

class StepStorage:
    def __init__(self):
        self._steps = []

    def GetSteps(self):
        return self._steps

    def AddMove(self, move):
        if isinstance(move, Move):
            if move is None:
                raise ArgumentNullException("move")
            self._steps.append(move)
        else:
            x, y = move
            self._steps.append(Move(x, y))

    def AddColor(self, color):
        if isinstance(color, Color):
            if color is None:
                raise ArgumentNullException("color")
            self._steps.append(color)
        else:
            if color is None:
                raise ArgumentNullException("color")
            self._steps.append(Color(color))

```

```

def AddPoint(self, point):
    if isinstance(point, Point):
        if point is None:
            raise ArgumentNullException("point")
        self._steps.append(point)
    else:
        x, y = point
        self._steps.append(Point(x, y))

def AddRectangle(self, rectangle):
    if isinstance(rectangle, Rectangle):
        if rectangle is None:
            raise ArgumentNullException("rectangle")
        self._steps.append(rectangle)
    else:
        if len(rectangle) == 3:
            xLeft, yTop, size = rectangle
            self._steps.append(Rectangle(xLeft, yTop, size))
        else:
            xLeft, yTop, xRight, yBottom = rectangle
            self._steps.append(Rectangle(xLeft, yTop, xRight, yBottom))

def AddCircle(self, circle):
    if isinstance(circle, Circle):
        if circle is None:
            raise ArgumentNullException("circle")
        self._steps.append(circle)

```

```

else:
    xCenter, yCenter, radius = circle
    self._steps.append(Circle(xCenter, yCenter, radius))

class IPainter:
    def Paint(self, steps):
        raise NotImplementedError()

class SimplePainter(IPainter):
    def Paint(self, steps):
        if steps is None:
            raise ArgumentNullException("steps")
        for step in steps:
            print(step.GetRepresentation())

class Program:
    @staticmethod
    def Main(args):
        storage = StepStorage()
        storage.AddMove((3, 5))
        storage.AddColor("red")
        storage.AddPoint((10, 10))
        storage.AddMove((100, 100))
        storage.AddRectangle((12, 14, 55))
        storage.AddCircle((16, 16, 13))
        simplePainter = SimplePainter()
        simplePainter.Paint(storage.GetSteps())

```

```
if __name__ == "__main__":  
    class InvalidOperationException(Exception):  
        pass  
  
    class ArgumentNullException(Exception):  
        pass  
  
    Program.Main([])
```

Можно сделать следующие выводы о результате трансляции для данного варианта:

- Свойство безопасности проверка входных аргументов, которое принадлежит классу L1, сохраняется.
- Свойство безопасности сильная гарантия состояния программы к возникновению исключений, которое принадлежит классу L1, сохраняется.
- Свойство безопасности корректная работа с абстрактными типами и методами, которое принадлежит классу L1, не сохраняется из-за того, что в результате нет вообще абстрактных типов и методов.
- Свойство безопасности типобезопасность, которое принадлежит классу L2, не сохраняется.
- Свойство безопасности корректная поддержка перегруженных методов, которое принадлежит классу L2, поддерживается частично за счет изменения интерфейса кода. Поэтому считаем, что это свойство безопасности не сохраняется.
- Все свойства безопасности, относящиеся к классу L3, теряются. Мы считаем, что для нас это приемлемо (из-за особенностей языка Python).
- Свойств безопасности, относящихся к классу L4, нет.
- Результат выполнения полученного кода совпадает с результатом выполнения исходного кода.

- Интерфейс кода (интерфейс типов), полученного в результате трансляции, не совпадает с интерфейсом исходного кода из-за подхода к реализации поддержки перегруженных методов.
- Некоторые сущности (например, конструктор класса *Rectangle*) реализованы не самым лучшим способом.

Таким образом, мы не можем считать данную трансляцию кода успешной, т.к. хотя функциональные требования полностью выполнены, нефункциональные требования выполнены лишь частично, особенно в области безопасности кода (см. раздел 3.7).

Попытка номер 2.

Использовался следующий промпт:

Тебе нужно транслировать следующий код с языка C# на язык Python. Делай так, чтобы транслированный код был по максимуму похож на исходный.

Не используй комментарии в коде.

Есть такое понятие как свойства безопасности в коде.

Мы их можем классифицировать следующим образом относительно операции трансляции кода со следующим обозначением этих типов (классов) свойств безопасности:

L1 - свойства безопасности, которые автоматически сохраняются при трансляции;

L2 - свойства безопасности, поддержка которых отсутствует в языке/платформе, на который мы транслируем код, но которые мы можем симитировать (с помощью дополнительного кода, генерируемого при трансляции);

L3 - свойства безопасности, поддержка которых отсутствует в языке/платформе, на который мы транслируем код, и которые мы не можем симитировать (либо их имитация крайне сложна);

L4 - свойства безопасности, поддержка которых отсутствует в исходном коде, но которые появляются в коде после трансляции, причем не важно из-за действий транслятора или из-за свойств языка/платформы.

Необходимо, чтобы свойства безопасности, относящиеся к классам L1 и L2 были сохранены при трансляции.

В результате был получен следующий код:

Листинг 22 – Результат трансляции на язык Python с помощью LLM в рамках подхода 2 без использования промптов с уточнениями

```
import sys
from typing import List

class Step:
    def _check(self) -> bool:
        raise NotImplementedError

    def get_representation(self) -> str:
        raise NotImplementedError

class Move(Step):
    def __init__(self, x_pos_value: int, y_pos_value: int):
        self._x_pos = x_pos_value
        self._y_pos = y_pos_value

    def _check(self) -> bool:
        return (self._x_pos >= 0) and (self._y_pos >= 0)
```

```
def get_representation(self) -> str:
    if not self._check():
        raise InvalidOperationException("Bad data")
    return f"move({self._x_pos},{self._y_pos})"
```

```
class Color(Step):
    def __init__(self, color_value: str):
        self._color = color_value

    def _check(self) -> bool:
        return (self._color is not None) and (len(self._color) > 0)

    def get_representation(self) -> str:
        if not self._check():
            raise InvalidOperationException("Bad data")
        return f"color({self._color})"
```

```
class Point(Step):
    def __init__(self, x_pos_value: int, y_pos_value: int):
        self._x_pos = x_pos_value
        self._y_pos = y_pos_value

    def _check(self) -> bool:
        return (self._x_pos >= 0) and (self._y_pos >= 0)

    def get_representation(self) -> str:
        if not self._check():
```

```

        raise InvalidOperationException("Bad data")
    return f"point({self._x_pos},{self._y_pos})"

class Rectangle(Step):
    def __init__(self, x_left_value: int, y_top_value: int, x_right_value: int = None,
y_bottom_value: int = None, size: int = None):
        if size is not None:
            self._x_left = x_left_value
            self._y_top = y_top_value
            self._x_right = x_left_value + size
            self._y_bottom = y_top_value + size
        else:
            self._x_left = x_left_value
            self._y_top = y_top_value
            self._x_right = x_right_value
            self._y_bottom = y_bottom_value

    def _check(self) -> bool:
        return (self._x_left >= 0) and (self._y_top >= 0) and (self._x_right >= 0) and
(self._y_bottom >= 0) and (self._x_right > self._x_left) and (self._y_bottom >
self._y_top)

    def get_representation(self) -> str:
        if not self._check():
            raise InvalidOperationException("Bad data")
        return
f"rectangle({self._x_left},{self._y_top},{self._x_right},{self._y_bottom})"

```

```

class Circle(Step):
    def __init__(self, x_center_value: int, y_center_value: int, radius_value: int):
        self._x_center = x_center_value
        self._y_center = y_center_value
        self._radius = radius_value

    def _check(self) -> bool:
        min_x = self._x_center - self._radius
        min_y = self._y_center - self._radius
        return (self._x_center >= 0) and (self._y_center >= 0) and (self._radius > 0)
and (min_x >= 0) and (min_y >= 0)

    def get_representation(self) -> str:
        if not self._check():
            raise InvalidOperationException("Bad data")
        return f'circle({self._x_center},{self._y_center},{self._radius})'

class StepStorage:
    def __init__(self):
        self._steps = []

    def get_steps(self) -> List[Step]:
        return self._steps

    def add_move(self, move):
        if isinstance(move, Move):
            if move is None:
                raise ArgumentNullException("move")

```

```

        self._steps.append(move)
    else:
        x, y = move
        self._steps.append(Move(x, y))

def add_color(self, color):
    if isinstance(color, Color):
        if color is None:
            raise ArgumentNullException("color")
        self._steps.append(color)
    else:
        if color is None:
            raise ArgumentNullException("color")
        self._steps.append(Color(color))

def add_point(self, point):
    if isinstance(point, Point):
        if point is None:
            raise ArgumentNullException("point")
        self._steps.append(point)
    else:
        x, y = point
        self._steps.append(Point(x, y))

def add_rectangle(self, *args):
    if len(args) == 1:
        rectangle = args[0]
        if rectangle is None:

```

```

        raise ArgumentNullException("rectangle")
    self._steps.append(rectangle)
elif len(args) == 4:
    x_left, y_top, x_right, y_bottom = args
    self._steps.append(Rectangle(x_left, y_top, x_right, y_bottom))
elif len(args) == 3:
    x_left, y_top, size = args
    self._steps.append(Rectangle(x_left, y_top, size=size))

def add_circle(self, circle):
    if isinstance(circle, Circle):
        if circle is None:
            raise ArgumentNullException("circle")
        self._steps.append(circle)
    else:
        x_center, y_center, radius = circle
        self._steps.append(Circle(x_center, y_center, radius))

class IPainter:
    def paint(self, steps: List[Step]) -> None:
        raise NotImplementedError

class SimplePainter(IPainter):
    def paint(self, steps: List[Step]) -> None:
        if steps is None:
            raise ArgumentNullException("steps")
        for step in steps:
            print(step.get_representation())

```

```

class Program:
    @staticmethod
    def main(args: List[str]) -> None:
        storage = StepStorage()
        storage.add_move((3, 5))
        storage.add_color("red")
        storage.add_point((10, 10))
        storage.add_move((100, 100))
        storage.add_rectangle(12, 14, 55)
        storage.add_circle((16, 16, 13))
        simplePainter = SimplePainter()
        simplePainter.paint(storage.get_steps())

class InvalidOperationException(Exception):
    pass

class ArgumentNullException(Exception):
    pass

if __name__ == "__main__":
    Program.main(sys.argv[1:])

```

Можно сделать следующие выводы о результате трансляции для данного варианта:

- Свойство безопасности проверка входных аргументов, которое принадлежит классу L1, сохраняется.
- Свойство безопасности сильная гарантия состояния программы к возникновению исключений, которое принадлежит классу L1, сохраняется.

- Свойство безопасности корректная работа с абстрактными типами и методами, которое принадлежит классу L1, не сохраняется из-за того, что в результате нет вообще абстрактных типов и методов.
- Свойство безопасности типобезопасность, которое принадлежит классу L2, не сохраняется.
- Свойство безопасности корректная поддержка перегруженных методов, которое принадлежит классу L2, поддерживается частично за счет изменения интерфейса кода. Поэтому считаем, что это свойство безопасности не сохраняется.
- Все свойства безопасности, относящиеся к классу L3, теряются. Мы считаем, что для нас это приемлемо (из-за особенностей языка Python).
- Свойств безопасности, относящихся к классу L4, нет.
- Результат выполнения полученного кода совпадает с результатом выполнения исходного кода.
- Интерфейс кода (интерфейс типов), полученного в результате трансляции, не совпадает с интерфейсом исходного кода из-за подхода к реализации поддержки перегруженных методов, а также из-за изменения имен всех методов.

Таким образом, мы не можем считать данную трансляцию кода успешной, т.к. хотя функциональные требования полностью выполнены, нефункциональные требования выполнены лишь частично, особенно в области безопасности кода (см. раздел 3.7).

После нескольких промптов с уточнениями был получен следующий результат:

Листинг 23 – Результат трансляции на язык Python с помощью LLM в рамках подхода 2 с использованием промптов с уточнениями

```
import sys
from typing import List, Union, Optional
```

```

class Step:
    def _check(self) -> bool:
        raise NotImplementedError()

    def get_representation(self) -> str:
        raise NotImplementedError()

class Move(Step):
    def __init__(self, x_pos_value: int, y_pos_value: int):
        self.__x_pos = x_pos_value
        self.__y_pos = y_pos_value

    @property
    def x_pos(self) -> int:
        return self.__x_pos

    @property
    def y_pos(self) -> int:
        return self.__y_pos

    def _check(self) -> bool:
        return (self.__x_pos >= 0) and (self.__y_pos >= 0)

    def get_representation(self) -> str:
        if not self._check():
            raise InvalidOperationExcption("Bad data")
        return f'move({self.__x_pos},{self.__y_pos})'

```

```

class Color(Step):
    def __init__(self, color_value: str):
        if not isinstance(color_value, str):
            raise TypeError("color_value must be str")
        self.__color = color_value

    @property
    def color(self) -> str:
        return self.__color

    def _check(self) -> bool:
        return (self.__color is not None) and (len(self.__color) > 0)

    def get_representation(self) -> str:
        if not self._check():
            raise InvalidOperationExcption("Bad data")
        return f"color({self.__color})"

class Point(Step):
    def __init__(self, x_pos_value: int, y_pos_value: int):
        if not isinstance(x_pos_value, int) or not isinstance(y_pos_value, int):
            raise TypeError("x_pos_value and y_pos_value must be int")
        self.__x_pos = x_pos_value
        self.__y_pos = y_pos_value

    @property
    def x_pos(self) -> int:

```

```

    return self.__x_pos

@property
def y_pos(self) -> int:
    return self.__y_pos

def _check(self) -> bool:
    return (self.__x_pos >= 0) and (self.__y_pos >= 0)

def get_representation(self) -> str:
    if not self._check():
        raise InvalidOperationException("Bad data")
    return f"point({self.__x_pos},{self.__y_pos})"

class Rectangle(Step):
    def __init__(self, x_left_value: int, y_top_value: int, x_right_value: int = None,
y_bottom_value: int = None, size: int = None):
        if not isinstance(x_left_value, int) or not isinstance(y_top_value, int):
            raise TypeError("x_left_value and y_top_value must be int")
        if size is not None:
            if not isinstance(size, int):
                raise TypeError("size must be int")
            self.__x_left = x_left_value
            self.__y_top = y_top_value
            self.__x_right = x_left_value + size
            self.__y_bottom = y_top_value + size
        elif x_right_value is not None and y_bottom_value is not None:
            if not isinstance(x_right_value, int) or not isinstance(y_bottom_value, int):

```

```

        raise TypeError("x_right_value and y_bottom_value must be int")
    self.__x_left = x_left_value
    self.__y_top = y_top_value
    self.__x_right = x_right_value
    self.__y_bottom = y_bottom_value
else:
    raise ValueError("Invalid constructor arguments")

@property
def x_left(self) -> int:
    return self.__x_left

@property
def y_top(self) -> int:
    return self.__y_top

@property
def x_right(self) -> int:
    return self.__x_right

@property
def y_bottom(self) -> int:
    return self.__y_bottom

def _check(self) -> bool:
    return (self.__x_left >= 0) and (self.__y_top >= 0) and (self.__x_right >= 0)
and (self.__y_bottom >= 0) and (self.__x_right > self.__x_left) and
(self.__y_bottom > self.__y_top)

```

```

def get_representation(self) -> str:
    if not self._check():
        raise InvalidOperationException("Bad data")
    return
f"rectangle({self.__x_left},{self.__y_top},{self.__x_right},{self.__y_bottom})"

class Circle(Step):
    def __init__(self, x_center_value: int, y_center_value: int, radius_value: int):
        if not isinstance(x_center_value, int) or not isinstance(y_center_value, int) or
not isinstance(radius_value, int):
            raise TypeError("x_center_value, y_center_value, radius_value must be
int")
        self.__x_center = x_center_value
        self.__y_center = y_center_value
        self.__radius = radius_value

    @property
    def x_center(self) -> int:
        return self.__x_center

    @property
    def y_center(self) -> int:
        return self.__y_center

    @property
    def radius(self) -> int:
        return self.__radius

```

```

def _check(self) -> bool:
    min_x = self.__x_center - self.__radius
    min_y = self.__y_center - self.__radius
    return (self.__x_center >= 0) and (self.__y_center >= 0) and (self.__radius >
0) and (min_x >= 0) and (min_y >= 0)

def get_representation(self) -> str:
    if not self._check():
        raise InvalidOperationException("Bad data")
    return f"circle({self.__x_center},{self.__y_center},{self.__radius})"

class StepStorage:
    def __init__(self):
        self.__steps = []

    def get_steps(self) -> List[Step]:
        return self.__steps

    def add_move(self, param: Union[Move, int, tuple]) -> None:
        if isinstance(param, Move):
            if param is None:
                raise ArgumentNullException("move")
            self.__steps.append(param)
        elif isinstance(param, tuple) and len(param) == 2:
            x, y = param
            if not isinstance(x, int) or not isinstance(y, int):
                raise TypeError("x and y must be int")

```

```

        self.__steps.append(Move(x, y))
    else:
        raise TypeError("Invalid parameter type for add_move")

def add_color(self, param: Union[Color, str]) -> None:
    if isinstance(param, Color):
        if param is None:
            raise ArgumentNullException("color")
        self.__steps.append(param)
    elif isinstance(param, str):
        if param is None:
            raise ArgumentNullException("color")
        self.__steps.append(Color(param))
    else:
        raise TypeError("Invalid parameter type for add_color")

def add_point(self, param: Union[Point, int, tuple]) -> None:
    if isinstance(param, Point):
        if param is None:
            raise ArgumentNullException("point")
        self.__steps.append(param)
    elif isinstance(param, tuple) and len(param) == 2:
        x, y = param
        if not isinstance(x, int) or not isinstance(y, int):
            raise TypeError("x and y must be int")
        self.__steps.append(Point(x, y))
    else:
        raise TypeError("Invalid parameter type for add_point")

```

```

def add_rectangle(self, *args) -> None:
    if len(args) == 1:
        rectangle = args[0]
        if rectangle is None:
            raise ArgumentNullException("rectangle")
        if not isinstance(rectangle, Rectangle):
            raise TypeError("Expected Rectangle object")
        self.__steps.append(rectangle)
    elif len(args) == 4:
        x_left, y_top, x_right, y_bottom = args
        if not all(isinstance(arg, int) for arg in args):
            raise TypeError("All arguments must be int")
        self.__steps.append(Rectangle(x_left, y_top, x_right, y_bottom))
    elif len(args) == 3:
        x_left, y_top, size = args
        if not all(isinstance(arg, int) for arg in args):
            raise TypeError("All arguments must be int")
        self.__steps.append(Rectangle(x_left, y_top, size=size))
    else:
        raise TypeError("Invalid number of arguments for add_rectangle")

def add_circle(self, param: Union[Circle, int, tuple]) -> None:
    if isinstance(param, Circle):
        if param is None:
            raise ArgumentNullException("circle")
        self.__steps.append(param)
    elif isinstance(param, tuple) and len(param) == 3:

```

```

    x_center, y_center, radius = param
    if not all(isinstance(arg, int) for arg in param):
        raise TypeError("x_center, y_center, radius must be int")
    self.__steps.append(Circle(x_center, y_center, radius))
else:
    raise TypeError("Invalid parameter type for add_circle")

```

```

class IPainter:

```

```

    def paint(self, steps: List[Step]) -> None:
        raise NotImplementedError()

```

```

class SimplePainter(IPainter):

```

```

    def paint(self, steps: List[Step]) -> None:
        if steps is None:
            raise ArgumentNullException("steps")
        if not isinstance(steps, list):
            raise TypeError("steps must be list")
        for step in steps:
            if not isinstance(step, Step):
                raise TypeError("Each element in steps must be Step instance")
            print(step.get_representation())

```

```

class Program:

```

```

    @staticmethod
    def main(args: List[str]) -> None:
        storage = StepStorage()
        storage.add_move((3, 5))
        storage.add_color("red")

```

```

storage.add_point((10, 10))
storage.add_move((100, 100))
storage.add_rectangle(12, 14, 55)
storage.add_circle((16, 16, 13))
simplePainter = SimplePainter()
simplePainter.paint(storage.get_steps())

class InvalidOperationException(Exception):
    pass

class ArgumentNullException(Exception):
    pass

if __name__ == "__main__":
    Program.main(sys.argv[1:])

```

Также LLM выдала следующее заключение о найденных свойствах безопасности и их классах:

Сохранённые L1 свойства:

Инкапсуляция (двойное подчёркивание `__` для `private` полей)

Наследование (`Step` как базовый класс)

Проверка на `null` (`ArgumentNullException`)

Логика проверки через метод `_check()`

Абстрактные методы

Сохранённые L2 свойства:

Protected методы → метод `_check()` с одним подчёркиванием (конвенция `protected`)

Readonly поля → `property` без `setter`, приватные поля `__field`

Перегрузка методов → проверка типов через `isinstance()` и `*args`

Строгая типизация → runtime проверки типов через `isinstance()` и `TypeError`
Приватные поля → name mangling с `__` для эмуляции `private`

Можно сделать следующие выводы о результате трансляции для данного варианта:

- Не все заключения о найденных свойствах и/или их классах корректны: например, свойства безопасности инкапсуляция и `protected` методы принадлежат классу L3 (см раздел 3.5), наследование вообще не является свойством безопасности, поддержка `readonly` полей является свойством безопасности, которое принадлежит классу L3.
- Свойство безопасности проверка входных аргументов, которое принадлежит классу L1, сохраняется.
- Свойство безопасности сильная гарантия состояния программы к возникновению исключений, которое принадлежит классу L1, сохраняется.
- Свойство безопасности корректная работа с абстрактными типами и методами, которое принадлежит классу L1, не сохраняется из-за того, что в результате нет вообще абстрактных типов и методов.
- Свойство безопасности типобезопасность, которое принадлежит классу L2, частично сохраняется; например, в конструкторе класса `Move` нет проверок на соответствие аргументов ожидаемым типам.
- Свойство безопасности корректная поддержка перегруженных методов, которое принадлежит классу L2, поддерживается частично за счет изменения интерфейса кода. Поэтому считаем, что это свойство безопасности не сохраняется.
- Все свойства безопасности, относящиеся к классу L3, теряются. Мы считаем, что для нас это приемлемо (из-за особенностей языка Python).
- Свойств безопасности, относящихся к классу L4, нет.
- Результат выполнения полученного кода совпадает с результатом выполнения исходного кода.

- Интерфейс кода (интерфейс типов), полученного в результате трансляции, не совпадает с интерфейсом исходного кода из-за подхода к реализации поддержки перегруженных методов, а также из-за изменения имен всех методов.

Таким образом, мы не можем считать данную трансляцию кода успешной, т.к. хотя функциональные требования полностью выполнены, нефункциональные требования выполнены лишь частично (см. раздел 3.7). Следует сказать, что результат этой трансляции уже сильно близок к результату, который мы ожидаем.

Попытка номер 3.

Использовался следующий промпт:

Тебе нужно транслировать следующий код с языка C# на язык Python. Делай так, чтобы транслированный код был по максимуму похож на исходный.

Не используй комментарии в коде.

Есть такое понятие как свойства безопасности в коде.

В данном коде есть следующие свойства безопасности, которые необходимо сохранить:

- проверка входных аргументов
- сильная гарантия состояния программы к возникновению исключений
- типобезопасность
- корректная работа перегруженных методов
- корректная работа абстрактных типов и методов

В результате был получен следующий код:

Листинг 24 – Результат трансляции на язык Python с помощью LLM в рамках подхода 3 без использования промптов с уточнениями

```
import sys
```

```
from typing import List
```

```
class Step:
```

```
    def _check(self) -> bool:  
        raise NotImplementedError
```

```
    def get_representation(self) -> str:  
        raise NotImplementedError
```

```
class Move(Step):
```

```
    def __init__(self, x_pos_value: int, y_pos_value: int):  
        self._x_pos = x_pos_value  
        self._y_pos = y_pos_value
```

```
    def _check(self) -> bool:  
        return (self._x_pos >= 0) and (self._y_pos >= 0)
```

```
    def get_representation(self) -> str:  
        if not self._check():  
            raise InvalidOperationException("Bad data")  
        return f'move({self._x_pos},{self._y_pos})'
```

```
class Color(Step):
```

```
    def __init__(self, color_value: str):  
        self._color = color_value
```

```
    def _check(self) -> bool:  
        return (self._color is not None) and (len(self._color) > 0)
```

```

def get_representation(self) -> str:
    if not self._check():
        raise InvalidOperationException("Bad data")
    return f"color({self._color})"

```

```

class Point(Step):

```

```

    def __init__(self, x_pos_value: int, y_pos_value: int):
        self._x_pos = x_pos_value
        self._y_pos = y_pos_value

```

```

    def _check(self) -> bool:
        return (self._x_pos >= 0) and (self._y_pos >= 0)

```

```

    def get_representation(self) -> str:
        if not self._check():
            raise InvalidOperationException("Bad data")
        return f"point({self._x_pos},{self._y_pos})"

```

```

class Rectangle(Step):

```

```

    def __init__(self, x_left_value: int, y_top_value: int, x_right_value: int = None,
y_bottom_value: int = None, size: int = None):

```

```

        if x_right_value is not None and y_bottom_value is not None:

```

```

            self._x_left = x_left_value

```

```

            self._y_top = y_top_value

```

```

            self._x_right = x_right_value

```

```

            self._y_bottom = y_bottom_value

```

```

        elif size is not None:

```

```

        self._x_left = x_left_value
        self._y_top = y_top_value
        self._x_right = x_left_value + size
        self._y_bottom = y_top_value + size
    else:
        raise ArgumentException("Invalid constructor parameters")

    def _check(self) -> bool:
        return (self._x_left >= 0) and (self._y_top >= 0) and (self._x_right >= 0) and
        (self._y_bottom >= 0) and (self._x_right > self._x_left) and (self._y_bottom >
        self._y_top)

    def get_representation(self) -> str:
        if not self._check():
            raise InvalidOperationExpection("Bad data")
        return
        f"rectangle({self._x_left},{self._y_top},{self._x_right},{self._y_bottom})"

class Circle(Step):
    def __init__(self, x_center_value: int, y_center_value: int, radius_value: int):
        self._x_center = x_center_value
        self._y_center = y_center_value
        self._radius = radius_value

    def _check(self) -> bool:
        min_x = self._x_center - self._radius
        min_y = self._y_center - self._radius

```

```
    return (self._x_center >= 0) and (self._y_center >= 0) and (self._radius > 0)
and (min_x >= 0) and (min_y >= 0)
```

```
def get_representation(self) -> str:
    if not self._check():
        raise InvalidOperationException("Bad data")
    return f"circle({self._x_center},{self._y_center},{self._radius})"
```

```
class StepStorage:
```

```
    def __init__(self):
        self._steps: List[Step] = []
```

```
    def get_steps(self) -> List[Step]:
        return self._steps
```

```
    def add_move(self, move_or_x, y=None):
        if isinstance(move_or_x, Move):
            if move_or_x is None:
                raise ArgumentNullException("move")
            self._steps.append(move_or_x)
        elif isinstance(move_or_x, int) and isinstance(y, int):
            self._steps.append(Move(move_or_x, y))
        else:
            raise ArgumentException("Invalid arguments")
```

```
    def add_color(self, color_or_value):
        if isinstance(color_or_value, Color):
            if color_or_value is None:
```

```

        raise ArgumentNullException("color")
    self._steps.append(color_or_value)
elif isinstance(color_or_value, str):
    if color_or_value is None:
        raise ArgumentNullException("color")
    self._steps.append(Color(color_or_value))
else:
    raise ArgumentException("Invalid arguments")

def add_point(self, point_or_x, y=None):
    if isinstance(point_or_x, Point):
        if point_or_x is None:
            raise ArgumentNullException("point")
        self._steps.append(point_or_x)
    elif isinstance(point_or_x, int) and isinstance(y, int):
        self._steps.append(Point(point_or_x, y))
    else:
        raise ArgumentException("Invalid arguments")

def add_rectangle(self, rectangle_or_x_left, y_top=None, x_right=None,
y_bottom=None, size=None):
    if isinstance(rectangle_or_x_left, Rectangle):
        if rectangle_or_x_left is None:
            raise ArgumentNullException("rectangle")
        self._steps.append(rectangle_or_x_left)
    elif isinstance(rectangle_or_x_left, int) and isinstance(y_top, int) and
isinstance(x_right, int) and isinstance(y_bottom, int):

```

```

        self._steps.append(Rectangle(rectangle_or_x_left, y_top, x_right,
y_bottom))
    elif isinstance(rectangle_or_x_left, int) and isinstance(y_top, int) and
isinstance(size, int):
        self._steps.append(Rectangle(rectangle_or_x_left, y_top, size=size))
    else:
        raise ArgumentException("Invalid arguments")

def add_circle(self, circle_or_x_center, y_center=None, radius=None):
    if isinstance(circle_or_x_center, Circle):
        if circle_or_x_center is None:
            raise ArgumentNullException("circle")
        self._steps.append(circle_or_x_center)
    elif isinstance(circle_or_x_center, int) and isinstance(y_center, int) and
isinstance(radius, int):
        self._steps.append(Circle(circle_or_x_center, y_center, radius))
    else:
        raise ArgumentException("Invalid arguments")

class IPainter:
    def paint(self, steps: List[Step]) -> None:
        raise NotImplementedError

class SimplePainter(IPainter):
    def paint(self, steps: List[Step]) -> None:
        if steps is None:
            raise ArgumentNullException("steps")
        for step in steps:

```

```

        print(step.get_representation())

class ArgumentNullException(Exception):
    pass

class ArgumentException(Exception):
    pass

class InvalidOperationException(Exception):
    pass

class Program:
    @staticmethod
    def main(args: List[str]) -> None:
        storage = StepStorage()
        storage.add_move(3, 5)
        storage.add_color("red")
        storage.add_point(10, 10)
        storage.add_move(100, 100)
        storage.add_rectangle(12, 14, size=55)
        storage.add_circle(16, 16, 13)
        simplePainter = SimplePainter()
        simplePainter.paint(storage.get_steps())

if __name__ == "__main__":
    Program.main(sys.argv)

```

Можно сделать следующие выводы о результате трансляции для данного варианта:

- Свойство безопасности проверка входных аргументов, которое принадлежит классу L1, сохраняется.
- Свойство безопасности сильная гарантия состояния программы к возникновению исключений, которое принадлежит классу L1, сохраняется.
- Свойство безопасности корректная работа с абстрактными типами и методами, которое принадлежит классу L1, не сохраняется из-за того, что в результате нет вообще абстрактных типов и методов.
- Свойство безопасности типобезопасность, которое принадлежит классу L2, не сохраняется.
- Свойство безопасности корректная поддержка перегруженных методов, которое принадлежит классу L2, поддерживается частично за счет изменения интерфейса кода. Поэтому считаем, что это свойство безопасности не сохраняется.
- Все свойства безопасности, относящиеся к классу L3, теряются. Мы считаем, что для нас это приемлемо (из-за особенностей языка Python).
- Свойств безопасности, относящихся к классу L4, нет.
- Результат выполнения полученного кода совпадает с результатом выполнения исходного кода.
- Интерфейс кода (интерфейс типов), полученного в результате трансляции, не совпадает с интерфейсом исходного кода из-за подхода к реализации поддержки перегруженных методов, а также из-за изменения имен всех методов.
- Странная попытка использовать один и тот же аргумент функции для параметров разных типов, в результате чего появляются аргументы с подобными именами: *move_or_x*

Таким образом, мы не можем считать данную трансляцию кода успешной, т.к. хотя функциональные требования полностью выполнены,

нефункциональные требования выполнены лишь частично, особенно в области безопасности кода (см. раздел 3.7).

После нескольких промптов с уточнениями был получен следующий результат:

Листинг 25 – Результат трансляции на язык Python с помощью LLM в рамках подхода 3 с использованием промптов с уточнениями

```
from typing import List
from abc import ABC, abstractmethod

class Step(ABC):
    @abstractmethod
    def _check(self) -> bool:
        pass

    @abstractmethod
    def get_representation(self) -> str:
        pass

class Move(Step):
    def __init__(self, x_pos_value: int, y_pos_value: int):
        if not isinstance(x_pos_value, int) or not isinstance(y_pos_value, int):
            raise TypeError("Arguments must be of type int")
        self._x_pos = x_pos_value
        self._y_pos = y_pos_value

    def _check(self) -> bool:
        return (self._x_pos >= 0) and (self._y_pos >= 0)
```

```

def get_representation(self) -> str:
    if not self._check():
        raise InvalidOperationException("Bad data")
    return f"move({self._x_pos},{self._y_pos})"

```

```

class Color(Step):

```

```

    def __init__(self, color_value: str):
        if not isinstance(color_value, str):
            raise TypeError("Argument must be of type str")
        self._color = color_value

```

```

    def _check(self) -> bool:
        return (self._color is not None) and (len(self._color) > 0)

```

```

    def get_representation(self) -> str:
        if not self._check():
            raise InvalidOperationException("Bad data")
        return f"color({self._color})"

```

```

class Point(Step):

```

```

    def __init__(self, x_pos_value: int, y_pos_value: int):
        if not isinstance(x_pos_value, int) or not isinstance(y_pos_value, int):
            raise TypeError("Arguments must be of type int")
        self._x_pos = x_pos_value
        self._y_pos = y_pos_value

```

```

    def _check(self) -> bool:
        return (self._x_pos >= 0) and (self._y_pos >= 0)

```

```

def get_representation(self) -> str:
    if not self._check():
        raise InvalidOperationException("Bad data")
    return f"point({self._x_pos},{self._y_pos})"

class Rectangle(Step):
    def __init__(self, x_left_value: int, y_top_value: int, x_right_value: int = None,
y_bottom_value: int = None, size: int = None):
        if not isinstance(x_left_value, int) or not isinstance(y_top_value, int):
            raise TypeError("Arguments must be of type int")
        if x_right_value is not None and y_bottom_value is not None:
            if not isinstance(x_right_value, int) or not isinstance(y_bottom_value, int):
                raise TypeError("Arguments must be of type int")
            self._x_left = x_left_value
            self._y_top = y_top_value
            self._x_right = x_right_value
            self._y_bottom = y_bottom_value
        elif size is not None:
            if not isinstance(size, int):
                raise TypeError("Argument must be of type int")
            self._x_left = x_left_value
            self._y_top = y_top_value
            self._x_right = x_left_value + size
            self._y_bottom = y_top_value + size
        else:
            raise ArgumentException("Invalid constructor parameters")

```

```

def _check(self) -> bool:
    return (self._x_left >= 0) and (self._y_top >= 0) and (self._x_right >= 0) and
(self._y_bottom >= 0) and (self._x_right > self._x_left) and (self._y_bottom >
self._y_top)

def get_representation(self) -> str:
    if not self._check():
        raise InvalidOperationExcption("Bad data")
    return
f'rectangle({self._x_left},{self._y_top},{self._x_right},{self._y_bottom})'

class Circle(Step):
    def __init__(self, x_center_value: int, y_center_value: int, radius_value: int):
        if not isinstance(x_center_value, int) or not isinstance(y_center_value, int) or
not isinstance(radius_value, int):
            raise TypeError("Arguments must be of type int")
        self._x_center = x_center_value
        self._y_center = y_center_value
        self._radius = radius_value

    def _check(self) -> bool:
        min_x = self._x_center - self._radius
        min_y = self._y_center - self._radius
        return (self._x_center >= 0) and (self._y_center >= 0) and (self._radius > 0)
and (min_x >= 0) and (min_y >= 0)

    def get_representation(self) -> str:
        if not self._check():

```

```

        raise InvalidOperationException("Bad data")
    return f"circle({self._x_center},{self._y_center},{self._radius})"

class StepStorage:
    def __init__(self):
        self._steps: List[Step] = []

    def get_steps(self) -> List[Step]:
        return self._steps

    def add_move(self, move_or_x, y=None):
        if isinstance(move_or_x, Move):
            if move_or_x is None:
                raise ArgumentNullException("move")
            if not isinstance(move_or_x, Move):
                raise TypeError("Expected Move type")
            self._steps.append(move_or_x)
        elif isinstance(move_or_x, int) and isinstance(y, int):
            self._steps.append(Move(move_or_x, y))
        else:
            raise ArgumentException("Invalid arguments")

    def add_color(self, color_or_value):
        if isinstance(color_or_value, Color):
            if color_or_value is None:
                raise ArgumentNullException("color")
            if not isinstance(color_or_value, Color):
                raise TypeError("Expected Color type")

```

```

        self._steps.append(color_or_value)
    elif isinstance(color_or_value, str):
        if color_or_value is None:
            raise ArgumentNullException("color")
        self._steps.append(Color(color_or_value))
    else:
        raise ArgumentException("Invalid arguments")

def add_point(self, point_or_x, y=None):
    if isinstance(point_or_x, Point):
        if point_or_x is None:
            raise ArgumentNullException("point")
        if not isinstance(point_or_x, Point):
            raise TypeError("Expected Point type")
        self._steps.append(point_or_x)
    elif isinstance(point_or_x, int) and isinstance(y, int):
        self._steps.append(Point(point_or_x, y))
    else:
        raise ArgumentException("Invalid arguments")

def add_rectangle(self, rectangle_or_x_left, y_top=None, x_right=None,
y_bottom=None, size=None):
    if isinstance(rectangle_or_x_left, Rectangle):
        if rectangle_or_x_left is None:
            raise ArgumentNullException("rectangle")
        if not isinstance(rectangle_or_x_left, Rectangle):
            raise TypeError("Expected Rectangle type")
        self._steps.append(rectangle_or_x_left)

```

```

        elif isinstance(rectangle_or_x_left, int) and isinstance(y_top, int) and
isinstance(x_right, int) and isinstance(y_bottom, int):
            self._steps.append(Rectangle(rectangle_or_x_left, y_top, x_right,
y_bottom))
        elif isinstance(rectangle_or_x_left, int) and isinstance(y_top, int) and
isinstance(size, int):
            self._steps.append(Rectangle(rectangle_or_x_left, y_top, size=size))
        else:
            raise ArgumentException("Invalid arguments")

def add_circle(self, circle_or_x_center, y_center=None, radius=None):
    if isinstance(circle_or_x_center, Circle):
        if circle_or_x_center is None:
            raise ArgumentNullException("circle")
        if not isinstance(circle_or_x_center, Circle):
            raise TypeError("Expected Circle type")
        self._steps.append(circle_or_x_center)
    elif isinstance(circle_or_x_center, int) and isinstance(y_center, int) and
isinstance(radius, int):
        self._steps.append(Circle(circle_or_x_center, y_center, radius))
    else:
        raise ArgumentException("Invalid arguments")

class IPainter:
    def paint(self, steps: List[Step]) -> None:
        raise NotImplementedError

class SimplePainter(IPainter):

```

```

def paint(self, steps: List[Step]) -> None:
    if steps is None:
        raise ArgumentNullException("steps")
    if not isinstance(steps, list):
        raise TypeError("Expected list type")
    for step in steps:
        if not isinstance(step, Step):
            raise TypeError("Expected Step type")
        print(step.get_representation())

class ArgumentNullException(Exception):
    pass

class ArgumentException(Exception):
    pass

class InvalidOperationException(Exception):
    pass

class Program:
    @staticmethod
    def main(args: List[str]) -> None:
        storage = StepStorage()
        storage.add_move(3, 5)
        storage.add_color("red")
        storage.add_point(10, 10)
        storage.add_move(100, 100)
        storage.add_rectangle(12, 14, size=55)

```

```
storage.add_circle(16, 16, 13)
simplePainter = SimplePainter()
simplePainter.paint(storage.get_steps())

if __name__ == "__main__":
    Program.main([])
```

Можно сделать следующие выводы о результате трансляции для данного варианта:

- Свойство безопасности проверка входных аргументов, которое принадлежит классу L1, сохраняется.
- Свойство безопасности сильная гарантия состояния программы к возникновению исключений, которое принадлежит классу L1, сохраняется.
- Свойство безопасности корректная работа с абстрактными типами и методами, которое принадлежит классу L1, сохраняется частично, т.к. почему-то класс *Step* и его методы сделаны абстрактными, а класс *IPainter* и его методы не сделаны абстрактными.
- Свойство безопасности типобезопасность, которое принадлежит классу L2, сохраняется.
- Свойство безопасности корректная поддержка перегруженных методов, которое принадлежит классу L2, поддерживается частично за счет изменения интерфейса кода. Также, реализация поведения перегруженных методов в коде на языке Python отличается от поведения перегруженных методов в коде на языке C#: в коде на языке C# я могу, например, передать *null* в метод *StepStorage.AddMove*, но не могу в коде на языке Python передать *None* в метод *StepStorage.add_move*. Поэтому считаем, что это свойство безопасности не сохраняется.
- Все свойства безопасности, относящиеся к классу L3, теряются. Мы считаем, что для нас это приемлемо (из-за особенностей языка Python).

- Свойств безопасности, относящихся к классу L4, нет.
- Результат выполнения полученного кода совпадает с результатом выполнения исходного кода.
- Интерфейс кода (интерфейс типов), полученного в результате трансляции, не совпадает с интерфейсом исходного кода из-за подхода к реализации поддержки перегруженных методов, а также из-за изменения имен всех методов.
- Странная попытка использовать один и тот же аргумент функции для параметров разных типов, в результате чего появляются аргументы с подобными именами: *move_or_x*

Таким образом, мы не можем считать данную трансляцию кода успешной, т.к. хотя функциональные требования полностью выполнены, нефункциональные требования выполнены лишь частично (см. раздел 3.7). Следует сказать, что результат этой трансляции уже сильно близок к результату, который мы ожидаем.

6.5 Выводы из результатов экспериментов

Из полученных результатов экспериментов можно сделать следующие выводы:

- Данный эксперимент демонстрирует методику на модельном примере, а не доказывает её промышленную применимость ко всем возможным вариантам кода: web-сервисам, API, микросервисам, библиотекам и т.п.
- В выбранном модельном примере методика (трансляция кода с помощью симплификатора и транслятора) обеспечивает более предсказуемое сохранение защитных инвариантов. Следует сказать, что это полностью зависит от того, насколько полно и корректно реализован транслятор (см. раздел 4.10).
- Трансляция кода вручную показывает, что разработчики не всегда занимаются выявлением и анализом свойств безопасности при решении

подобных задач. Это по итогу приводит к тому, что свойства безопасности, которые принадлежат классу L2, теряются, т.к. для их сохранения необходимо создавать специальные компенсирующие механизмы, как, например, в случае такого свойства безопасности, как типобезопасность (см. раздел 3.5). Про анализ кода, созданного вручную следует сказать следующее: с одной стороны с точки зрения статистики нужно, чтобы вариантов решения было несколько и чем больше, тем лучше, с другой стороны - для этого нам нужно ввести понятие “средний” код и алгоритм, как его получить из всех возможных вариантов.

- Результаты трансляции с помощью LLM достаточно неоднозначны. В рамках проведённого эксперимента при ограниченном числе промптов трансляция с помощью LLM обеспечивала соблюдение всех функциональных требований, но не гарантировала сохранение всех заявленных инвариантов безопасности, изменяла интерфейс и требовала дополнительных уточнений
- Непредсказуемость работы LLM: периодически LLM может выдавать некорректный результат. Даже в данном эксперименте дважды LLM выдавал неработающий код. Данный код очень простой, поэтому все проблемы достаточно легко найти, однако в случае большого проекта это будет не так и тогда встает вопрос о контроле качества результата, получаемого с помощью LLM.
- Есть вопросы к качеству кода, генерируемом с помощью LLM по сравнению с кодом, который либо получается непосредственно в результате работы человека, либо получается в результате использования транслятора; например, использование одних и тех же именованных аргументов метода для объектов разных типов (обычно все-таки используют разные именованные аргументы метода для объектов разных типов). Это означает, что при трансляции большой

кодовой базы с одного языка на другой, качество кода может достаточно сильно деградировать.

- При работе с автоматизированным транслятором мы можем с помощью тестов как проверять корректность работы транслятора, так и документировать особенности его работы (например, как транслируется та или иная конструкция). Однако, для трансляции с помощью LLM возникает вопрос о возможности существования подобных тестов, т.к. нет никакой гарантии, что на один и тот же запрос к LLM мы всегда будем получать один и тот же ответ; к тому же, если запросы к LLM платные, то идея подобных тестов полностью теряет свой смысл.

Давайте рассмотрим результаты экспериментов в табличном виде. В таблице 9 приведено поведение всех свойств безопасности, которые были выделены в исходном коде при проведении эксперимента (см. раздел 6.1) при всех использованных видах трансляции.

Таблица 9. Поведение свойств безопасности при трансляции

Инвариант	Класс	Трансляция по методике	Ручная трансляция	Трансляция с помощью LLM
проверка входных аргументов	L1	сохраняется	сохраняется	сохраняется
сильная гарантия состояния к возникновению исключений	L1	сохраняется	сохраняется	сохраняется
корректная работа с абстрактными типами и методами	L1	сохраняется	сохраняется	теряется

типобезопасность	L2	сохраняется, с генерацией специального кода	теряется	теряется (есть частичная поддержка)
корректная поддержка перегруженных методов	L2	сохраняется, с генерацией специального кода (для набора перегруженных методов, использованных в экспериментальном примере)	теряется (есть частичная поддержка)	теряется (есть частичная поддержка)
Инкапсуляция, модификаторы доступа	L3	теряется	теряется	теряется
поддержка readonly полей	L3	теряется	теряется	теряется

В таблице 10 приведены разнообразные метрики, которые могут быть получены в ходе проведения эксперимента при всех использованных видах трансляции.

Таблица 10. Метрики при трансляции

Метрика	Трансляция по методике	Ручная трансляция	Трансляция с помощью LLM
сохранение свойств класса L1	сохраняются полностью	сохраняются полностью	теряется свойство “корректная работа с абстрактными

			типами и методами”
компенсация свойств класса L2	сохраняются на 100%; генерируются соответствующие компенсации	теряются	теряются; частично генерируются соответствующие компенсации
фиксация потери свойств класса L3	фиксируются	фиксируются	фиксируются
совпадение функционала (результата выполнения)	совпадает полностью	совпадает полностью	совпадает полностью
сохранение интерфейса	сохраняется согласно требованиям	не сохраняется	не сохраняется
число ручных уточнений	0	0	2-4
предсказуемость результата	полностью предсказуем	зависит от разработчика	непредсказуем; можно получить неработающий вариант

В таблице 11 приведены те же самые результаты, но в более компактном виде.

Таблица 11. Результаты эксперимента

Сценарий	Трансляция по методике	Ручная трансляция	Трансляция с помощью LLM
----------	------------------------	-------------------	--------------------------

Свойств сохранено	L1	3/3	3/3	2/3 (частичная поддержка)
Свойства созданы компенсации	L2,	2/2	0/2 (частичная поддержка)	0/2 (частичная поддержка)
Свойств потеряно	L3	2/2	2/2	2/2
Функциональные требования		100%	100%	100%
Итог		успешна	успешна по функциональным требованиям, не успешна по сохранению свойств безопасности	успешна по функциональным требованиям, не успешна по сохранению свойств безопасности

В таблице 12 приведены результаты проверок на негативных сценариях
- на некорректных данных.

Таблица 12. Результаты проверок на негативных сценариях

Проверка	Исходный код	Трансляция по методике	Ручная трансляция	Трансляция с помощью LLM
вызов AddColor с null (None)	ошибка компиляции	исключение	исключение по другой причине	исключение
вызов AddColor с объектом другого типа	ошибка компиляции	исключение	UB	UB

Некорректные данные в Rectangle	исключение	исключение	исключение	исключение
Создание Step	ошибка компиляции	ошибка времени выполнения	ошибка времени выполнения	зависит от результата работы LLM
Вызов несуществующей перегрузки	ошибка компиляции	исключение	зависит от вызова	зависит от вызова

Также следует сказать о том, какие в будущем возможны дальнейшие эксперименты (в рамках уже других работ):

- Трансляция кода нескольких разнообразных приложений (web-приложений, микросервисов, библиотек и т.п.) с проверкой с помощью SAST и DAST как исходного кода, так и кода, полученного в результате трансляции с последующим сравнением результатов. Основной проблемой здесь является создание обертки над АПИ (см. раздел 4.5 и раздел 5.5.2), т.к. это достаточно трудоемкий процесс: в одной только базовой библиотеке BCL (Base Class Library) для .NET содержится примерно 10000 - 15000 типов, у каждого из которых в среднем 8-12 методов, а есть еще ASP.NET Core, в которой примерно 20000-30000 типов; конечно нам не все типы будут нужны сразу, но тем не менее это достаточно трудоемкий процесс.
- Выбор различных LLM и различных промптов для них с тем, чтобы оценить, насколько хорошо и стабильно можно решать задачу автоматической трансляции кода между языками с сохранением семантики безопасности с помощью LLM, какая из LLM лучше для этого подходит и насколько детальным должны быть начальные промпты, чтобы минимизировать количество промптов с уточнениями.

Эти эксперименты следует проводить для разных проектов с проверкой результатов работы, прохождения тестов, а также с помощью SAST и DAST проверок. Также, эти эксперименты необходимо проводить вместе с трансляцией кода с помощью транслятора для сравнения результатов, полученных с помощью транслятора и с помощью LLM.

7 Ограничения

Процесс автоматической трансляции, несмотря на свои возможности, не является полностью универсальным решением, т.к. у него есть немало ограничений. Давайте посмотрим на некоторые из них:

1) Мы далеко не для каждой пары языков можем в автоматическом режиме транслировать код между этими языками. Например, если исходный код написан на C++ и широко использует шаблоны и метапрограммирование, то такой код мы скорее всего не сможем транслировать на тот же C#, в котором шаблонов и метапрограммирования нет (см раздел 4.4).

2) Свойства безопасности, принадлежащие классам L1 и L2, сильно зависят от их поддержки в трансляторе (см. раздел 4.10). Как уже говорилось (см. раздел 3.4), свойства безопасности, которые принадлежат классу L1, автоматически сохраняются при трансляции, для сохранения свойств безопасности, которые принадлежат классу L2 необходимо сгенерировать соответствующие компенсирующие механизмы (с помощью дополнительного кода, генерируемого при трансляции). Это все справедливо только в случае “идеального транслятора”; достаточно часто бывают ситуации, что транслятор умеет транслировать не весь код с одного языка на другой, при этом такой его урезанной функциональности хватает для сохранения функциональных требований и поведения исходного кода (см. раздел 1.9). Если транслятор не поддерживает функциональность, от которой зависит некоторое свойство безопасности, которое принадлежит классу L1, то это свойство безопасности не будет автоматически сохранено при трансляции. Если транслятор не поддерживает генерацию соответствующих компенсирующих механизмов для некоторого свойства, которое принадлежит классу L2, то это свойство также не будет сохранено при трансляции.

3) Влияние качества исходного кода (особенно в случае legacy-кода). Мы формируем набор свойств безопасности (отпечаток безопасности), с которым работаем на протяжении всей процедуры трансляции, на основе анализа

исходного кода (см разделы 3.1 и 3.2). Однако, если исходный код имеет достаточно низкое качество, то его набор свойств безопасности будет достаточно беден (особенно часто это справедливо для случая legacy-кода). Например, если в исходном коде проверка входных аргументов (для не приватных членов) полностью отсутствует, то соответствующего свойства безопасности не будет в наборе свойств безопасности (отпечатке безопасности); если же в исходном коде проверка входных аргументов выполняется не везде, то соответствующее свойство безопасности будет в наборе свойств безопасности (отпечатке безопасности), но со значением “поддерживается частично” (в агрегирующем наборе свойств безопасности). Ни транслятор, ни симплификатор повлиять на это никак не могут - они выполняют совершенно другие задачи (в промышленном решении могут использоваться специальные утилиты для генерации дополнительного кода, но в рамках данной работы они не рассматриваются - см. раздел 5.3).

4) Некорректное сопоставление свойства из двух наборов свойств безопасности (отпечатков безопасности) во время их сравнения (см. раздел 3.3). Обычно, мы сравниваем свойства из следующих двух наборов свойств безопасности (отпечатков безопасности): первый набор получен при анализе свойств безопасности для исходного кода, а другой - при анализе свойств безопасности для кода, полученного в результате трансляции. При этом нам нужно уметь сопоставлять свойства безопасности из этих двух наборов свойств безопасности (отпечатков безопасности) для того, чтобы отслеживать то, как свойства безопасности изменяются во время трансляции кода. Если в наборе свойств безопасности (отпечатке безопасности) для исходного кода и наборе свойств безопасности (отпечатке безопасности) для кода, полученного в результате трансляции, есть свойства с одним и тем же именем, то в этом случае все тривиально - свойства с одинаковыми именами всегда могут быть сопоставлены. Однако, не для всех свойств безопасности, которые присутствуют в наборе свойств безопасности (отпечатке безопасности) для

исходного кода, есть свойства безопасности с совпадающими именами, которые присутствуют в наборе свойств безопасности (отпечатке безопасности) для кода, полученного в результате трансляции: одна часть свойств безопасности просто не сохраняется при трансляции (это свойства безопасности, которые принадлежат классу L3), а другая часть свойств безопасности появляется в результате трансляции (это свойства безопасности, которые принадлежат классу L4). Оказывается, что достаточно часто мы можем семантически сопоставить свойство безопасности исходного кода, которое принадлежит классу L3 со свойством безопасности кода, полученного в результате трансляции, которое принадлежит классу L4. Это связано с тем, что языки (и платформы) могут отличаться по той функциональности, которую они содержат (поддерживают). Например, в языке C# для обработки ошибочных ситуаций используют исключения, тогда как в языке Golang исключений нет (в языке Golang есть паника, но это далеко не то, что исключения языка C#) и используются ошибки (объекты, которые возвращаются из функции). Предположим, что мы транслируем код с языка C# на язык Golang. Предположим, что у нас есть свойство безопасности “сильная гарантия к возникновению исключений” в исходном коде на языке C#, а в коде на языке Golang, полученном в результате трансляции, есть свойство безопасности “сильная гарантия к возникновению ошибок”. Очевидно, что эти два свойства безопасности можно семантически сопоставить (причем первое формально принадлежит классу L3, а второе формально принадлежит классу L4). И вот при таком семантическом сопоставлении есть опасность, что мы сопоставим не те свойства и получим при сравнении двух наборов свойств безопасности (отпечатков безопасности) совсем не тот результат.

5) Невозможность сравнения двух свойств безопасности со значением “поддерживается частично”. Мы ввели свойства безопасности кода, их значения и правила сравнения двух свойств безопасности, которые можно

семантически сопоставить (см. разделы 3.1-3.3). Однако при сравнении двух свойств безопасности со значением “поддерживается частично” результат не определен. Но как показывает практика, значение свойств безопасности “поддерживается частично” встречается достаточно часто (в некоторых проектах это вообще самое частое значение для свойств безопасности). Но разумного способа сравнения двух свойств безопасности со значением “поддерживается частично” нет. Пусть, например, у нас есть метод *M* с пятью аргументами; если в исходном коде у него проверяются первый и второй аргументы, а в коде, полученном в результате трансляции - третий и четвертый, то свойство безопасности для метода *M* имеет значение “поддерживается частично” как для исходного кода, так и для кода, полученного в результате трансляции. Очевидно, что невозможно сравнить эти два свойства безопасности. Особенно сильно это касается сравнения двух агрегирующих наборов свойств безопасности (отпечатков безопасности), т.к. кажется, что именно для агрегирующих наборов свойств безопасности (отпечатков безопасности) гораздо чаще будут встречаться свойства безопасности со значением “поддерживается частично”.

б) Получение свойств безопасности в автоматизированном режиме. Свойства безопасности можно получать как вручную, так и в автоматическом режиме. Однако, при получении свойств безопасности в автоматическом режиме есть ряд сложностей. Во-первых, необходимо уметь получать AST не только для исходного кода, но и для кода, полученного в результате трансляции (это не проблема, например, для примеров в данной работе, т.к. мы транслируем код с языка C# на язык Python, но может быть проблемой для другой пары языков). Во-вторых, для получения свойств безопасности в автоматическом режиме необходимо уметь анализировать AST специальным образом (например, для поиска определенных паттернов и конструкций); это достаточно большая задача, по объему и сложности не уступающая данной работе.

7) Влияние внешних зависимостей. Как уже говорилось ранее (см. раздел 3.6), внешние зависимости являются внешним фактором, который способен изменять состояние свойств безопасности после трансляции с течением времени и, как итог, приводить к “деградации” отпечатка безопасности. Другими словами, с течением времени из-за внешних зависимостей семантика безопасности может становиться “слабее” уже после трансляции. И это никак не исправить без вмешательства разработчиков, причем вносить правки потенциально нужно и в исходный код, и в код транслятора (или в библиотеку, используемую для согласования АПИ между исходным языком и языком, на который выполняется трансляция - см. раздел 4.5); после чего нужно будет получать новую версию кода с помощью трансляции.

8) Влияние ручного управления трансляцией на набор свойств безопасности (отпечатка безопасности) кода, полученного в результате трансляции. В результате ручного управления трансляцией мы можем получить код, который слабо связан с исходным кодом; у нас могут даже появиться новые сущности и исчезнуть сущности, которые есть в исходном коде. Как итог, наше предсказание эволюции свойств безопасности при трансляции может сильно отличаться от реальной картины (особенно это может касаться детализированных наборов свойств безопасности).

9) Методика автоматической трансляции программного кода между языками с сохранением семантики безопасности является обобщаемой, но она не доказана для всех пар языков. В данной работе был создан прототип только для трансляции с языка C# на язык Python. Обратное направление трансляции с языка Python на язык C# не реализовано; точно так же для других пар языков требуется отдельный профиль трансляции.

10) В данной работе веса инвариантов безопасности не вводятся, поскольку их определение зависит от проекта, контекста использования и

требований заказчика; учёт весов рассматривается как направление дальнейшего развития методики.

ЗАКЛЮЧЕНИЕ

Давайте посмотрим на то, что у нас в рамках данной работы получилось сделать. Мы показали, какие бывают свойства безопасности кода и как их можно получить для текущей кодовой базы с помощью ее анализа, используя списки Common Weakness Enumeration (CWE) и спецификации исходного языка. Было показано как из этих свойств безопасности формировать набор свойств безопасности (отпечаток безопасности) как агрегирующий, так и детализированный, а также как сравнивать два набора свойств безопасности (отпечатка безопасности) - до процедуры трансляции и после. Была определена классификация свойств безопасности (классы L1, L2, L3, L4) относительно процедуры трансляции кода с одного языка на другой, после чего, на основании этой классификации были разработаны правила трансформации свойств безопасности во время процедуры трансляции кода. Мы показали на примерах, что для сохранения свойств безопасности, которые относятся к классу L2, необходимо генерировать компенсирующие механизмы (дополнительный код), а свойства безопасности, которые относятся к классу L3, вообще сохранить нельзя, и это является фундаментальными особенностями таких свойств безопасности, а не какими-то недоработками в процедуре трансляции. Мы определили, при каких условиях при трансляции у нас сохраняется семантика безопасности: мы можем определить эти условия еще до проведения процедуры трансляции исходя из функциональных (и нефункциональных) требований, а также из свойств безопасности, присущих нашему коду и их классификации. Был рассмотрен ряд дополнительных вопросов о влиянии внешних зависимостей и окружения на набор свойств безопасности кода (отпечаток безопасности). После этого была выполнена математическая формализация нашего подхода к работе со свойствами безопасности (с наборами свойств безопасности) при трансляции кода с одного языка на другой. Далее мы определили, что такое автоматическая трансляция кода между языками, после чего провели

неформальную классификацию некоторых языков программирования и показали проблемы, возникающие при трансляции кода между языками (при промышленном использовании транслятора между разными парами языков), которые относятся к разным классам. Было сделано наблюдение, что, чем больше совпадают языки, между которыми происходит трансляция кода, друг с другом, тем проще процесс трансляции; и наоборот, чем дальше языки, между которыми происходит трансляция кода, друг от друга, тем сложнее процесс трансляции. Отсюда была выдвинута следующая гипотеза: чем больше совпадают языки, между которыми происходит трансляция кода, друг с другом, тем больше свойств безопасности будут принадлежать классу L1; чем дальше языки, между которыми происходит трансляция кода, друг от друга, тем больше свойств будут принадлежать классам L2 и L3. После этого были рассмотрены проблемы согласования АПИ при трансляции между языками и предложены методы решения этих проблем; также были рассмотрены возможности ручного влияния на процесс автоматической трансляции. Далее было показано, что мы можем упростить код транслятора за счет выделения отдельного шага перед трансляцией - симплификации, т.е. упрощение исходного кода так, чтобы транслятору было проще его обрабатывать. В качестве одной из центральных гипотез была выдвинута гипотеза о том, что корректно спроектированные правила симплификации позволяют сохранять релевантные свойства безопасности исходного кода, одновременно снижая сложность транслятора и вероятность дефекта при трансляции. Далее было показано, как процесс трансляции вместе с симплификацией реализован; также были показаны некоторые детали этой реализации. Был проведен эксперимент по сравнению разных подходов к трансляции кода: с использованием транслятора (и симплификатора), вручную, а также с использованием LLM. И, наконец, были описаны ограничения, которые возникают при использовании автоматической трансляции с сохранением семантики безопасности.

Из данной работы можно сделать следующий вывод: была разработана и экспериментально продемонстрирована методика контролируемой трансляции программного кода между языками с сохранением семантики безопасности на примере трансляции с языка C# на язык Python. Методика не гарантирует отсутствия всех уязвимостей в целевом коде, но позволяет заранее сформировать ожидаемый отпечаток безопасности, классифицировать инварианты по характеру сохранения, применить компенсирующие механизмы для свойств безопасности, принадлежащих классу L2, зафиксировать допустимые ослабления для свойств безопасности, принадлежащих классу L3, и сопоставить фактический результат с ожидаемым. Тем не менее, у метода автоматической трансляции кода между языками есть свой ряд ограничений, который не позволяет во всех случаях успешно транслировать код между языками, особенно если есть достаточно жесткие требования на сохранение тех или иных свойств безопасности.

Также следует сказать, что в данной работе продемонстрирована применимость методики для трансляции кода с языка C# на язык Python, а не доказана универсальность для всех пар языков.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Ховард М., Лебланк Д. "Защищённый код". Русская редакция, 2003 г.
2. Common Weakness Enumeration (CWE) – URL: <https://cwe.mitre.org/>
3. Marco Patrignani, Amal Ahmed, and Dave Clarke. 2018. Formal Approaches to Secure Compilation: A survey of fully abstract compilation and related work. ACM Comput. Surv. 1, 1, Article 1. – URL: <https://doi.org/10.1145/3280984>
4. ГОСТ Р 71206-2024 Национальный Стандарт Российской Федерации. Защита информации. Разработка безопасного Программного Обеспечения. Безопасный компилятор языков C/C++ Общие требования (Information protection. Secure software development. Safe C/C++ compiler. General requirements).
5. Capability Hardware Enhanced RISC Instructions (CHERI) – URL: <https://www.cl.cam.ac.uk/research/security/ctsrd/cheri/>
6. Intel Software Guard Extensions (Intel SGX) – URL: <https://eprint.iacr.org/2016/086.pdf>
7. Proof-carrying code (PCC) – URL: <https://www.cs.princeton.edu/~appel/papers/fpcc.pdf>
8. CompCert – URL: <https://compcert.org/>
9. seL4 microkernel – URL: <https://sel4.systems/>
10. WebAssembly (Wasm) – URL: <https://webassembly.org/>
11. Translation Validation of Optimizing Compilers by Yi Fang A dissertation submitted in partial fulfillment of the requirements for the degree of Doctor of Philosophy Department of Computer Science Courant Institute of Mathematical Sciences New York University December, 2005.
12. Strategy pattern – URL: https://en.wikipedia.org/wiki/Strategy_pattern
13. CWE-787: Out-of-bounds Write – URL: <https://cwe.mitre.org/data/definitions/787.html>

14. Python isinstance function – URL: <https://docs.python.org/3/library/functions.html#isinstance>
15. .NET Reflection API – URL: <https://learn.microsoft.com/en-us/dotnet/fundamentals/reflection/overview>
16. Python name mangling – URL: <https://docs.python.org/3/tutorial/classes.html#private-variables>
17. Python inspect module – URL: <https://docs.python.org/3/library/inspect.html>
18. C standard string library – URL: <https://en.cppreference.com/c/header/string>
19. Software Composition Analysis – URL: <https://github.com/resources/articles/what-is-software-composition-analysis>
20. Path Traversal Vulnerabilities – URL: https://owasp.org/www-community/attacks/Path_Traversal
21. CVE – URL: <https://www.cve.org/>
22. CERT Secure Coding – URL: <https://www.sei.cmu.edu/secure-development/>
23. OWASP – URL: <https://owasp.org/>
24. ГОСТ Р 56939-2024 “Защита информации. Разработка безопасного программного обеспечения. Общие требования” – URL: <https://base.garant.ru/410749342/>
25. ГОСТ Р 58412-2019 “Защита информации. Анализ угроз безопасности информации при разработке программного обеспечения” – URL: <https://files.stroyinf.ru/Index2/1/4293729/4293729971.htm>
26. Приказ ФСТЭК России от 01.12.2023 № 240 (“Об утверждении порядка проведения сертификации процессов безопасной разработки программного обеспечения средств защиты информации”) – URL: <https://normativ.kontur.ru/document?moduleId=1&documentId=502199>

27. Банк данных угроз безопасности информации ФСТЭК – URL: <https://bdu.fstec.ru/threat>
28. Методика ФСТЭК России 2021 года. Оценка угроз безопасности информации – URL: <https://fstec.ru/dokumenty/vse-dokumenty/spetsialnye-normativnye-dokumenty/metodicheskij-dokument-ot-5-fevralya-2021-g>
29. Альфред Ахо, Моника С. Лам, Рави Сети, Джеффри Ульман “Компиляторы: принципы, технологии и инструменты”. Издательский дом “Вильямс”, 2017г.
30. Вайнгартен Ф. “Трансляция языков программирования”. Издательство “Мир”, 1977г.
31. Опалева Э. А., Самойленко В. П. “Языки программирования и методы трансляции”. Издательство “Питер”, 2001г.
32. Мёссенбёк Х. “Конструирование компиляторов”. Издательство: ДМК Пресс, 2025г.
33. Никлаус Вирт “Построение компиляторов”. Издательство: ДМК Пресс, 2010г.
34. Пирс Бенджамин “Типы в языках программирования”. Издательство “Лямбда пресс”: “Добросвет”, 2011г.
35. Robert Harper “Practical Foundations for Programming Languages”.
36. The .NET Compiler Platform SDK (Roslyn) – URL: <https://learn.microsoft.com/en-us/dotnet/csharp/roslyn-sdk/>
37. Clang LibTooling – URL: <https://clang.llvm.org/docs/LibTooling.html>
38. ANTLR – URL: <https://www.antlr.org/>
39. Garbage collection – URL: [https://en.wikipedia.org/wiki/Garbage_collection_\(computer_science\)](https://en.wikipedia.org/wiki/Garbage_collection_(computer_science))
40. Reference cycles – URL: <https://doc.rust-lang.org/book/ch15-06-reference-cycles.html>
41. Weak reference – URL: https://en.wikipedia.org/wiki/Weak_reference

42. A garbage collector for C and C++ - URL:
<https://www.cs.princeton.edu/~appel/modern/c/software/boehm/gc.html>
43. Simple tracing (mark and sweep) garbage collector for Rust – URL:
<https://github.com/Manishearth/rust-gc>
44. Resource acquisition is initialization (RAII) – URL:
https://en.wikipedia.org/wiki/Resource_acquisition_is_initialization
45. Cyclomatic complexity – URL:
<https://www.sonarsource.com/resources/library/cyclomatic-complexity/>
46. Partial Classes and members – URL: <https://learn.microsoft.com/en-us/dotnet/csharp/programming-guide/classes-and-structs/partial-classes-and-methods>
47. PEP 8 – Style Guide for Python Code – URL:
<https://peps.python.org/pep-0008/>

ПРИЛОЖЕНИЕ А

Исходный код транслятора и симплификатора

Исходный код симплификатора расположен по следующему URL:
<https://github.com/stdstring/mephi.learning/tree/master/information.security/diploma/apps/SourceCodeSimplifier>:

- SourceCodeSimplifierApp – проект консольного приложения симплификатора.
- SourceCodeSimplifierAppTests – проект с модульными и интеграционными тестами для симплификатора.

Исходный код транслятора расположен по следующему URL:
<https://github.com/stdstring/mephi.learning/tree/master/information.security/diploma/apps/SimplePythonPorter>:

- SimplePythonPorterApp – проект консольного приложения транслятора.
- SimplePythonPorter – проект библиотеки, содержащей ядро транслятора.
- SimplePythonPorter.Tests - проект с интеграционными тестами для транслятора.
- ExperimentExample1 – проект, использовавшийся в эксперименте в качестве исходного.
- ExperimentExample1.Result – результаты проведения эксперимента.